AutoML, Autoresearch, MLOps +@

4.10

서민교

1. AutoML

정의

- 주어진 `search space` 안에서 더 좋은 모델 설정을 자동으로 찾는 방법

대표 작업

- `model selection`, `hyperparameter tuning`, `pipeline search`

초점

- 새로운 알고리즘 자체보다 후보 비교와 설정 탐색 자동화

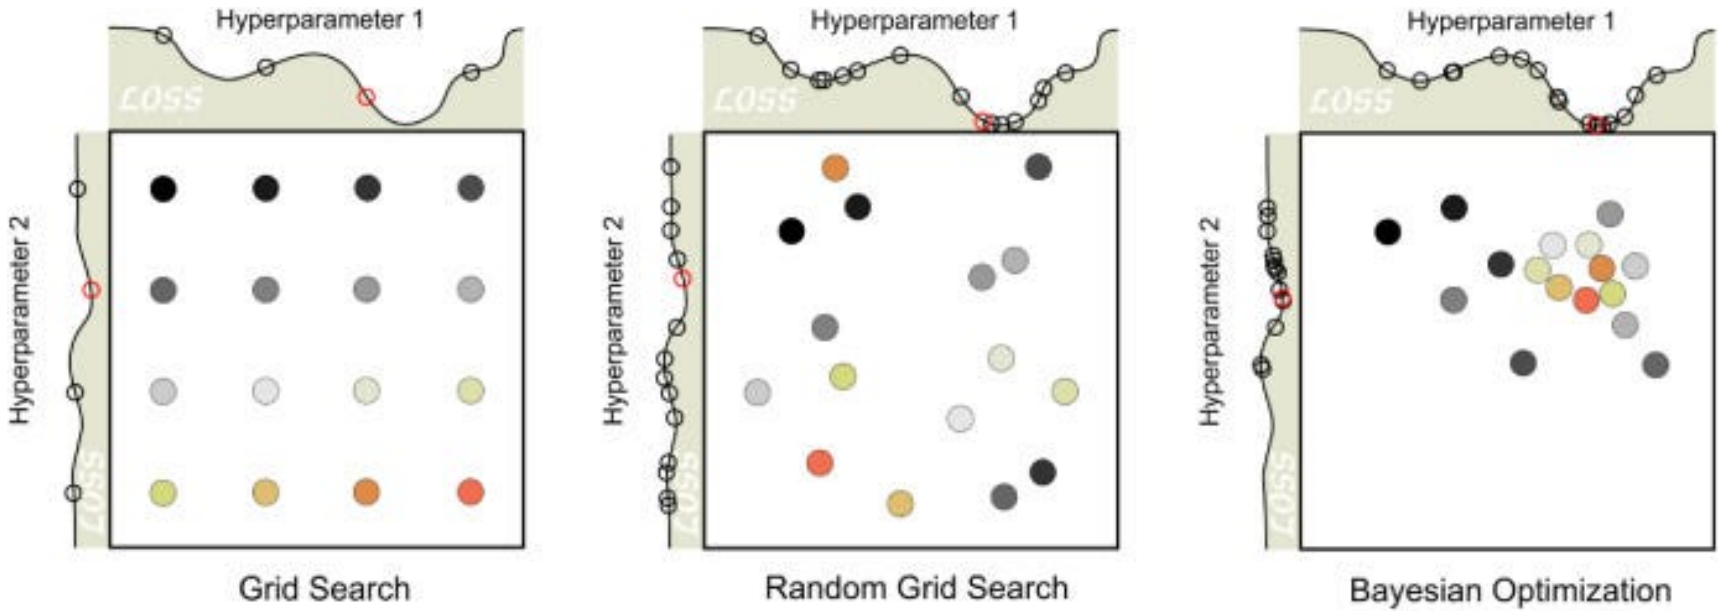

2. Neural Architecture Search

- 설정값이 아니라 architecture 자체를 탐색
- AutoML의 `더 넓은 search space` 확장선
- 그래도 중심은 여전히 모델/파이프라인 후보 탐색

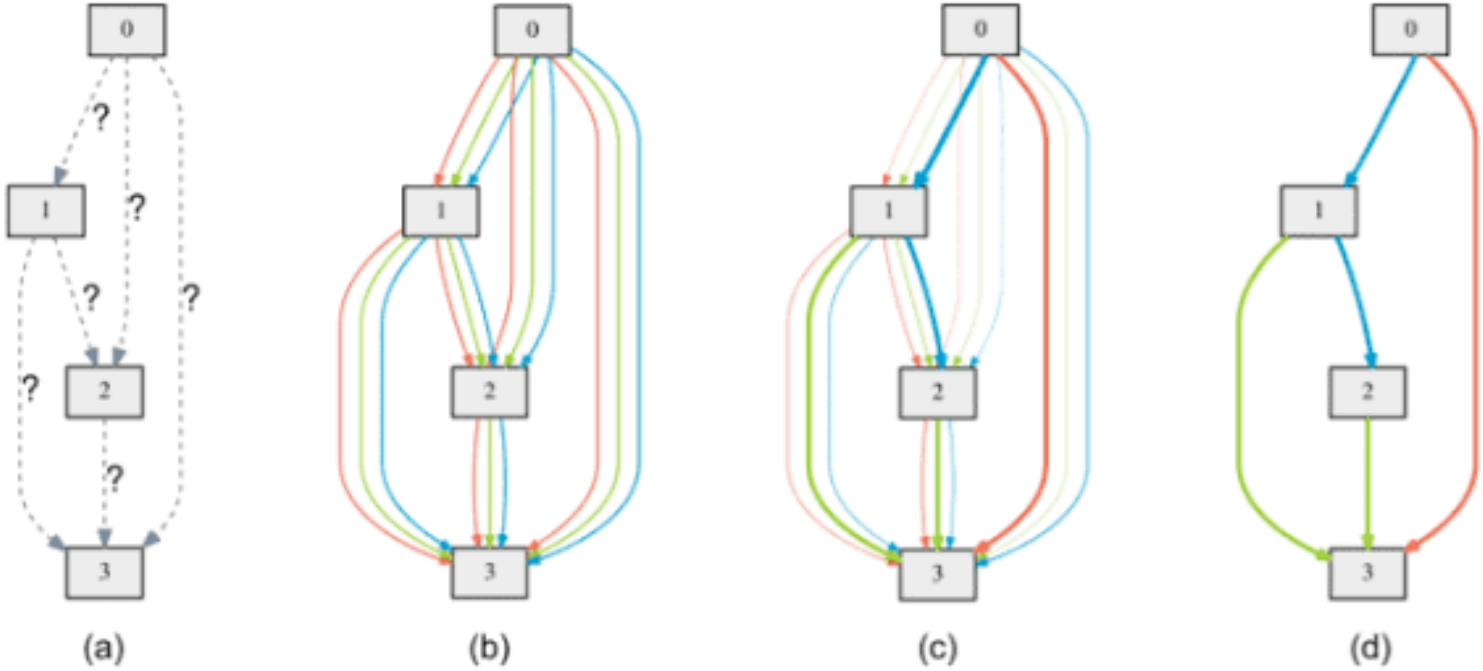

`hyperparameter search → pipeline search → architecture search`

3. Autoresearch

제안

- karpathy/autoresearch: 작은 training setup 위 `read → edit → run → keep-or-revert` loop 제시
- 연구 workflow 일부를 agent가 직접 수행하며, 설정 탐색을 넘어 `code`, `module`, `experiment` 자체 수정
- AutoML의 `fixed search space` 바깥으로 확장

이후 확장

- RD-Agent, AI-Scientist, GPT Researcher 등으로 빠르게 확장

4. Autoresearch Workflow

`Read → Hypothesis → Edit → Run → Analyze → Next experiment`

`Read`

- baseline, failure mode, 제약을 파악한다

`Hypothesis`

- 다음 실험에서 검증할 질문 하나를 명시한다

`Edit`

- 작은 가설 하나를 코드나 설정에 반영한다

`Run`

- 짧은 실험으로 metric과 artifact를 확인한다

`Analyze`

- keep, revert, 다음 실험 제안으로 이어진다

5. AutoML vs. Autoresearch

항목	AutoML	Autoresearch
탐색 대상	config, pipeline, architecture	hypothesis, code, module, experiment
핵심 질문	어떤 설정이 가장 좋은가	다음에 어떤 실험을 해야 하는가
edit 단위	parameter / architecture	code / module / pipeline / experiment
평가 방식	objective 중심	objective + reasoning + iteration
위험	비효율적 탐색	incoherent search, metric hacking
필요한 인프라	experiment infra	experiment + memory + harness

6. Autoresearch Applications

사용례

- 문헌 조사 / deep research: GPT Researcher
- 코드 수정 + 실험 반복: karpathy/autoresearch, RD-Agent
- end-to-end 연구 자동화: AI-Scientist

확장

- benchmark / evaluation: MLE-bench, MLAgentBench, MLR-Bench
- plugin / skill 생태계: awesome-autoresearch, Awesome Auto Research Tools

7. 실험 운영의 어려움

공통 어려움

- `많은 run` 비교와 누적
- 어떤 edit가 차이를 만들었는지 추적하기 어렵다

agent 특유 문제

- `artifact`, `promotion`, `monitoring`, `cost control`까지 함께 관리해야 한다

8. MLOps

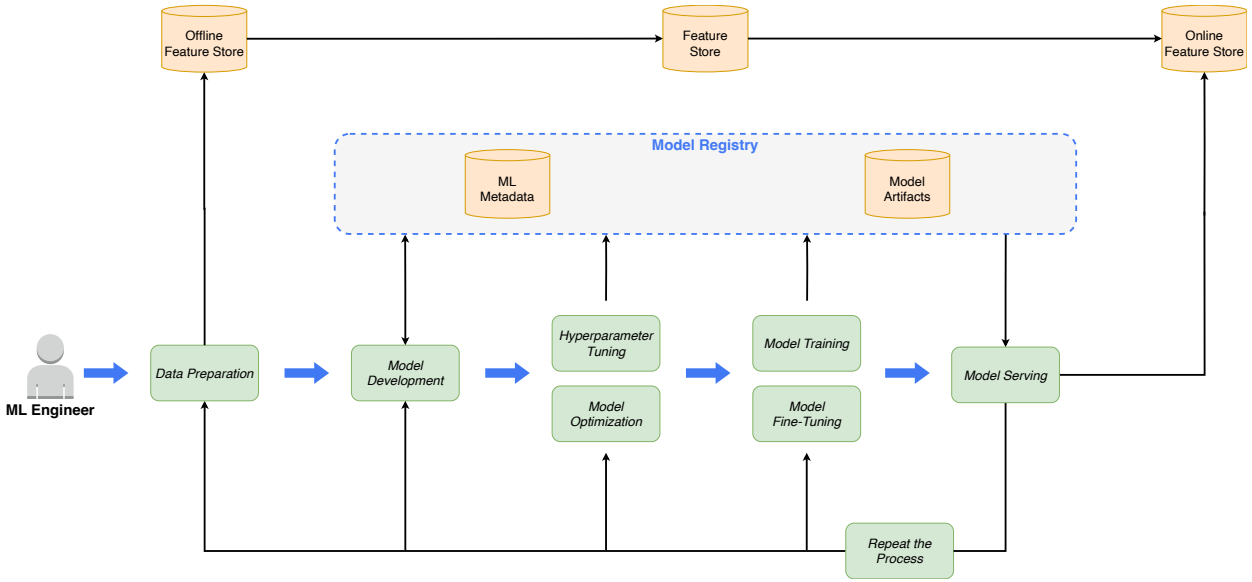

정의

- 모델 개발, 관리, 배포 파이프라인을 유지 관리하는 작업

필요성

- Autoresearch loop는 이 큰 ML lifecycle 안의 일부

핵심 역할

- 지속 운영 , 추적 , 승격 , 유지관리

9. MLOps 요소

요소	AutoML에서의 역할	Autoresearch에서의 역할
tracking	sweep 비교	hypothesis / code edit history 비교
orchestration	search job 실행	agent + eval job 실행
registry / lineage	best model 승격	experiment / prompt / code provenance 보존
monitoring / cost	retrain trigger, SLO	budget, drift, unsafe promotion guardrail

10. 두 질문

성능

- `(AutoML의 도메인에서)` `Autoresearch` 는 baseline보다 낫나

운영

- `Autoresearch` 에 어떤 harness가 있으면 좋을까

11. 질문 1 셋업

비교 항목

Method	구성
`TPE Direct`	`Optuna TPE` 가 직접 candidate 제안
`SMAC Direct`	`SMAC3` 가 직접 candidate 제안
`Plain Agent`	advisor 없이 plain `Autoresearch` 실행

실험 환경

- benchmarks: `fashion`, `twenty`, `spam`, `cifar`
- model: fixed `mlp` search space
- readout: `best val`, frontier trajectory

12. 관련 문헌

- Using Large Language Models for Hyperparameter Optimization
  - 실험 이력 기반 순차 튜닝은 가능하지만, 장기적으로 BO 우위는 불명확하다.
- LLAMBO: Large Language Models to Enhance Bayesian Optimization
  - LLM은 BO를 대체하기보다 초기 탐색을 강화하는 보조 수단에 가깝다.
- AgentHPO: Large Language Model Agent for Hyper-Parameter Optimization
  - Agent형 LLM HPO는 가능성을 보였지만, BO 대비 성능 우위 근거는 약하다.
- SLLMBO: Sequential Large Language Model-Based Hyper-parameter Optimization
  - Hybrid LLM-BO 방식은 일부 태스크에서 classical BO보다 강하다.

13. Optuna TPE

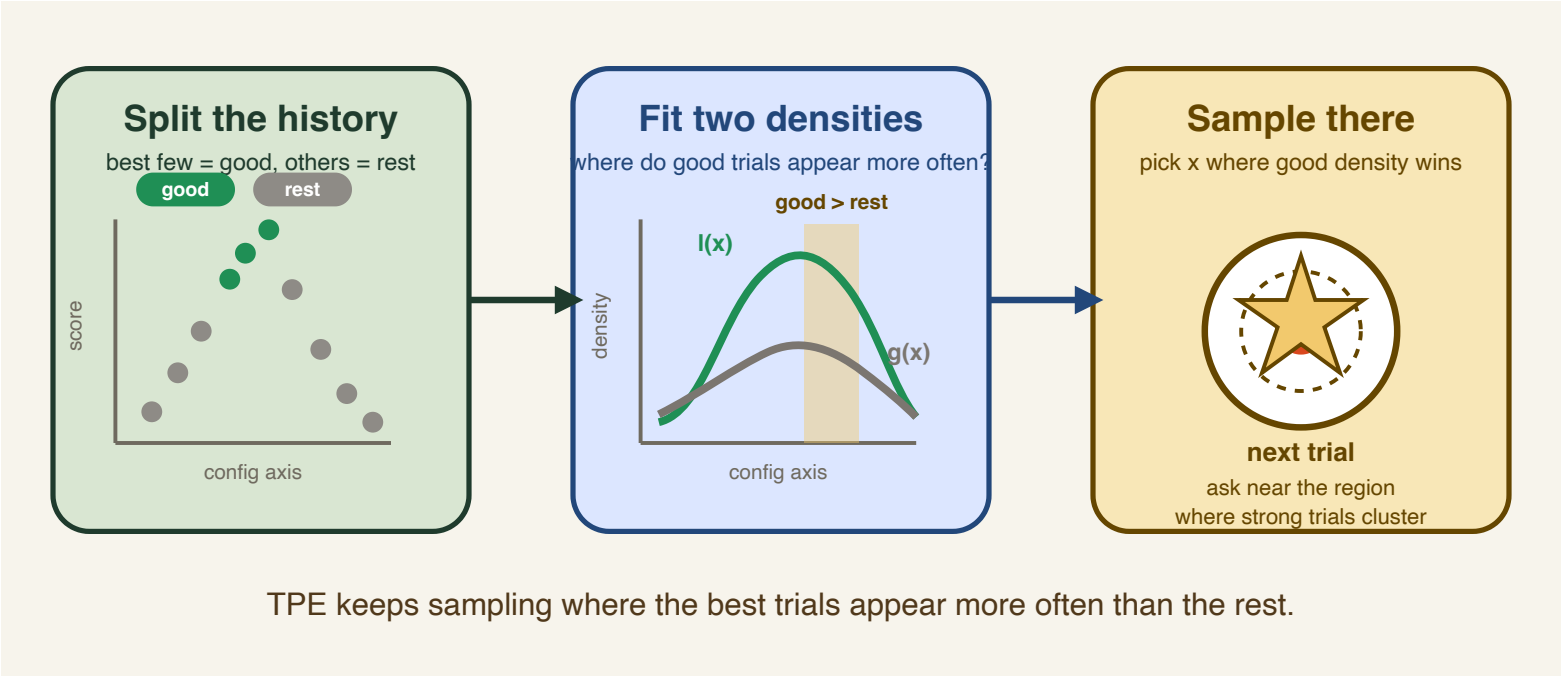

핵심 직관

- 지난 trial을 상위권 과 나머지 로 나눈다

다음 점

- 상위권이 자주 나오고 나머지는 덜 나오는 구간을 다시 찍는다

읽는 법

14. SMAC3

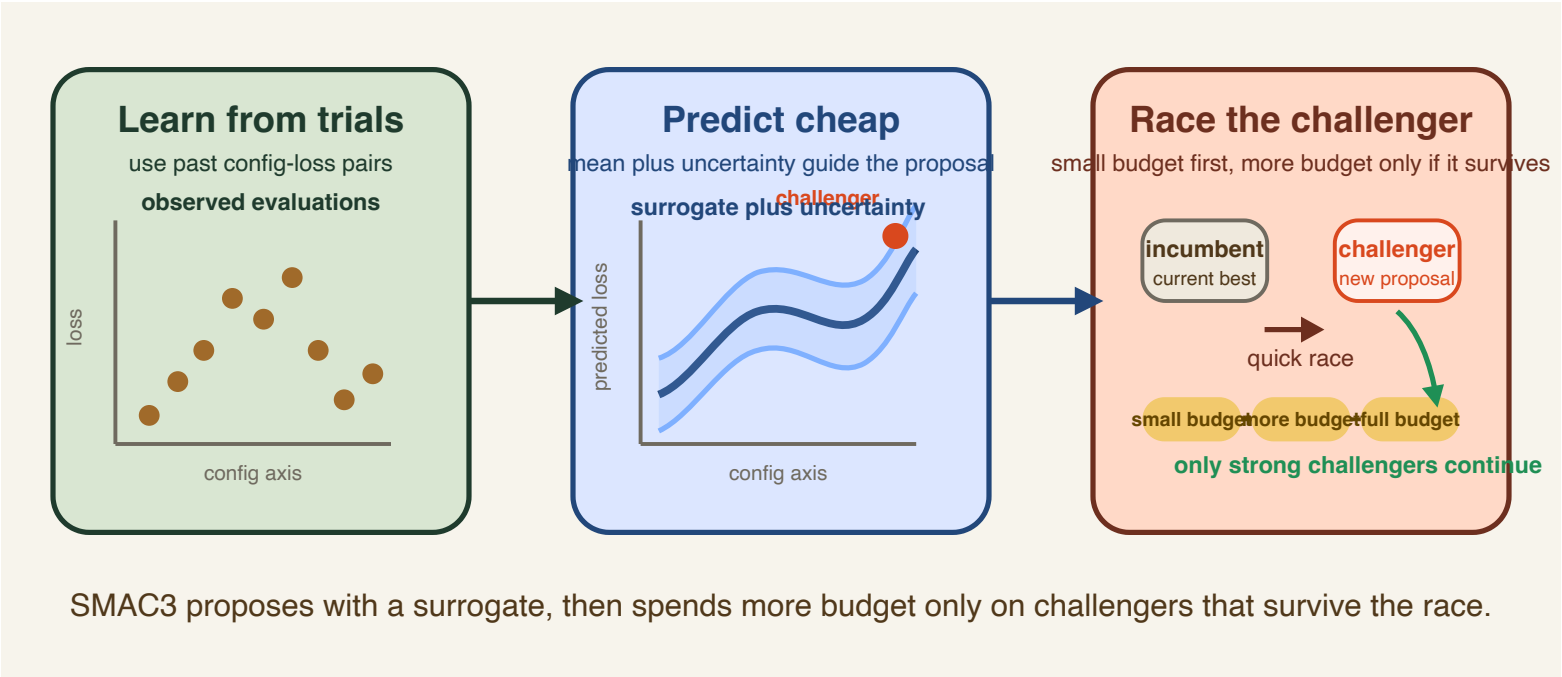

핵심 직관

- 과거 평가 기록으로 싸게 예측하는 대리모델을 만든다

다음 점

- 평균이 좋아 보이거나 불확실성이 큰 challenger를 먼저 뽑는다

비교 방식

15. 질문 1 표

Question 1: Comparison Groups x Datasets

Comparison Group	Fashion-MNIST	Twenty Newsgroups	SMS Spam	CIFAR-10
TPE Direct	0.854	0.551	0.990	0.428
SMAC Direct	0.863	0.543	0.989	0.413
Plain Agent	0.855	0.566	0.990	0.388

- 질문 1은 `Plain Agent` 와 `TPE/SMAC direct` 를 같은 dataset set에서 비교한 표다. winner는 여전히 dataset마다 갈린다.
- 그래서 baseline 비교의 결론은 단일 champion보다 dataset별 shortlist에 가깝다.

16. 질문 1 추적 A

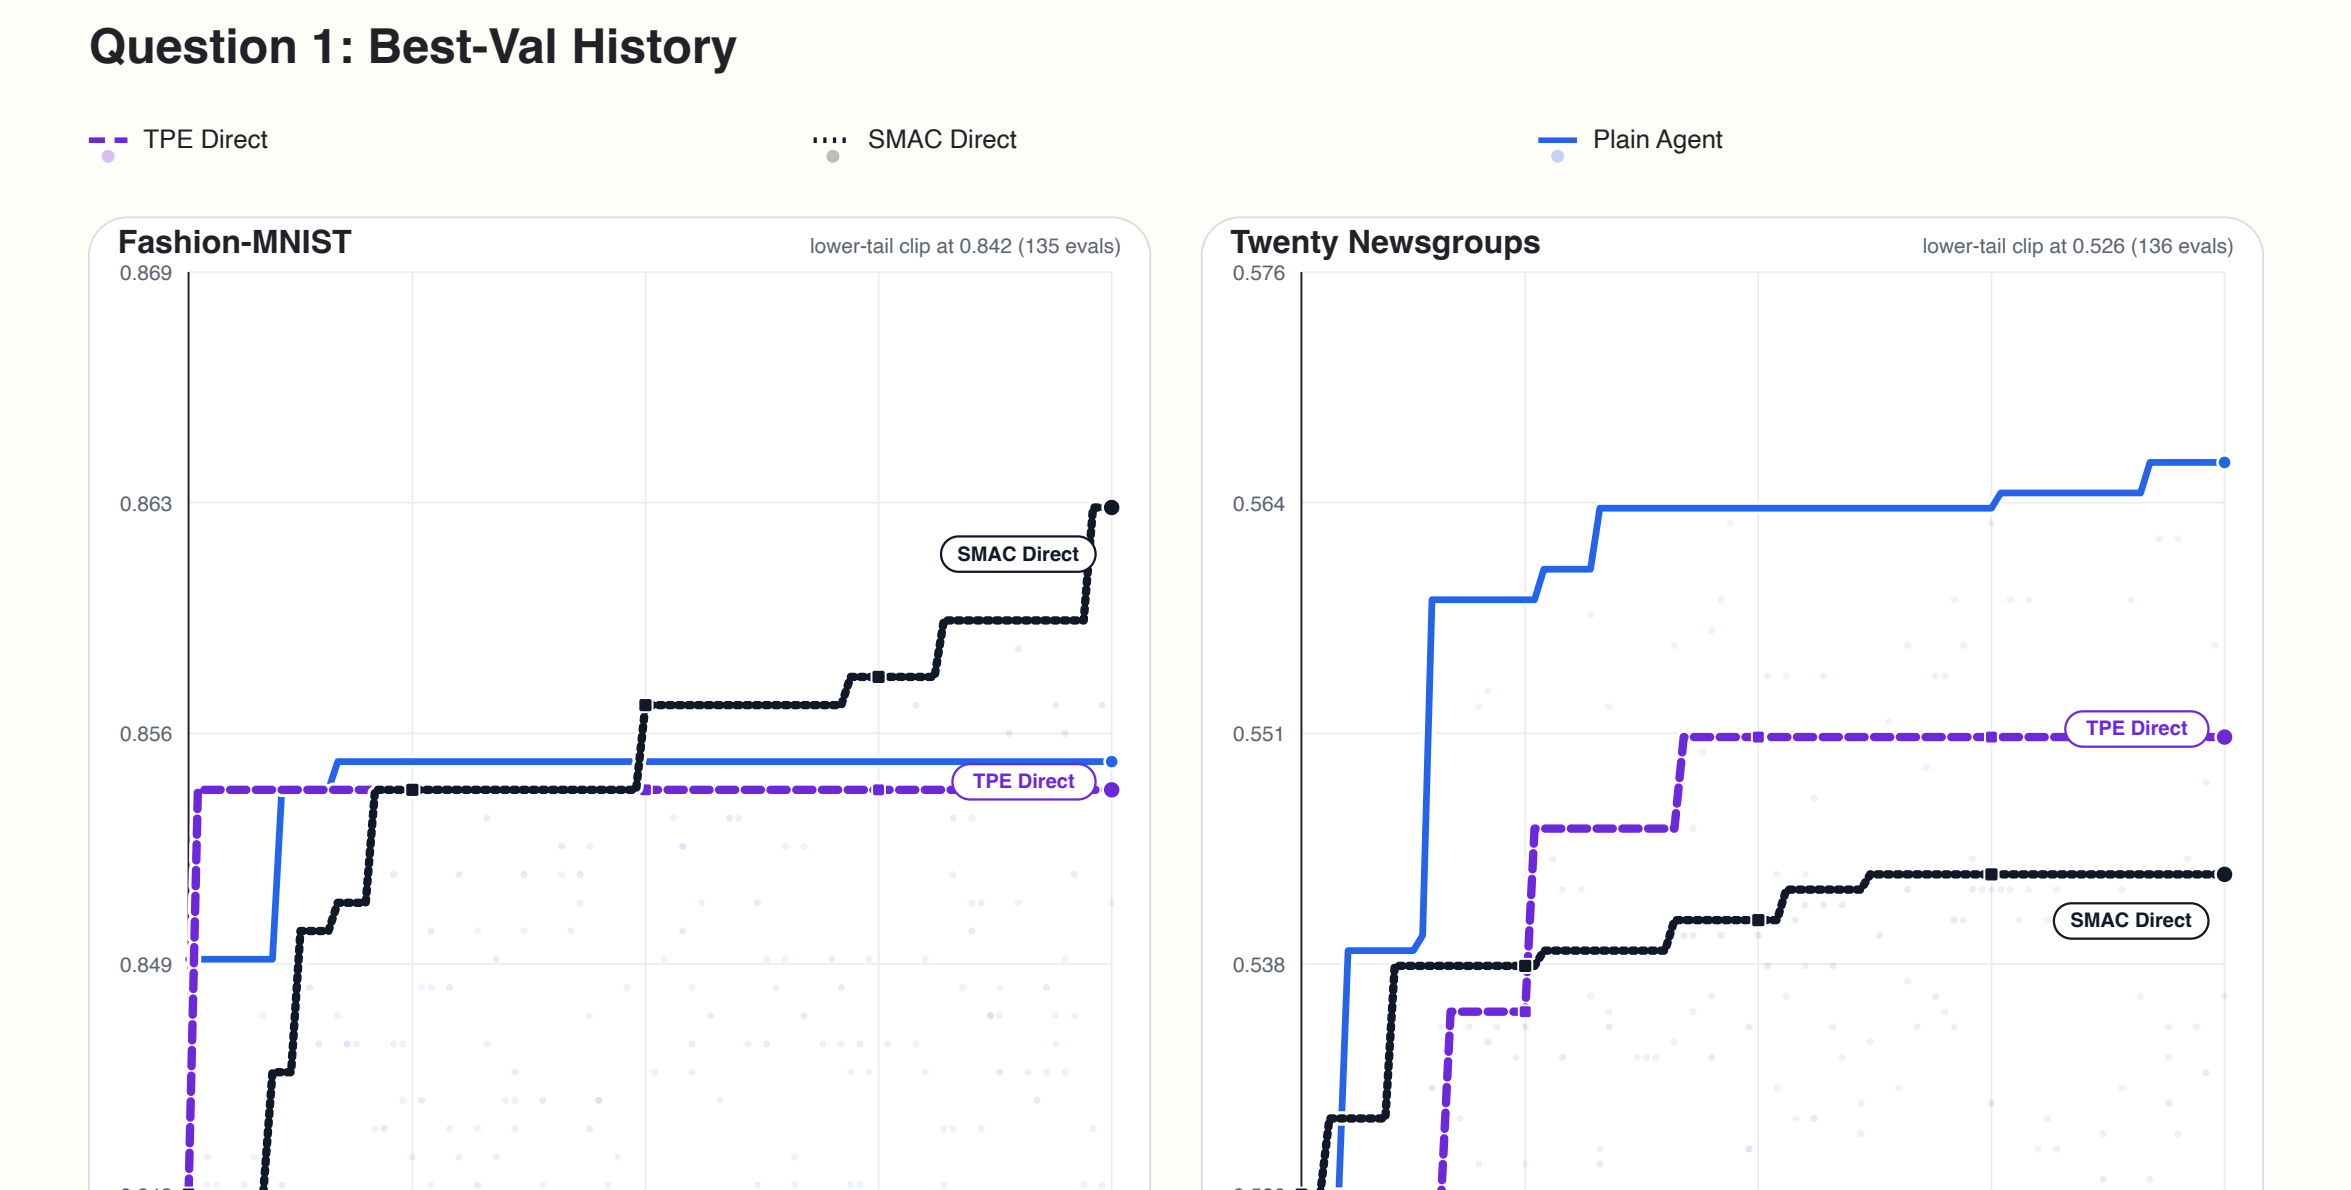
Question 1: Best-Val History
TPE Direct
SMAC Direct
Plain Agent
Fashion-MNIST
lower-tail clip at 0.842 (135 evals)
0.869
0.863
0.856
0.849
SMAC Direct
TPE Direct
Twenty Newsgroups
lower-tail clip at 0.526 (136 evals)
0.576
0.564
0.551
0.538
TPE Direct
SMAC Direct

17. 질문 1 추적 B

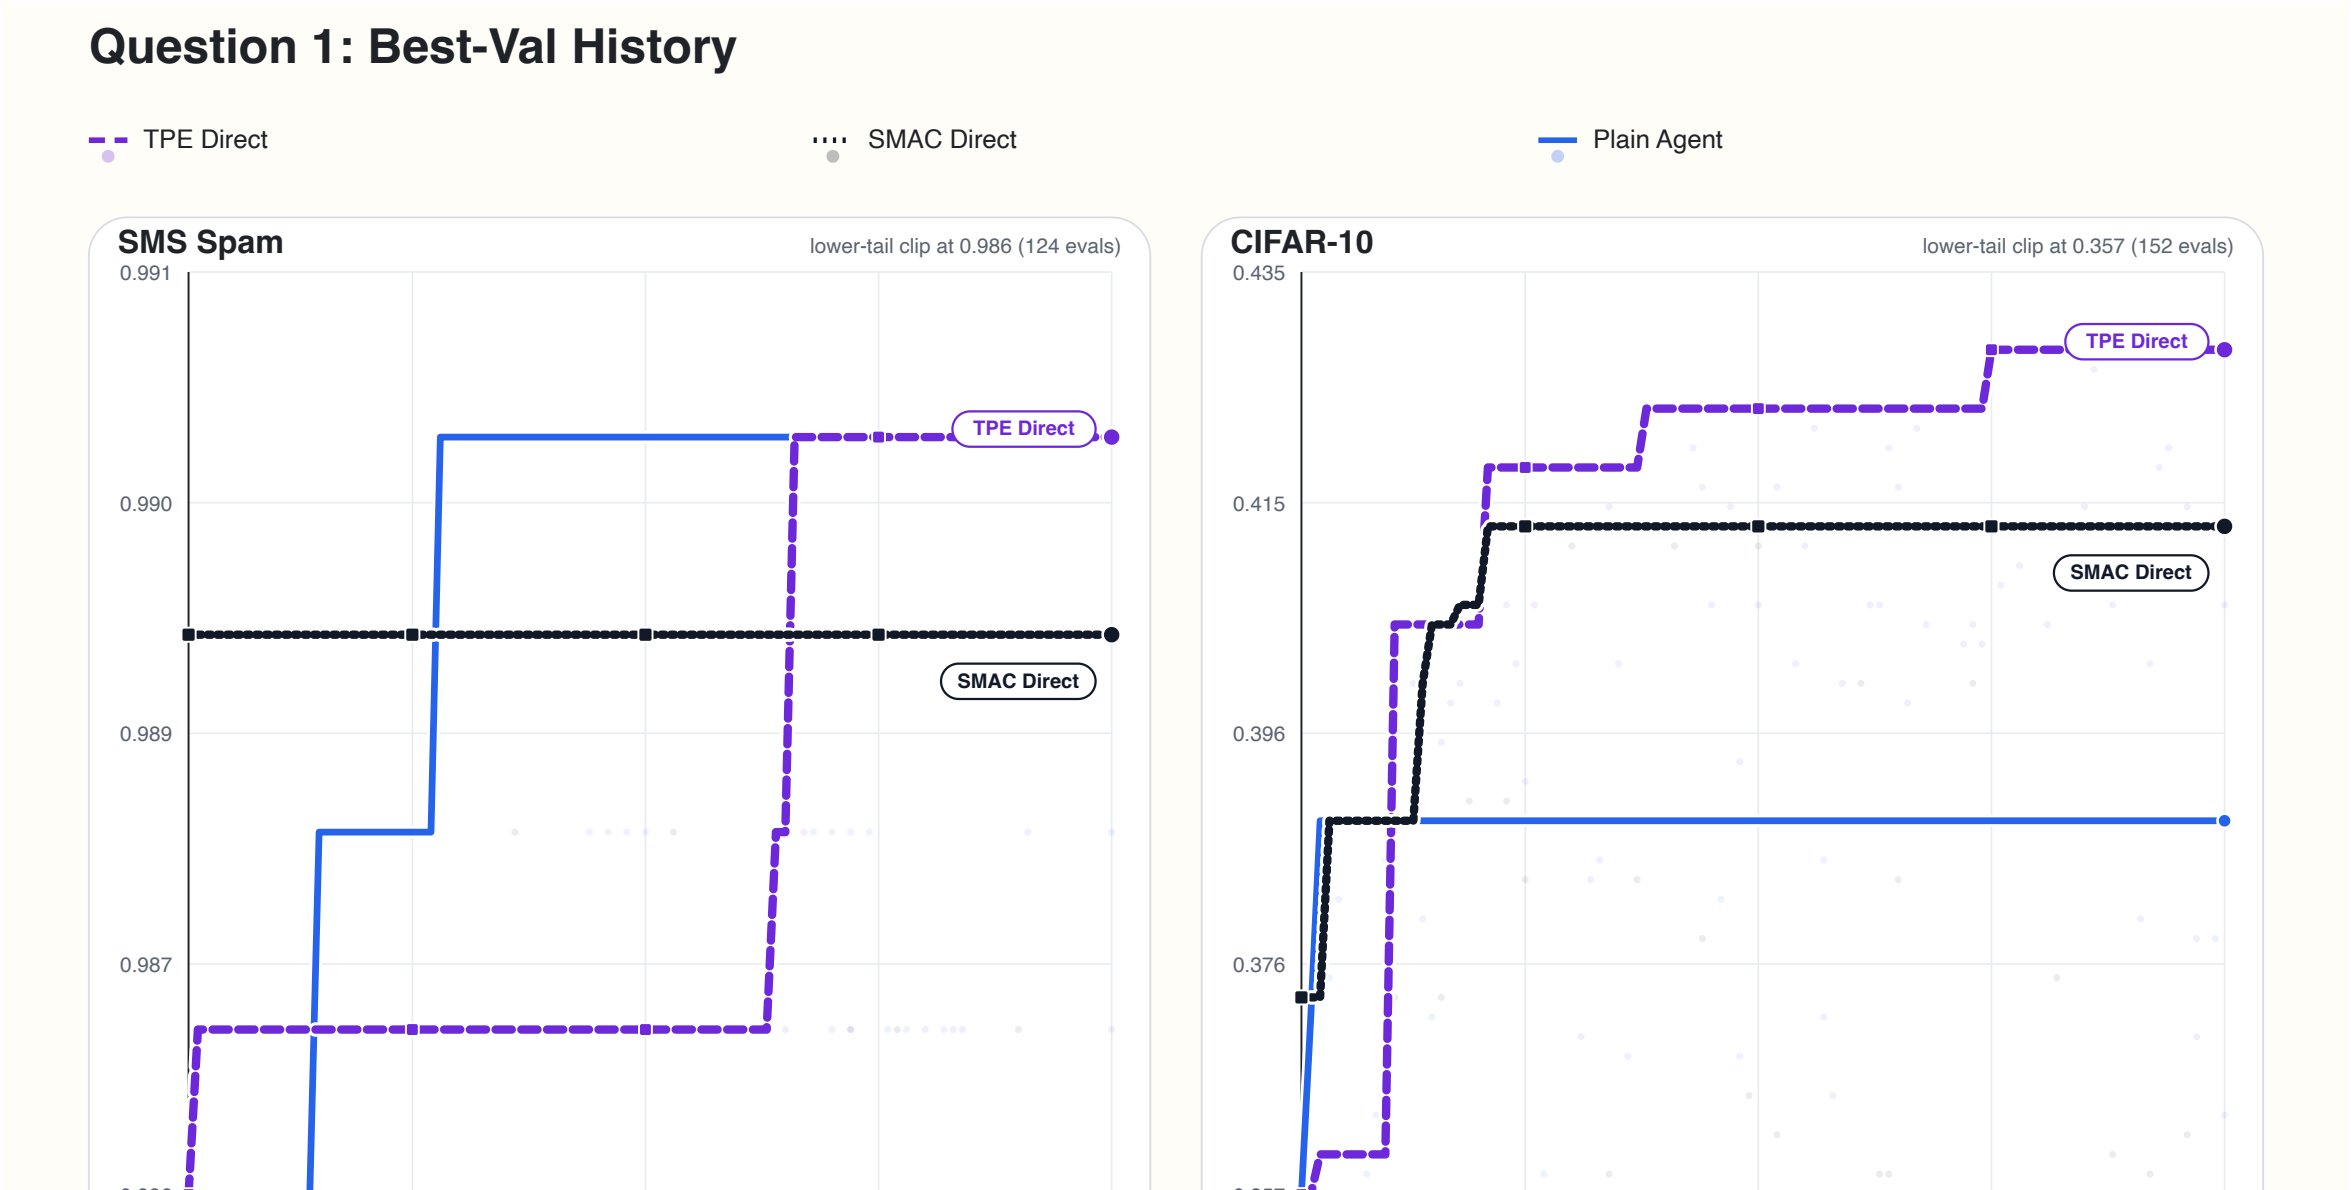
Question 1: Best-Val History
TPE Direct
SMAC Direct
Plain Agent
SMS Spam
lower-tail clip at 0.986 (124 evals)
0.991
0.990
0.989
0.987
TPE Direct
SMAC Direct
CIFAR-10
lower-tail clip at 0.357 (152 evals)
0.435
0.415
0.396
0.376
TPE Direct
SMAC Direct

18. 질문 2 셋업

비교 축

Harness	loop	초점
`Ratchet`	incumbent 중심 exploit	빠른 local climb
`Screening`	factor screening	main effect 분리
`Advanced`	staged DOE	다음 round 설계

실험 환경

- datasets: `fashion`, `twenty`, `spam`, `cifar`
- variants: 각 harness 안에서 `plain`, `TPE`, `SMAC`, `TPE+SMAC`
- readout: `best val`, frontier trajectory

19. 질문 2 요약

Question 2: Harness x Datasets

Comparison Group	Fashion-MNIST	Twenty Newsgroups	SMS Spam	CIFAR-10
Ratchet	0.863	0.566	0.990	0.440
Screening	0.865	0.551	0.992	0.428
Advanced	0.865	0.551	0.990	0.428

- harness 비교도 dataset마다 달랐다. 즉 `무슨 advisor를 붙였나` 만으로는 결과를 설명할 수 없고, `어떤 search loop를 돌렸나` 가 별도 요인이다.

20. Fashion, Twenty

Question 2: Best-Val History

Ratchet Screening Advanced

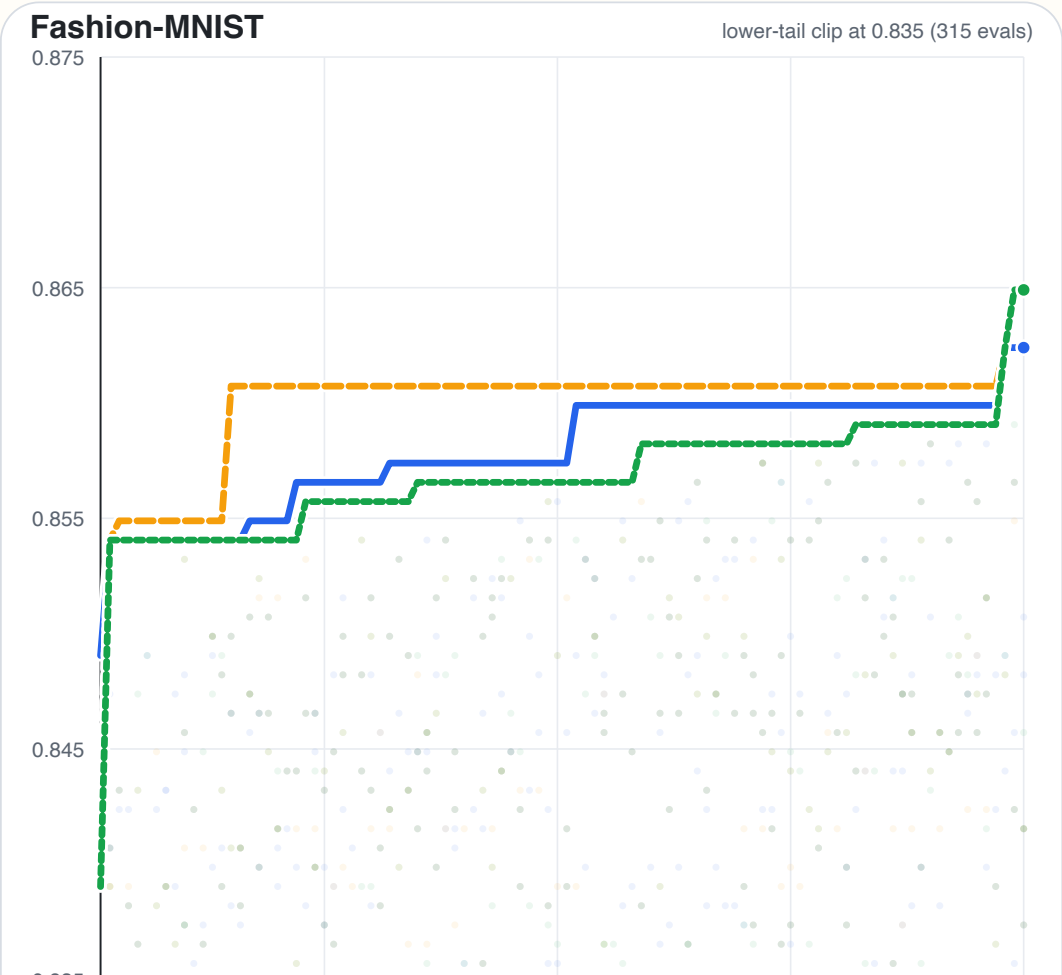

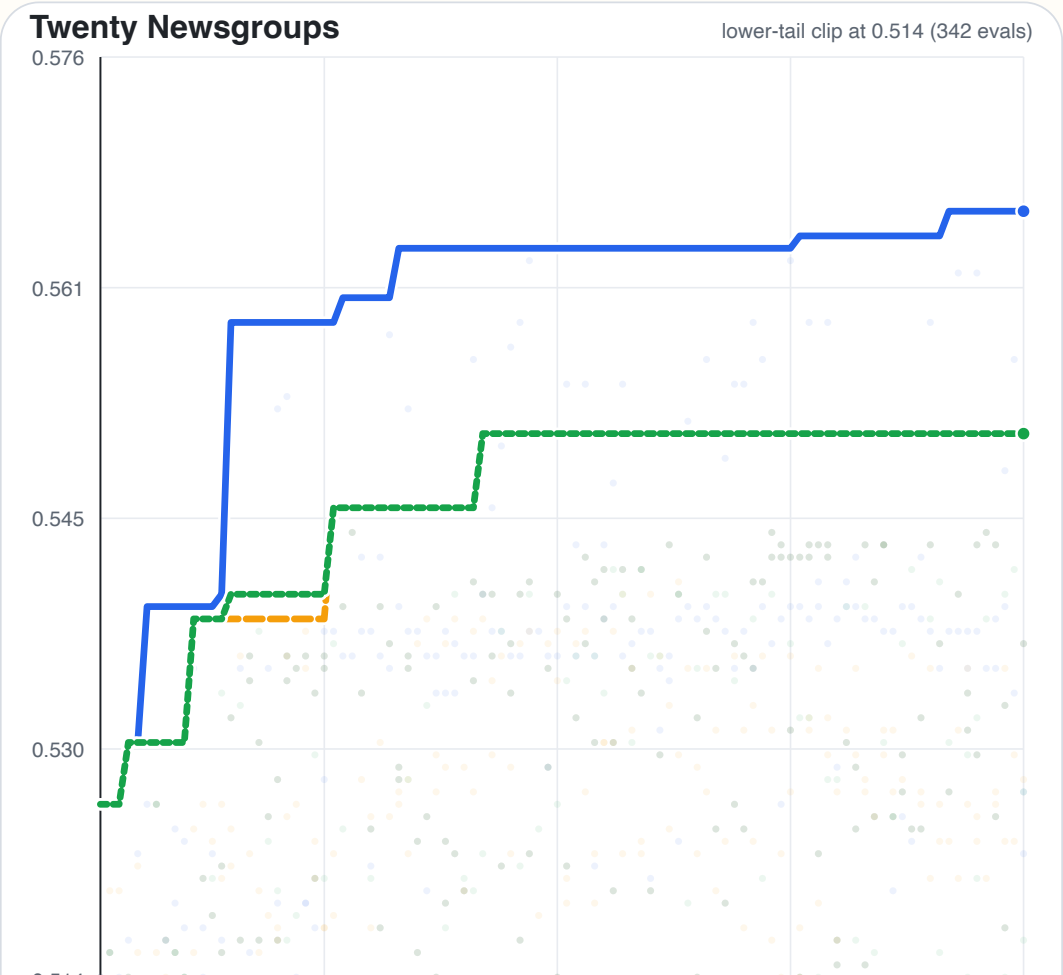

21. Spam, CIFAR

Question 2: Best-Val History

Ratchet Screening Advanced

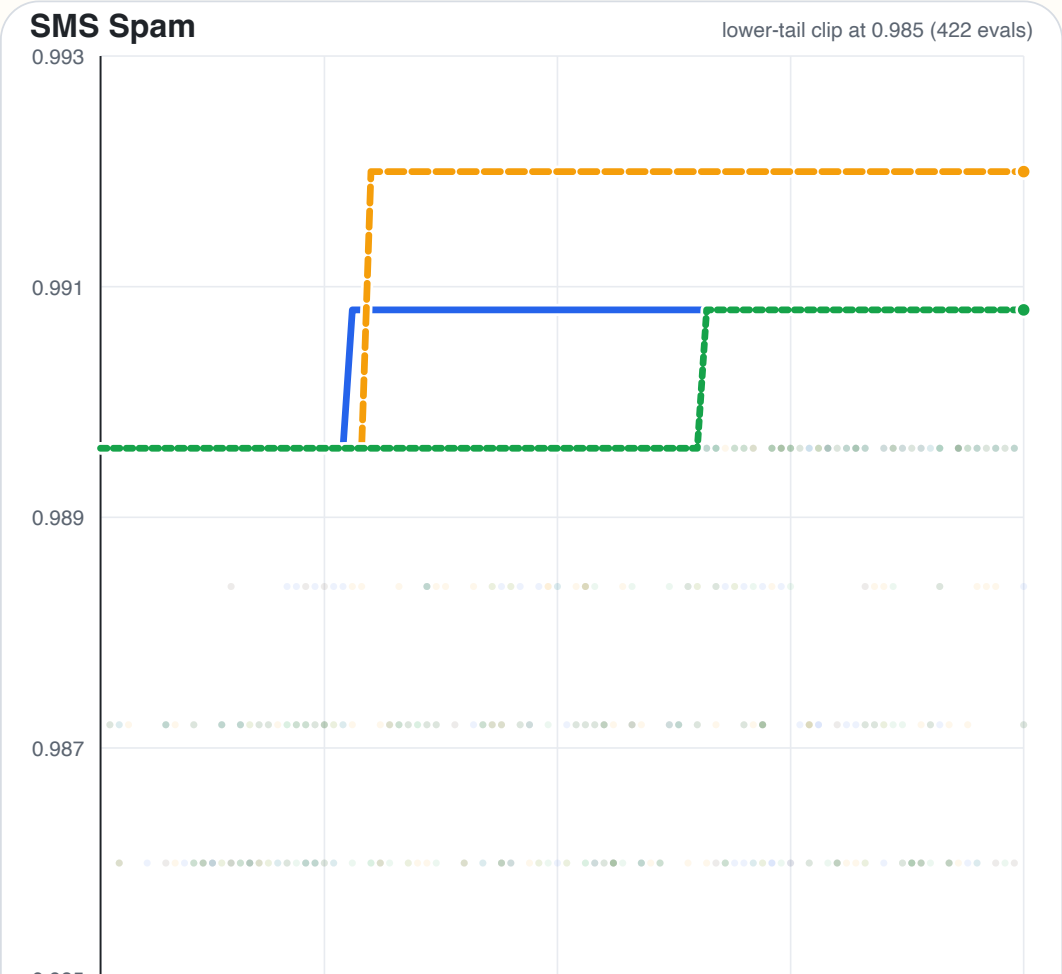

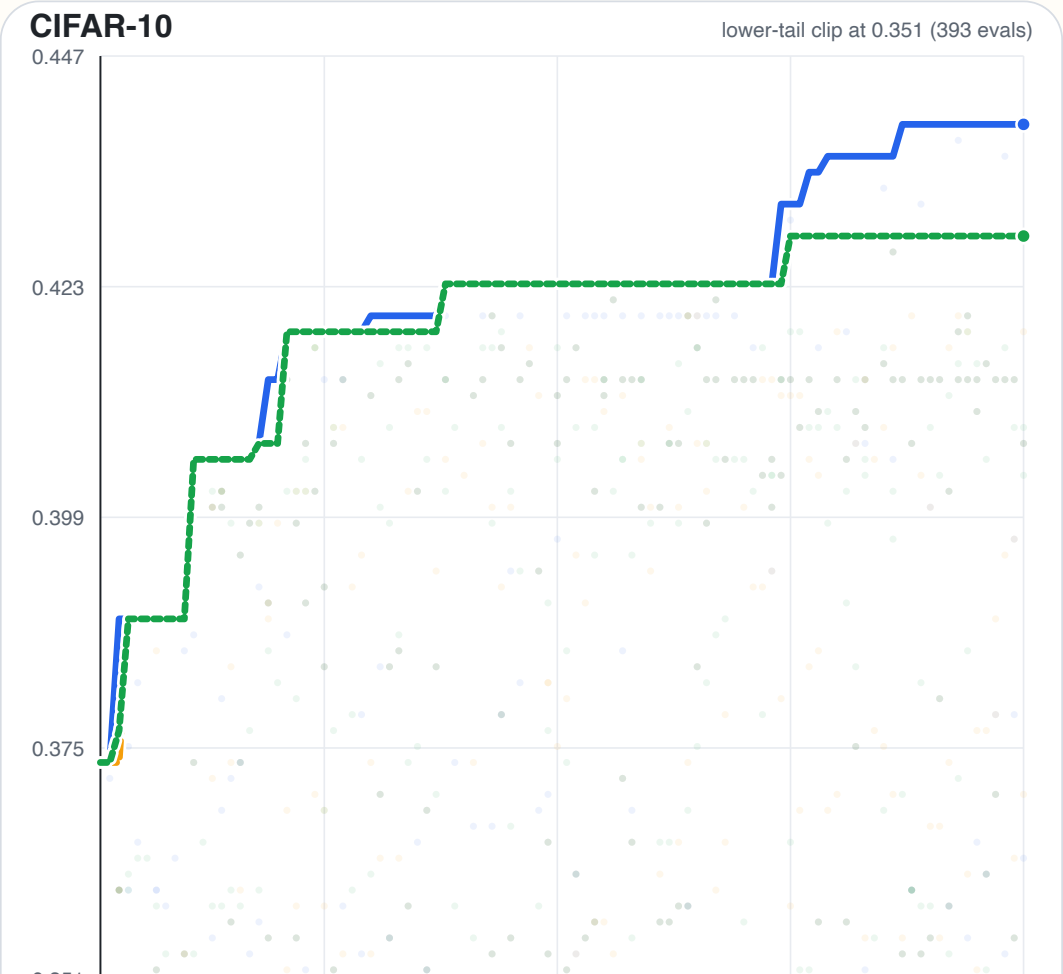

22. 공통 패턴

- winner는 dataset마다 달랐다.
- 같은 top score라도 frontier shape와 late gain 위치는 dataset마다 달랐다.
- hybrid가 ceiling을 높일 때도 있었지만, plain이 finalize를 더 잘하는 경우가 반복됐다.
- direct baseline도 여러 데이터셋에서 top tier에 남아 있었다.

23. 한계

- single split, repeated seed 평균 없음
- model family는 `mlp` 하나만 사용했다
- budget은 condition당 `100 + finalize 1` 로 짧다
- code-edit autoresearch와 open-ended research task는 아직 제외했다

24. References

구분	예시
curated landscape	awesome-autoresearch, Awesome Auto Research Tools
end-to-end systems	karpathy/autoresearch, RD-Agent, AI-Scientist
deep research	GPT Researcher
evaluation	MLE-bench, MLAgentBench, MLR-Bench
optimization baselines	Optuna docs, SMAC3 docs
visuals	AutoML image, NAS image, Kubeflow model registry lifecycle image