AutoML, Autoresearch, MLOps +@

26.4.8

서민교

1. AutoML이란 무엇인가?

- 모델 개발 탐색 일부 자동화
- 대표 대상: `model selection`, `hyperparameter tuning`, `pipeline search`
- 핵심: 비교적 주어진 `search space` 안 최적 설정 탐색

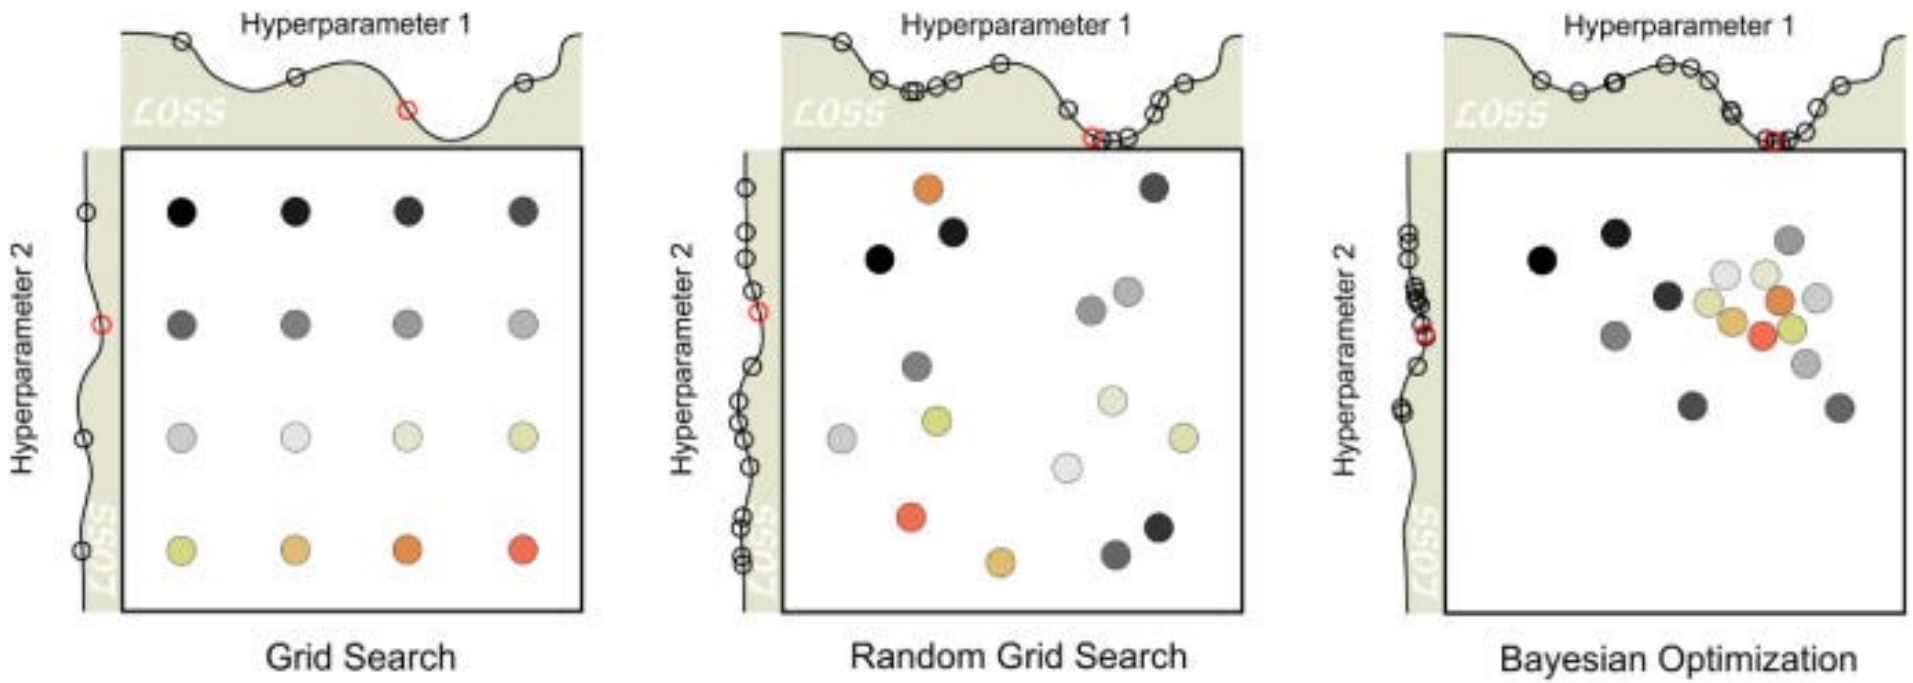

2. `Neural Architecture Search`는 AutoML의 확장이다

- parameter 대신 architecture 탐색
- AutoML의 `더 넓은 search space` 확장선
- 그래도 중심은 여전히 모델/파이프라인 후보 탐색

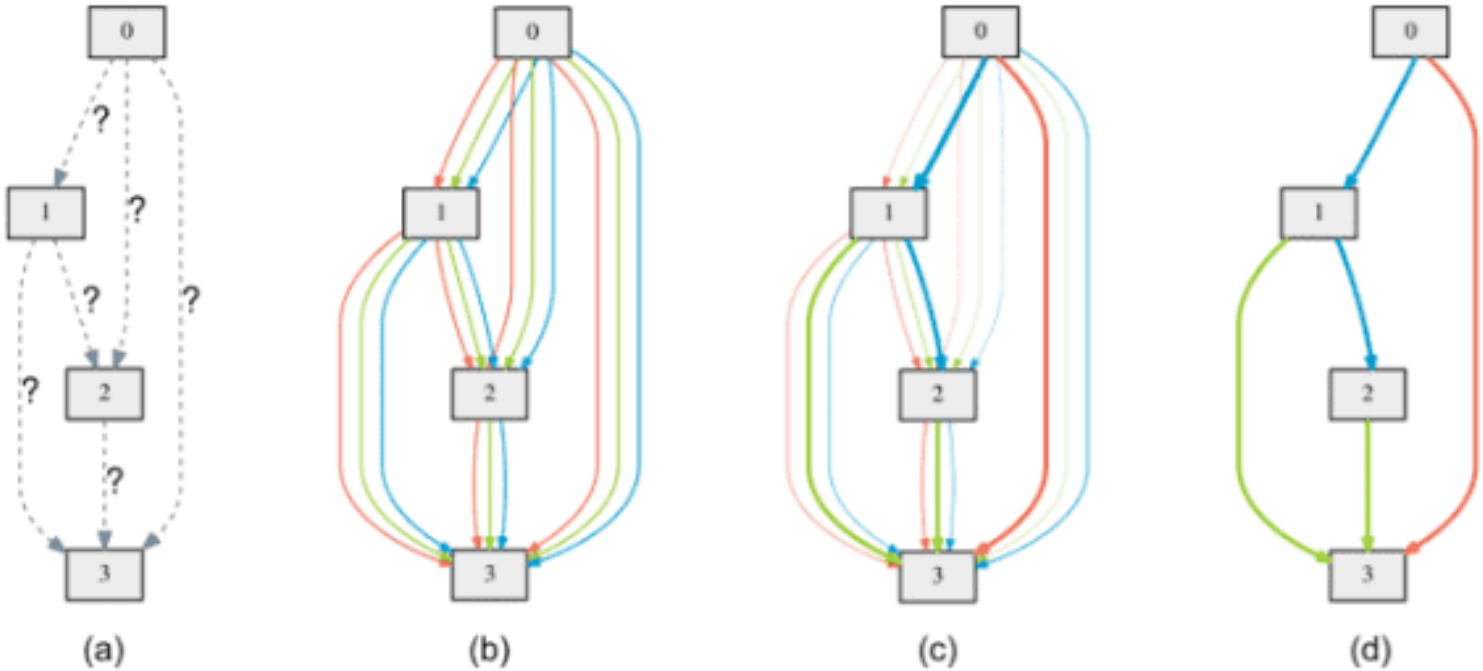

`hyperparameter search → pipeline search → architecture search`

3. `Autoresearch`는 어떻게 등장했고 무엇이 다른가?

- karpathy/autoresearch: 작은 training setup 위 `read → edit → run → keep-or-revert` loop 제시
- 연구 workflow 일부를 agent가 직접 수행하며, 설정 탐색을 넘어 `code`, `module`, `experiment` 자체 수정
- AutoML의 `fixed search space` 바깥으로 확장
- 이후 RD-Agent, AI-Scientist, GPT Researcher 등으로 빠르게 확장

4. Agent 작업 흐름

- 코드 읽기, baseline 파악
- 작은 가설 하나 선택
- 학습 코드나 설정 수정
- 짧은 실험 실행, metric 확인
- 나쁘면 revert, 의미 있으면 keep
- 핵심: `edit 한 번`이 아니라 `짧은 실험 loop의 누적`

```
Question → Read → Edit → Run → Analyze → Next experiment
```

5. AutoML vs. Autoresearch

항목	AutoML	Autoresearch
탐색 대상	config, pipeline, architecture	hypothesis, code, module, experiment
핵심 질문	어떤 설정이 가장 좋은가	다음에 어떤 실험을 해야 하는가
edit 단위	parameter / architecture	code / module / pipeline / experiment
평가 방식	objective 중심	objective + reasoning + iteration
위험	비효율적 탐색	incoherent search, metric hacking
필요한 인프라	experiment infra	experiment + memory + harness

6. 사용례와 확장

사용례

- 문헌 조사 / deep research: GPT Researcher
- 코드 수정 + 실험 반복: karpathy/autoresearch, RD-Agent
- end-to-end 연구 자동화: AI-Scientist

확장

- benchmark / evaluation: MLE-bench, MLAgentBench, MLR-Bench
- plugin / skill 생태계: awesome-autoresearch, Awesome Auto Research Tools
- memory, reusable modules, hardware fork

7. 체계적인 실험 관리의 필요

- 공통 문제: `많은 run` 비교와 누적
- 필수 요소: `tracking`, `lineage`, `orchestration`
- agent edit가 들어오면 `artifact`, `promotion`, `monitoring`, `cost control` 중요도 상승
- 결국 운영 문제

8. AutoML과 Autoresearch가 공통으로 요구하는 MLOps 요소

요소	AutoML에서의 역할	Autoresearch에서의 역할
tracking	sweep 비교	hypothesis / code edit history 비교
orchestration	search job 실행	agent + eval job 실행
registry / lineage	best model 승격	experiment / prompt / code provenance 보존
monitoring / cost	retrain trigger, SLO	budget, drift, unsafe promotion guardrail

9. MLOps는 모델 개발, 관리, 배포 파이프라인을 유지 관리하는 작업이다

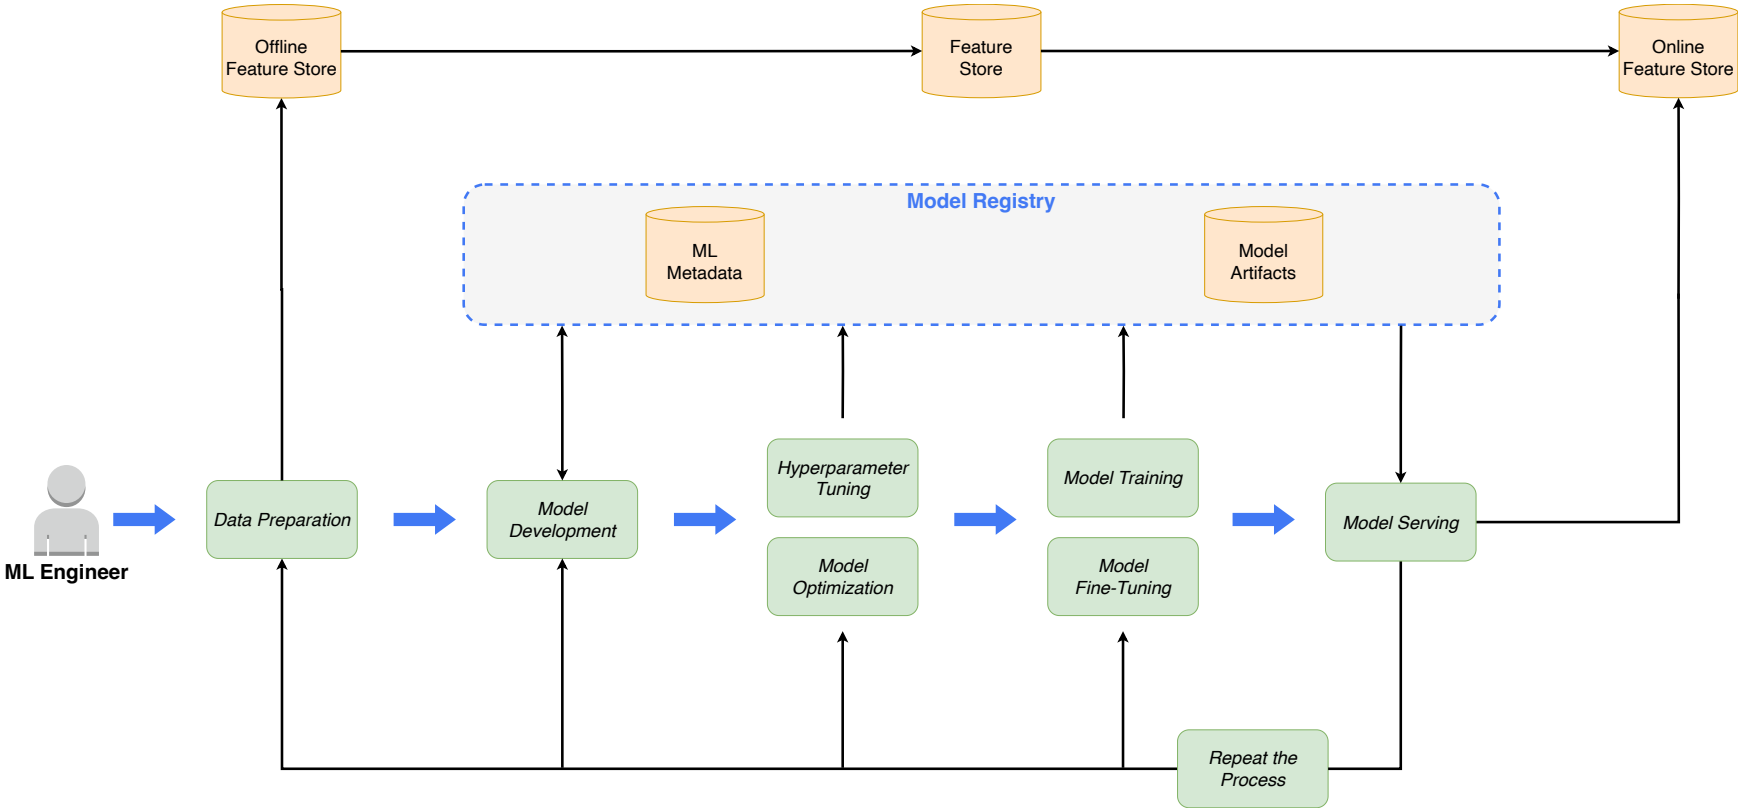

- Autoresearch loop는 이 큰 ML lifecycle 안의 일부
- 실제 시스템: `data`, `experiment`, `model registry`, `deployment`, `monitoring`
- 핵심 역할: `지속 운영`, `추적`, `승격`, `유지관리`

10. 오늘의 큰 질문 두 가지

1. `Autoresearch`는 기존 `AutoML` 도메인을 AutoML 기법들에 비해 잘 푸는가?
2. `Autoresearch`에 어떤 harness를 적용하는 게 좋은가?

- 질문 1은 `capability comparison`
- 질문 2는 `operating policy / harness design`
- 오늘 발표는 이 두 질문을 분리해서 본다.

11. 질문 1: 비교 기준으로 왜 `Optuna TPE`를 보나

- `Optuna`의 `TPESampler`는 대표적인 hyperparameter optimization baseline이다.
- 좋은 trial 집합과 나머지 trial 집합의 density를 따로 모델링하고, 그 비율이 큰 쪽을 우선 제안한다.
- bounded search space에서 강한 incumbent exploitation을 보여 주기 쉽다.
- 따라서 같은 AutoML search space에서 `Autoresearch`가 이 baseline보다 더 잘 푸는지가 첫 질문이다.

12. 질문 1: 비교 기준으로 왜 `SMAC3`를 보나

- `SMAC3`는 algorithm configuration과 hyperparameter optimization을 위한 대표적 Bayesian optimization baseline이다.
- surrogate model과 aggressive racing을 결합해 유망한 configuration에 평가 예산을 집중한다.
- mixed, categorical, conditional search space에서 자주 쓰이는 강한 비교 기준이다.
- 따라서 `Autoresearch`가 local search를 넘어선다면 이 baseline 대비 장점이 드러나야 한다.

13. 질문 1 실험 결과

TBD

- 현재 `Autoresearch`, `Optuna TPE`, `SMAC3` 비교 실험 진행 중
- 같은 bounded search space, 같은 benchmark, 같은 budget 기준으로 정리 예정

14. 질문 2: `Autoresearch`에 어떤 Harness를 적용할까?

- 질문 1이 `누가 더 잘 푸는가`라면, 질문 2는 `agent를 어떻게 운영해야 하는가`다.
- 여기부터는 `Autoresearch` 내부 운영 정책과 harness 설계를 본다.
- 아래 실험은 `DoE-guided harness`가 agent loop를 더 구조화할 수 있는지에 대한 답이다.

15. 왜 Harness 질문이 생기나

- 실험이 즉흥적으로 이어지기 쉬움
- 왜 이 실험을 했는지 attribution이 약함
- 큰 수정, 작은 튜닝, 검증 실험이 섞이기 쉬움
- robustness, replication, interaction 확인이 뒤로 밀림
- 잘 정리된 random search로 퇴화할 위험

16. 어떤 Harness가 필요한가

- 무엇을 먼저 볼지 정하는 우선순위
- 어떤 조합을 함께 볼지 정하는 규율
- 탐색 단계와 검증 단계 분리
- 작은 수정과 큰 수정을 다르게 다루는 운영 규칙
- 실패도 정보로 남기는 구조
- 다음 라운드를 설계하는 순차 실험 체계

17. Design of Experiments(DoE)란 무엇인가

- 여러 요인을 한 번에 바꿔 보며 effect를 읽는 실험 설계
- 한 번의 최고점보다 `요인`, `상호작용`, `안정성` 파악에 강점
- 핵심 질문: 무엇을 바꿨고, 무엇이 실제로 영향을 줬는가

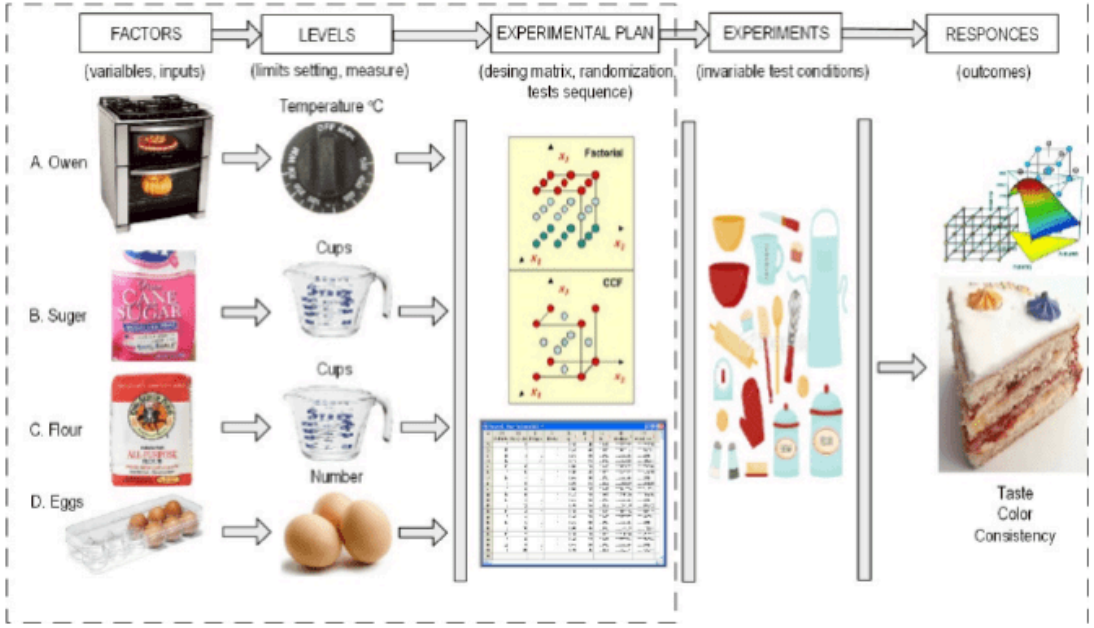

18. DoE에서 빌려오는 개념

- `screening` : 중요한 요인부터 좁히기
- `factorial thinking` : interaction 보기
- `sequential design` : 라운드별 정교화
- `robust design` : 평균이 아니라 안정성까지 확인
- `mixture / allocation` : 예산과 비율 배분

19. DoE-guided 운영과 비교한 Agents

Agent	운영 방식	특징
`01 Ratchet`	local ratchet loop	incumbent를 branch head로 두고 좁게 mutation
`02 Screening DoE`	simple screening	round마다 한 design question만 분리해 main effect를 읽음
`03 Advanced DoE`	staged DoE program	screening → interaction check → local refinement

20. 실험 설정

항목	설정
benchmark	`cifar10_real`
model	`mlp`
agent profiles	`Ratchet`, `Screening DoE`, `Advanced DoE`
advisor modes	`plain`, `TPE`, `SMAC`, `TPE+SMAC`, `TPE direct`, `SMAC direct`
isolated conditions	`14`
execution	root당 validation-history `100` runs + hidden finalize `1` 회

실행 메모

- 각 condition은 subagent로 별도 root에서 독립 실행
- 최종 검산: finalized manifest `14`, run artifact `100 x 14`
- 이번 비교는 code-edit autoresearch가 아니라 bounded `AutoML + advisory harness` 비교다

탐색 축

- preprocessing: `normalization`, `outlier`, `projection`, `resampling`
- architecture: `hidden_dims`, `activation`, `normalization_layer`
- optimization: `solver`, `learning_rate`, `batch_size`, `max_iter`

21. 최종 요약: validation 1등과 hidden 1등은 달랐다

관점	조건	Best Val	Hidden Test
validation 최고	`screening_plain`	`0.4433`	`0.3700`
hidden test 최고	`ratchet_smac`	`0.4017`	`0.4100`
plain 조건 최고 hidden	`ratchet_plain`	`0.4350`	`0.3883`
direct 조건 최고	`tpe_direct`	`0.4383`	`0.3733`
dual-advisor 최고	`screening_tpe_smac`	`0.4200`	`0.3867`

- `TPE` 는 validation ceiling을 자주 올렸지만 hidden winner는 `SMAC` 쪽에서 나왔다.
- 이번 budget `100` 에선 `TPE+SMAC` 조합이 단일 advisor를 안정적으로 이기지 못했다.
- 아래 히스토리 plot은 가독성을 위해 `profile별 3개` 와 `advisor mode별 3개` 로 나눴다.

22. Ratchet 계열 비교

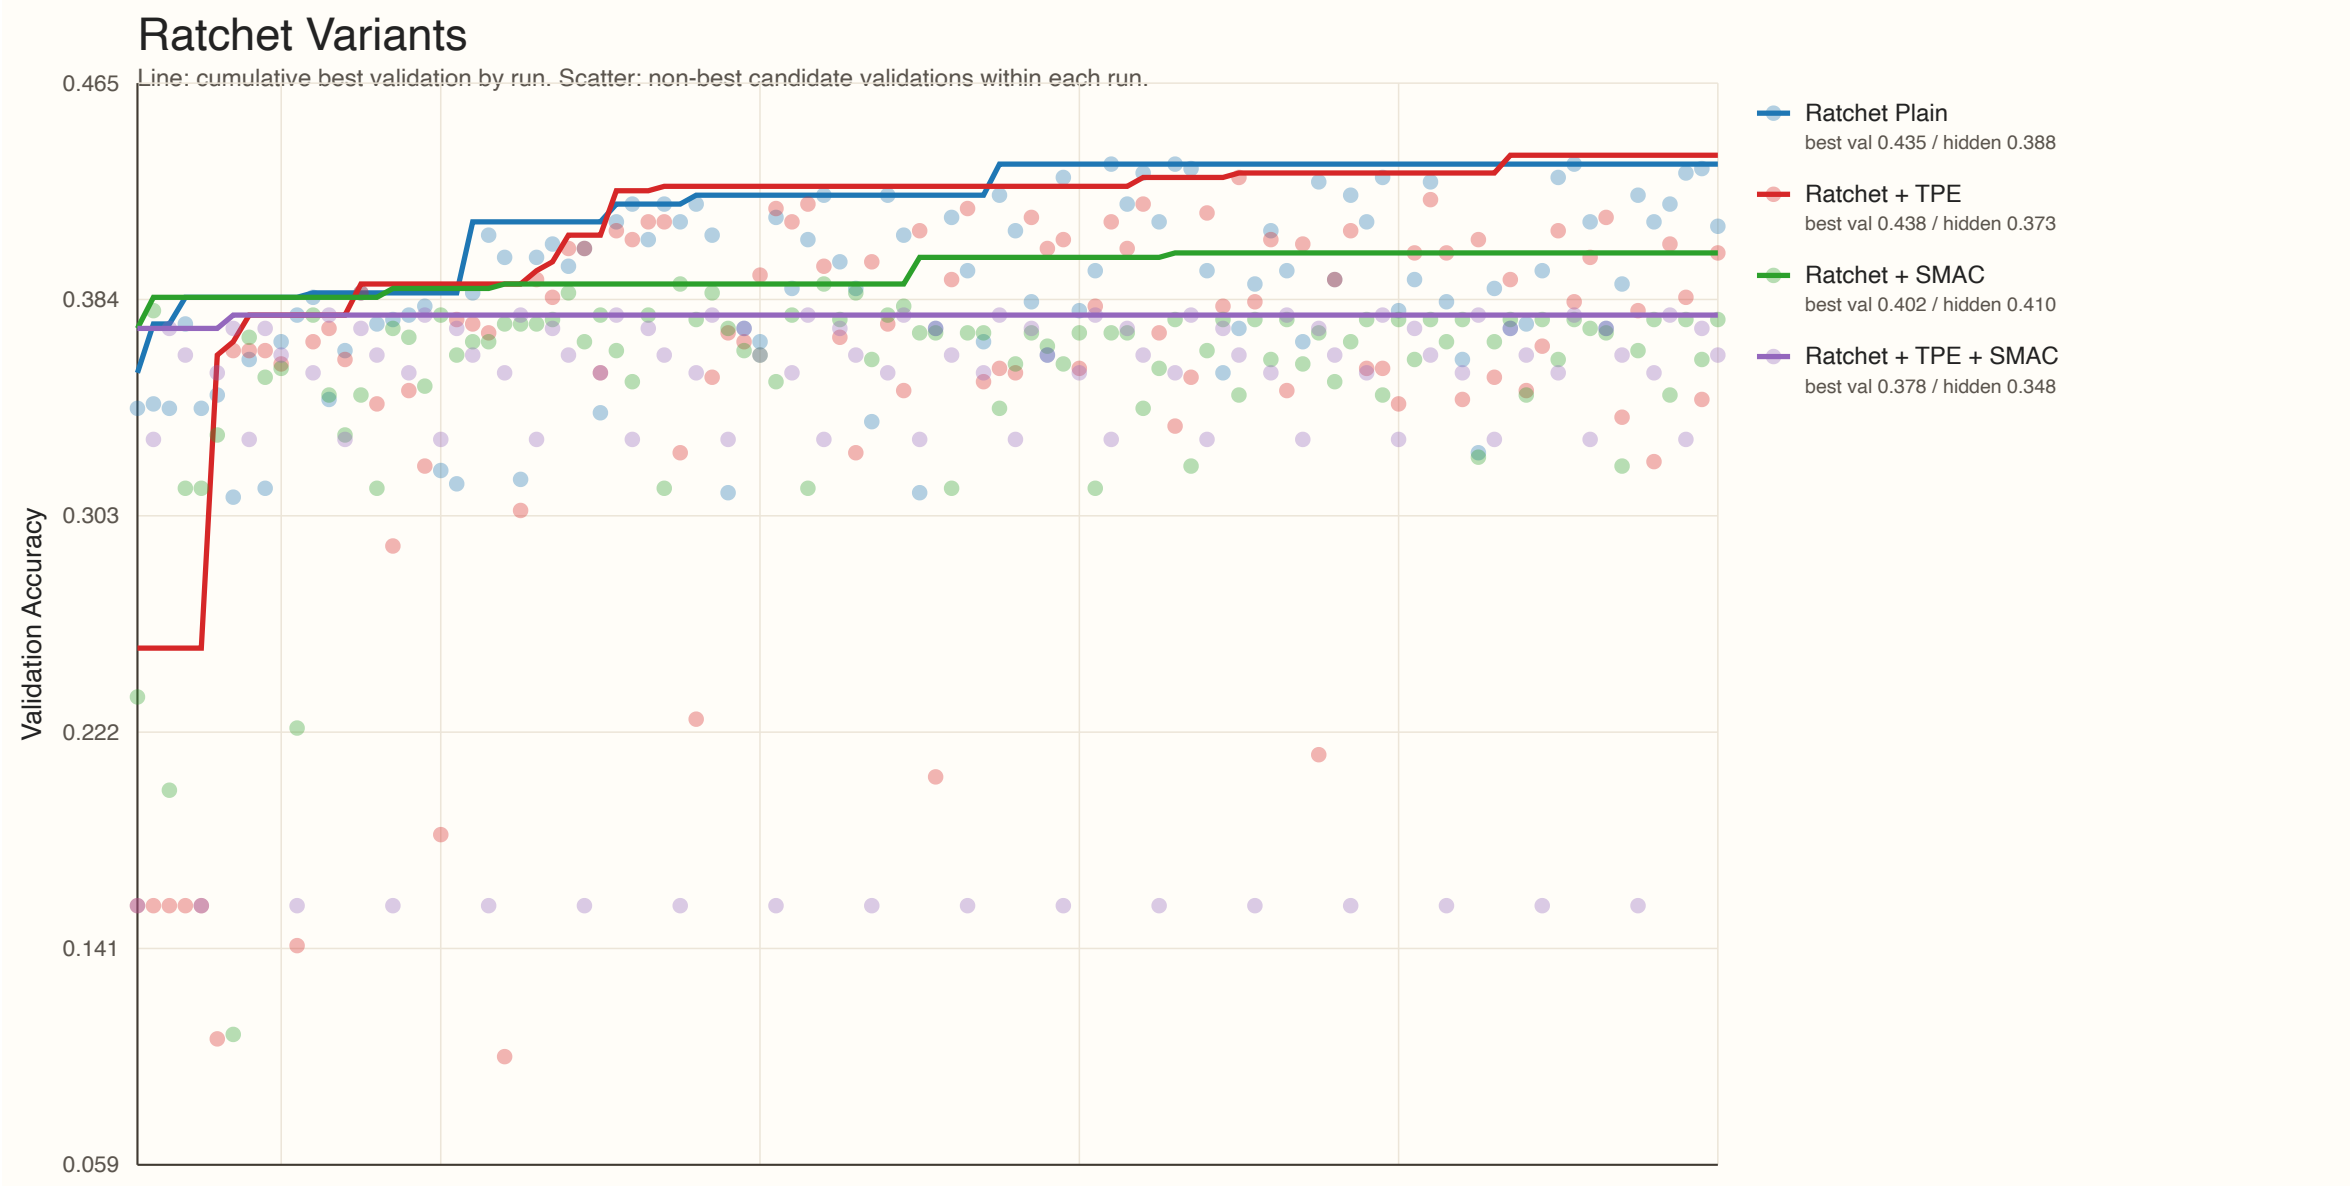

23. Screening 계열 비교

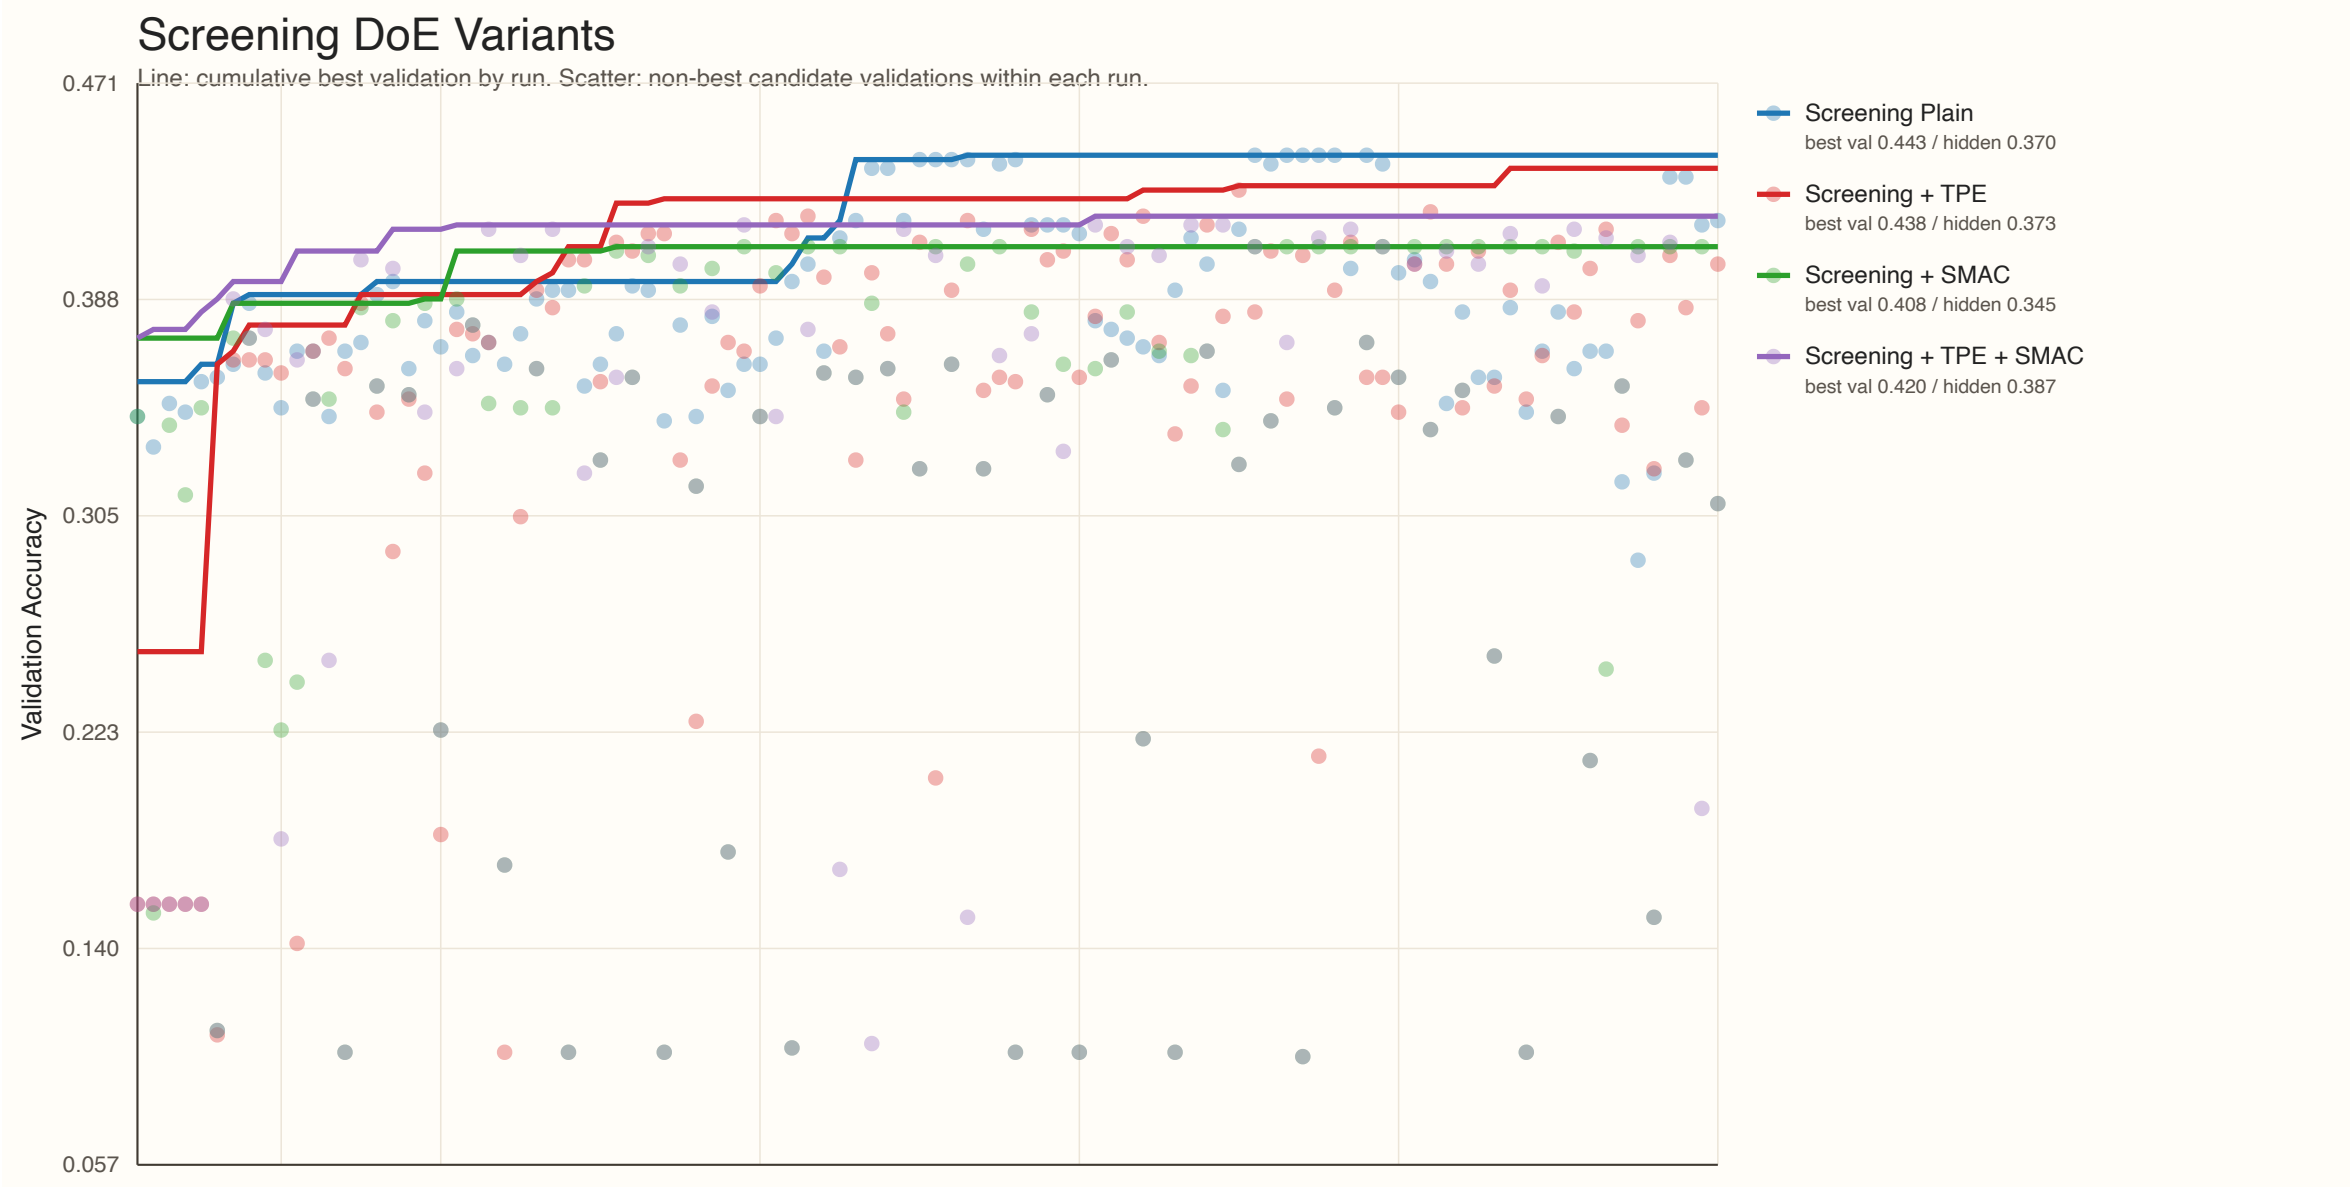

24. Advanced 계열 비교

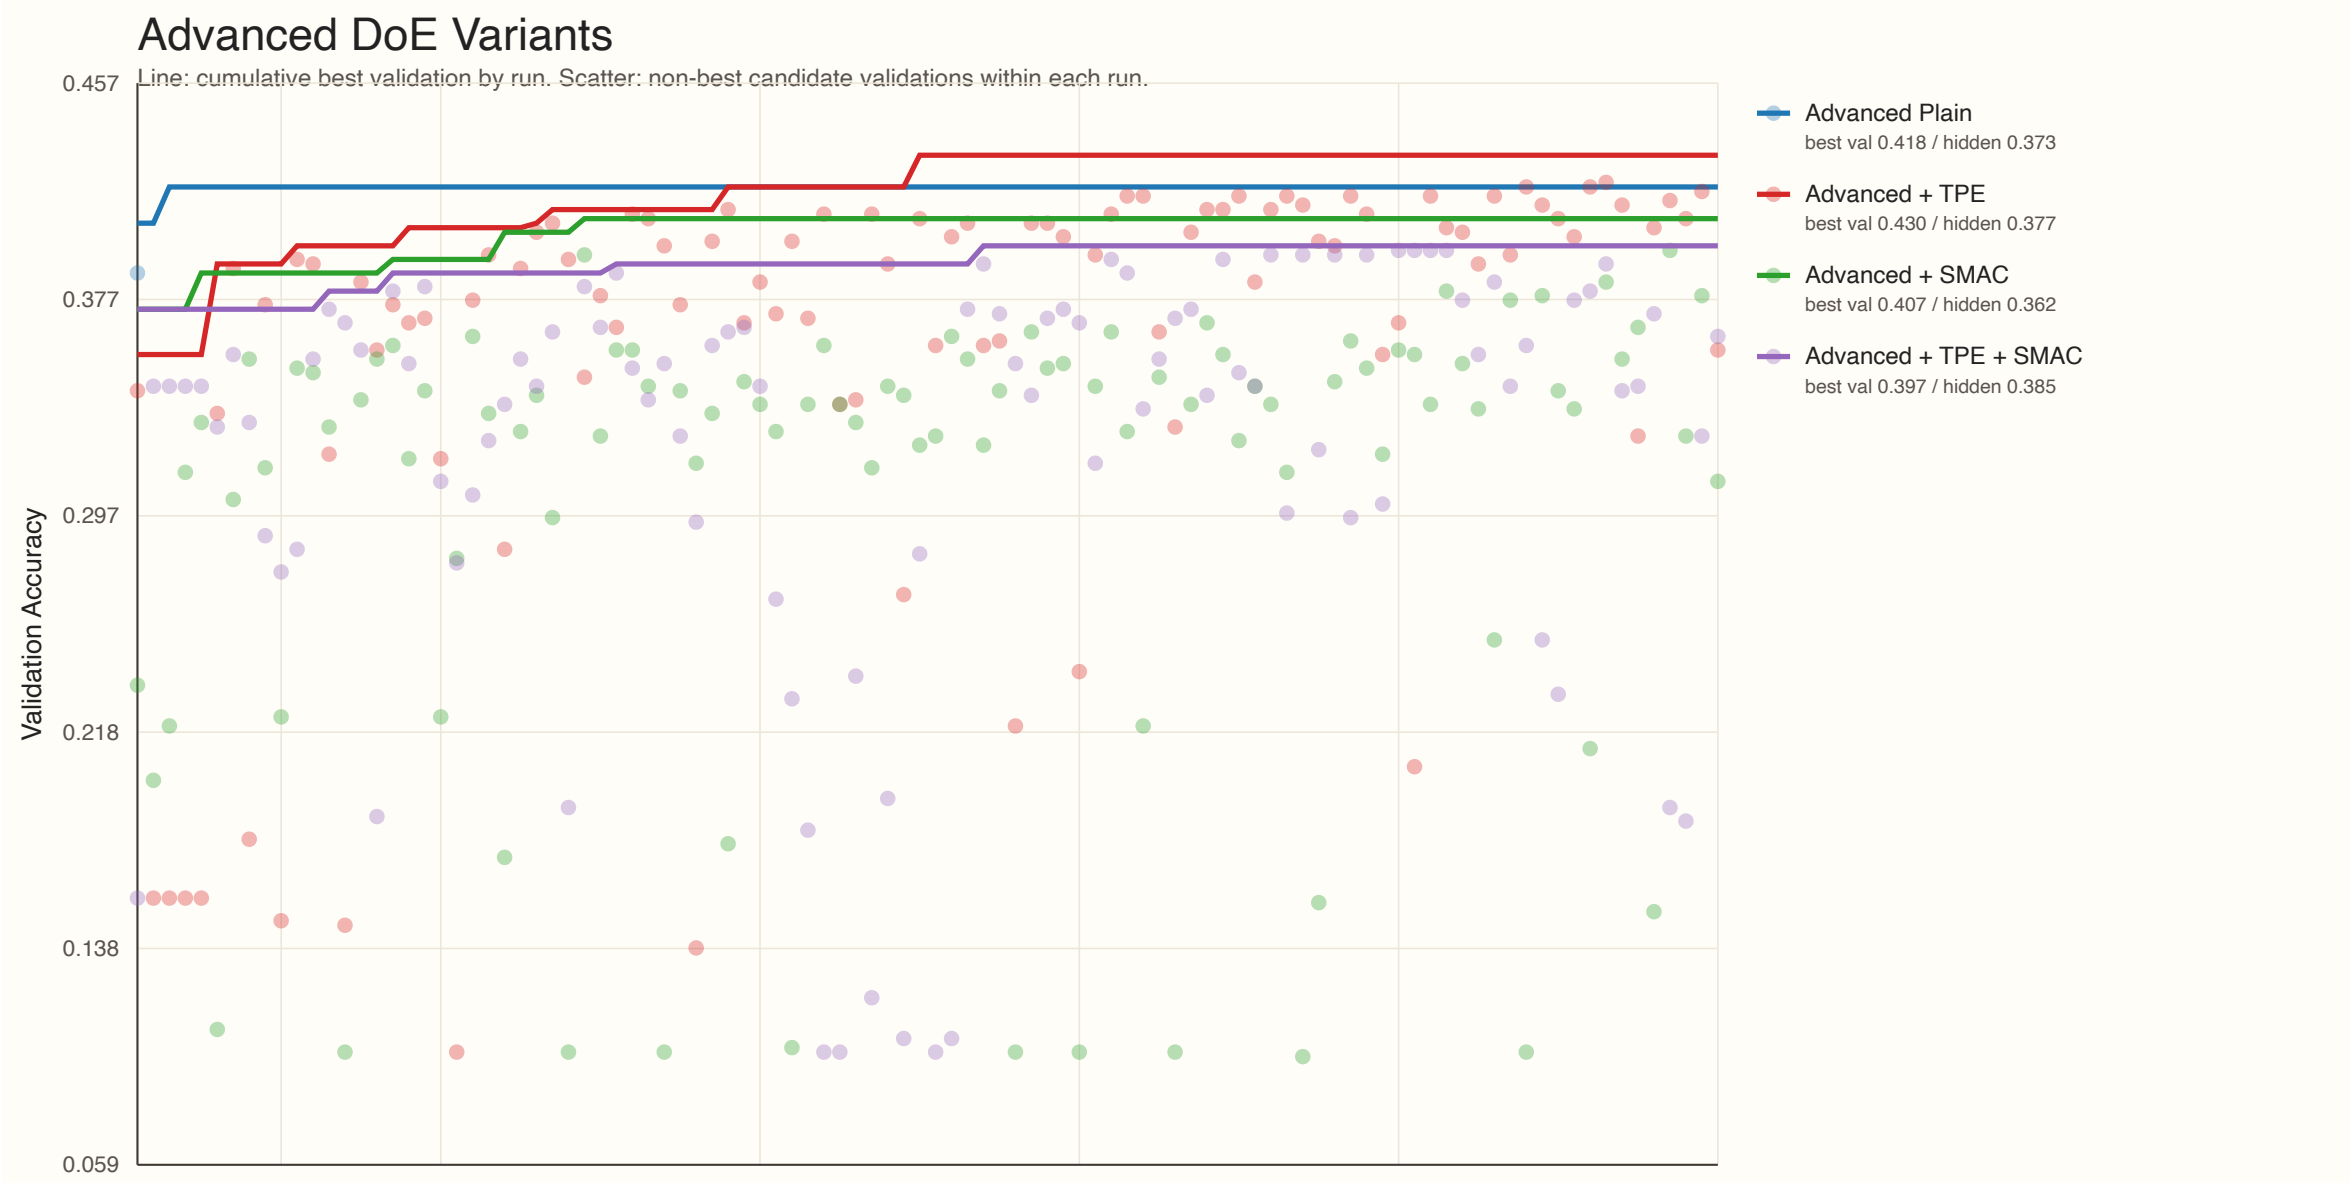

25. Plain agent간 비교

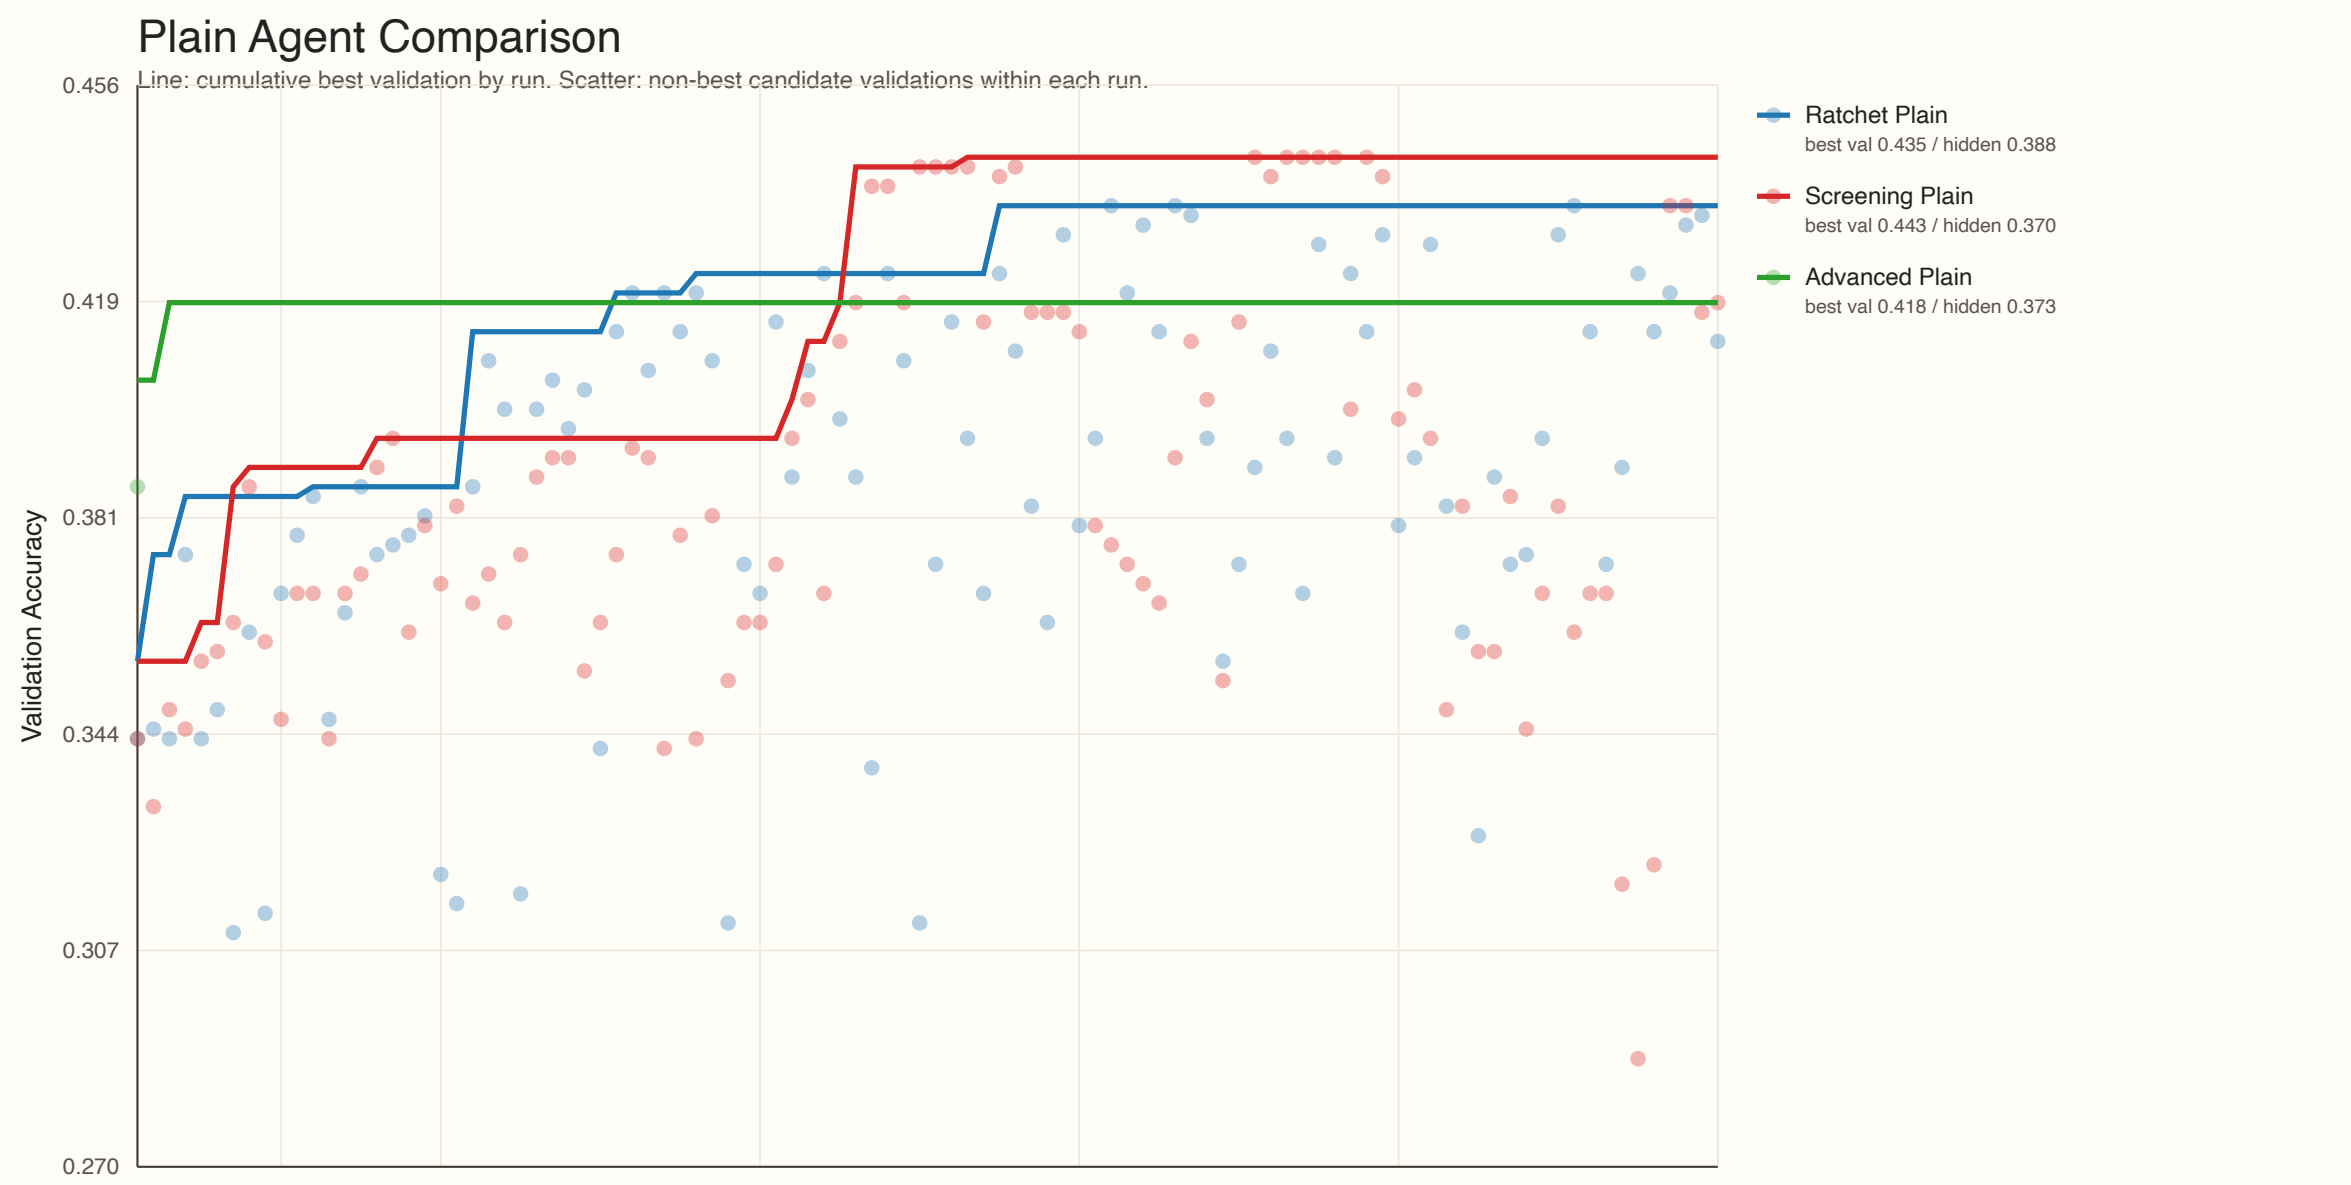

26. TPE agent간 비교

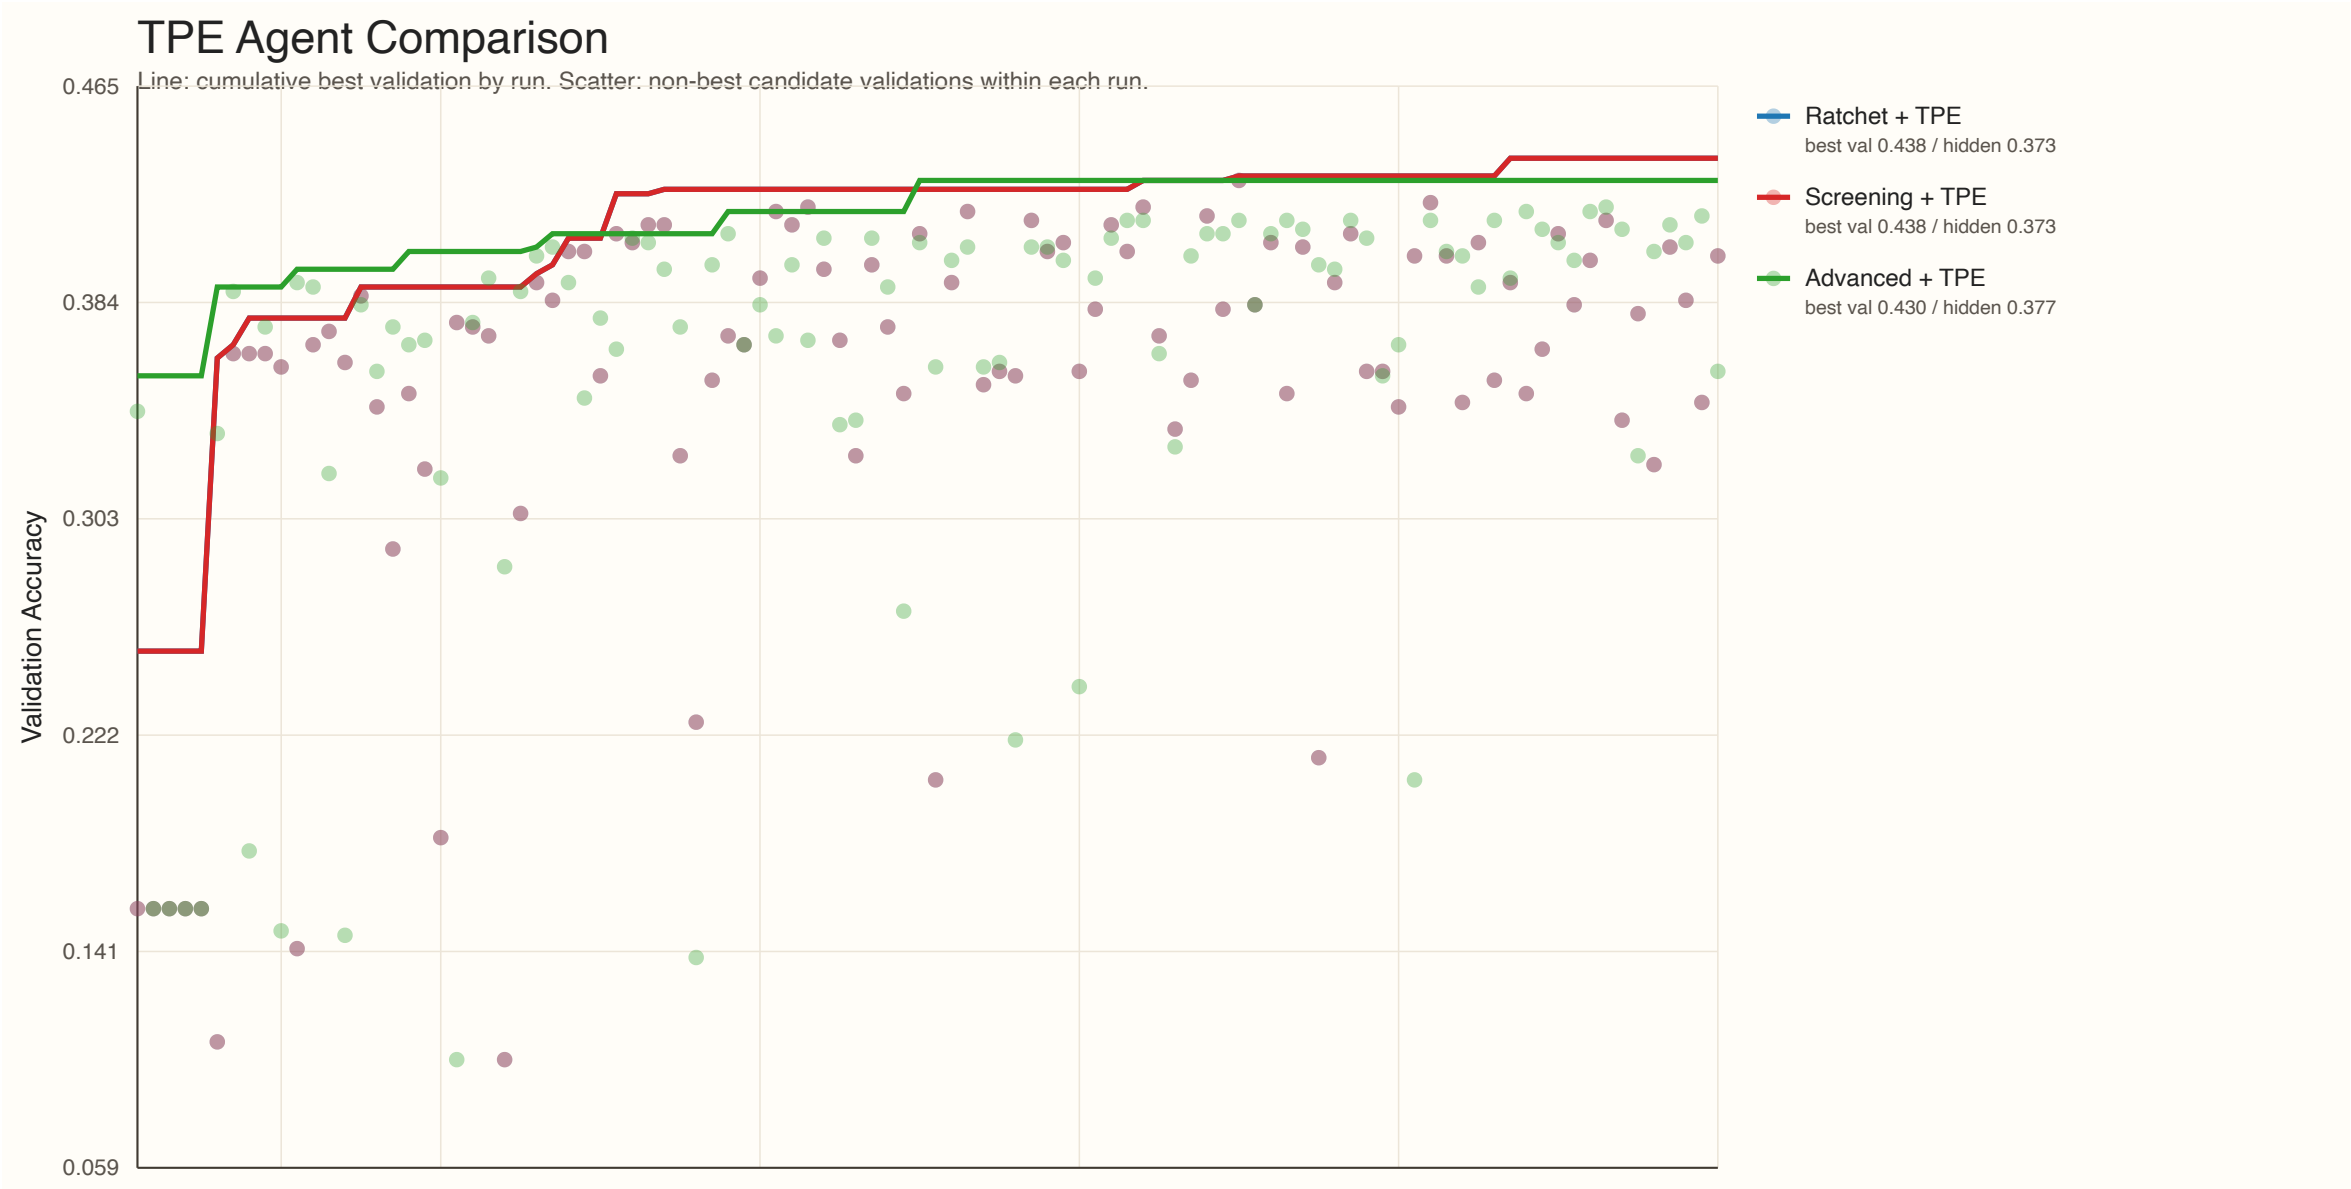

27. SMAC agent간 비교

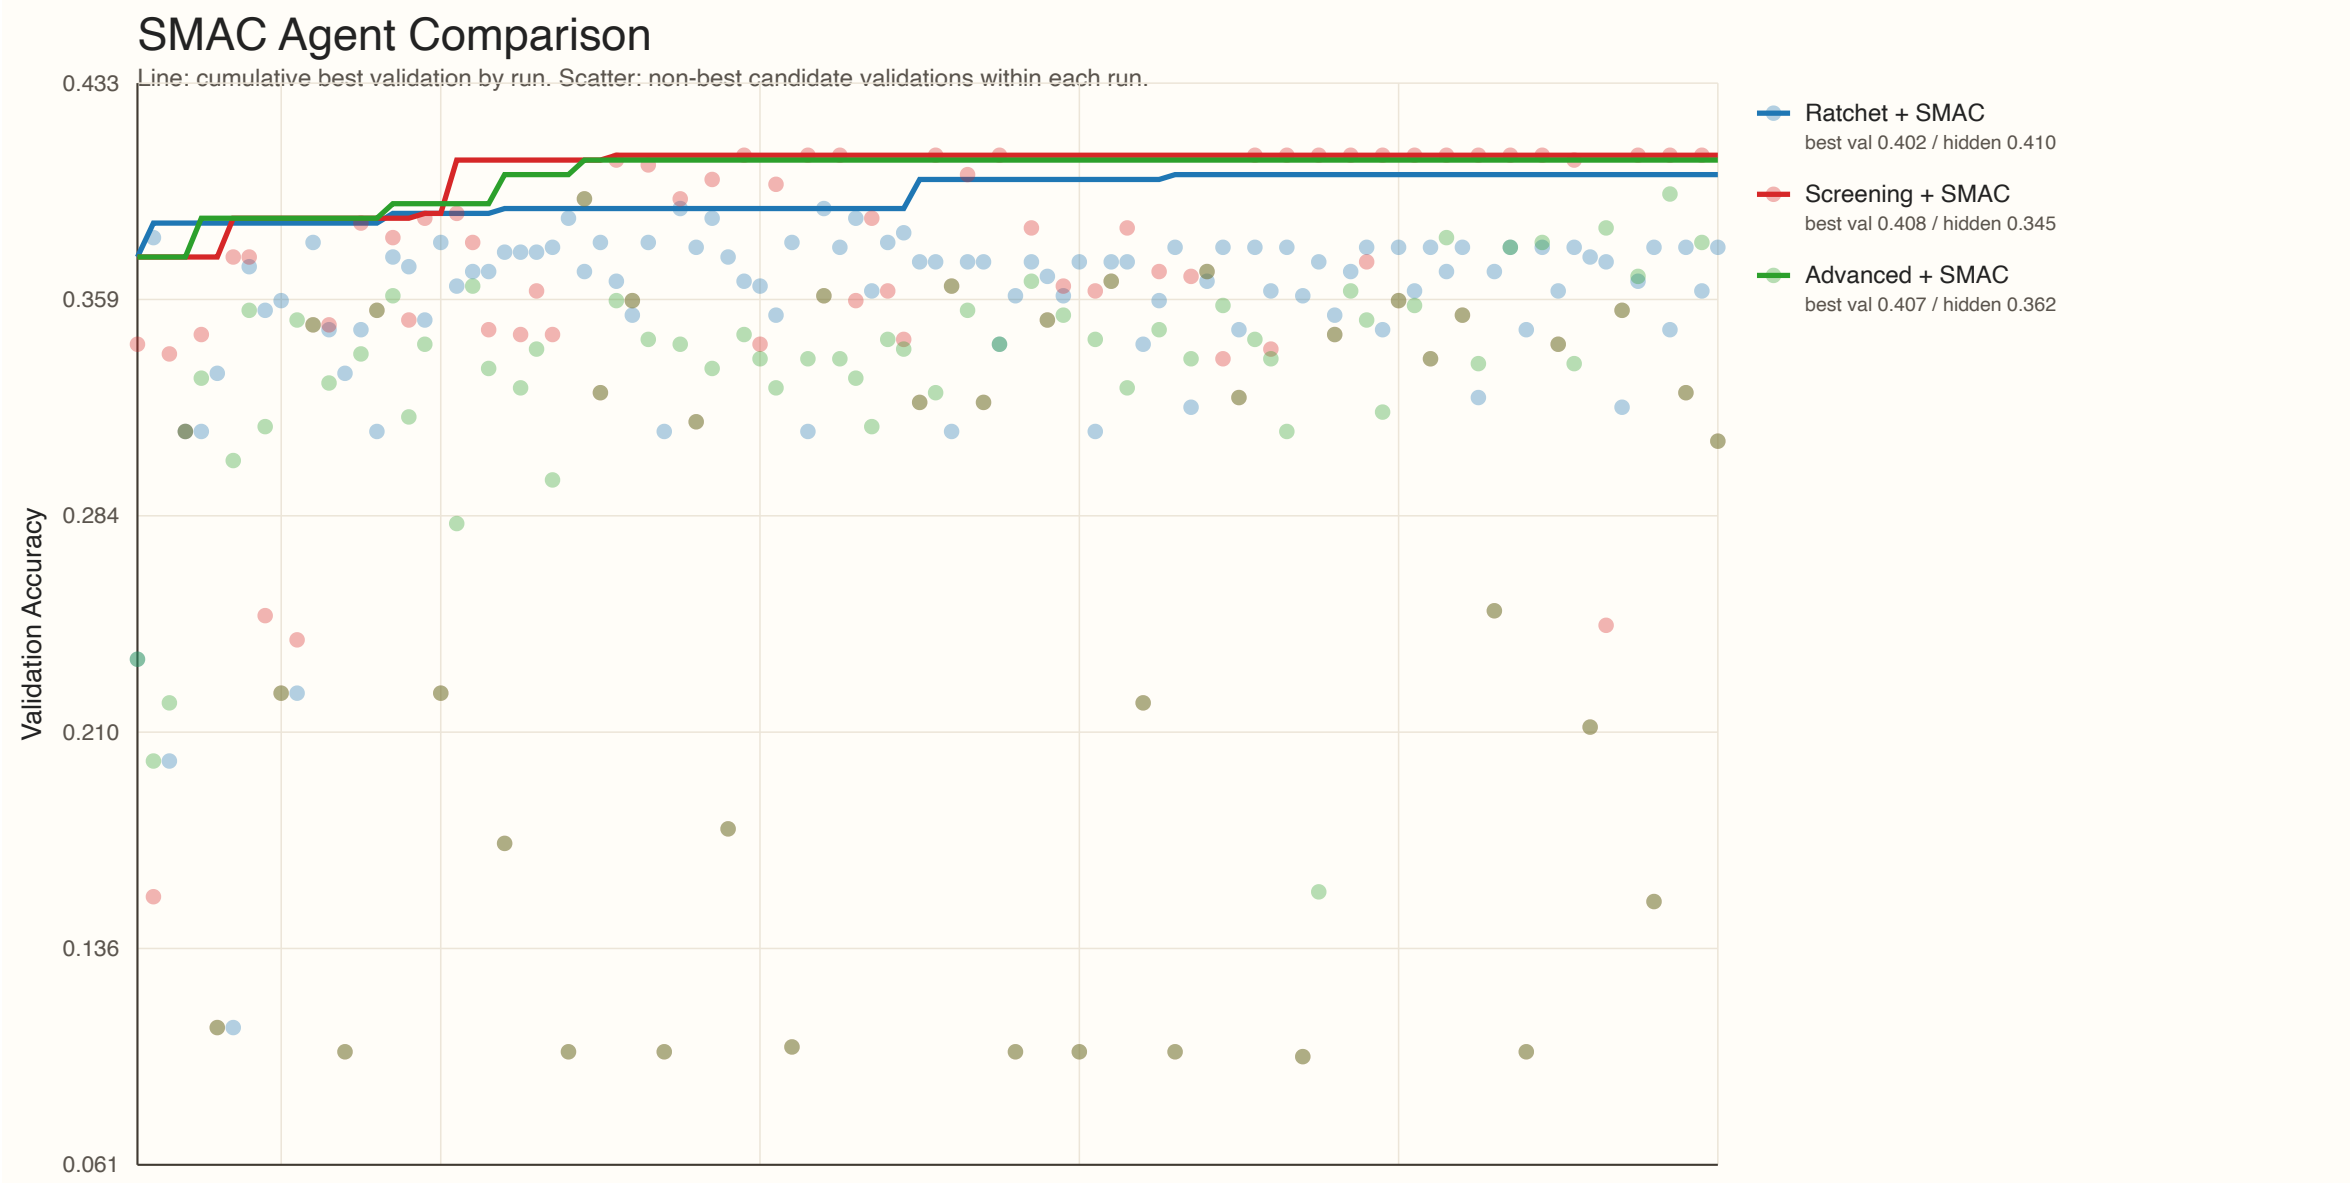

28. 이번 batch에서 읽을 점

- `profile별 3개` 는 advisor가 같은 agent 안에서 무엇을 바꾸는지 보여준다.
- `mode별 3개` 는 같은 advisor 아래에서 agent policy 차이를 보여준다.
- `dual-advisor` 는 per-profile plot에만 남겼다. cross-agent까지 겹치면 비교 이득보다 시각적 잡음이 커진다.
- 핵심 mismatch는 유지된다: validation 최고는 `screening_plain`, hidden 최고는 `ratchet_smac`.

29. Harness 관점에서 남는 교훈

- `best val`, `hidden finalize`, `artifact completeness`를 같이 봐야 한다.
- run count와 history row count를 혼동하면 early finalize가 생긴다.
- advisor trace에는 invalid proposal이 섞일 수 있어 log-domain과 search-space guard가 필요하다.
- isolate / finalize / history를 분리해야 mid-run best와 final winner를 동시에 읽을 수 있다.

30. 한계

- 단일 benchmark, single split batch라 분산 추정이 약하다.
- run budget `100`은 dual-advisor의 late gain을 보기엔 짧을 수 있다.
- hidden finalize는 final incumbent `1`회 기준이라 top-k reseeding은 아직 없다.
- code-edit autoresearch loop까지는 포함하지 않았다.

31. References

구분	예시
curated landscape	awesome-autoresearch, Awesome Auto Research Tools
end-to-end systems	karpathy/autoresearch, RD-Agent, AI-Scientist
deep research	GPT Researcher
evaluation	MLE-bench, MLAgentBench, MLR-Bench
optimization baselines	Optuna docs, SMAC3 docs
visuals	AutoML image, NAS image, Kubeflow model registry lifecycle image