AutoML, Autoresearch, MLOps +@

26.4.8

서민교

1. AutoML

정의

- 주어진 `search space` 안에서 더 좋은 모델 설정을 자동으로 찾는 방법

대표 작업

- `model selection`, `hyperparameter tuning`, `pipeline search`

초점

- 새로운 알고리즘 자체보다 후보 비교와 설정 탐색 자동화

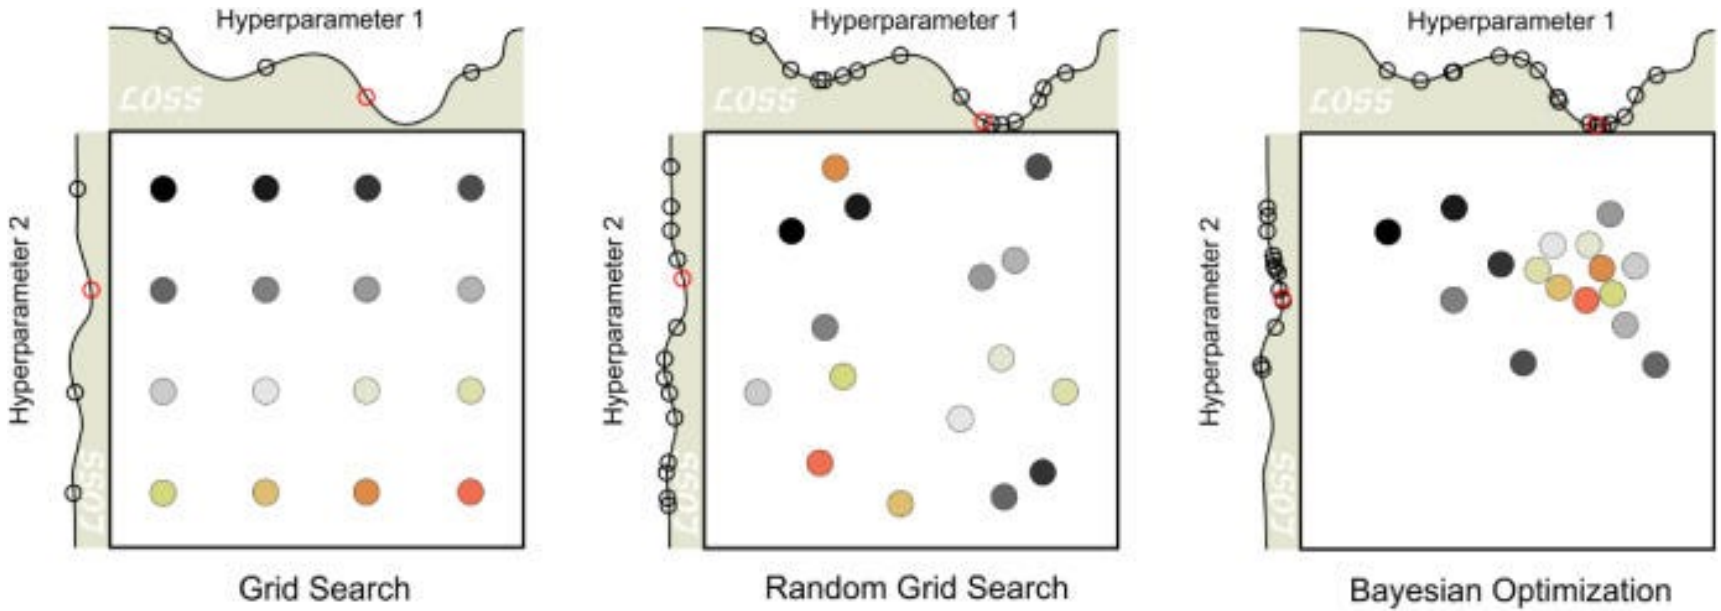

2. Neural Architecture Search

- 설정값이 아니라 architecture 자체를 탐색
- AutoML의 `더 넓은 search space` 확장선
- 그래도 중심은 여전히 모델/파이프라인 후보 탐색

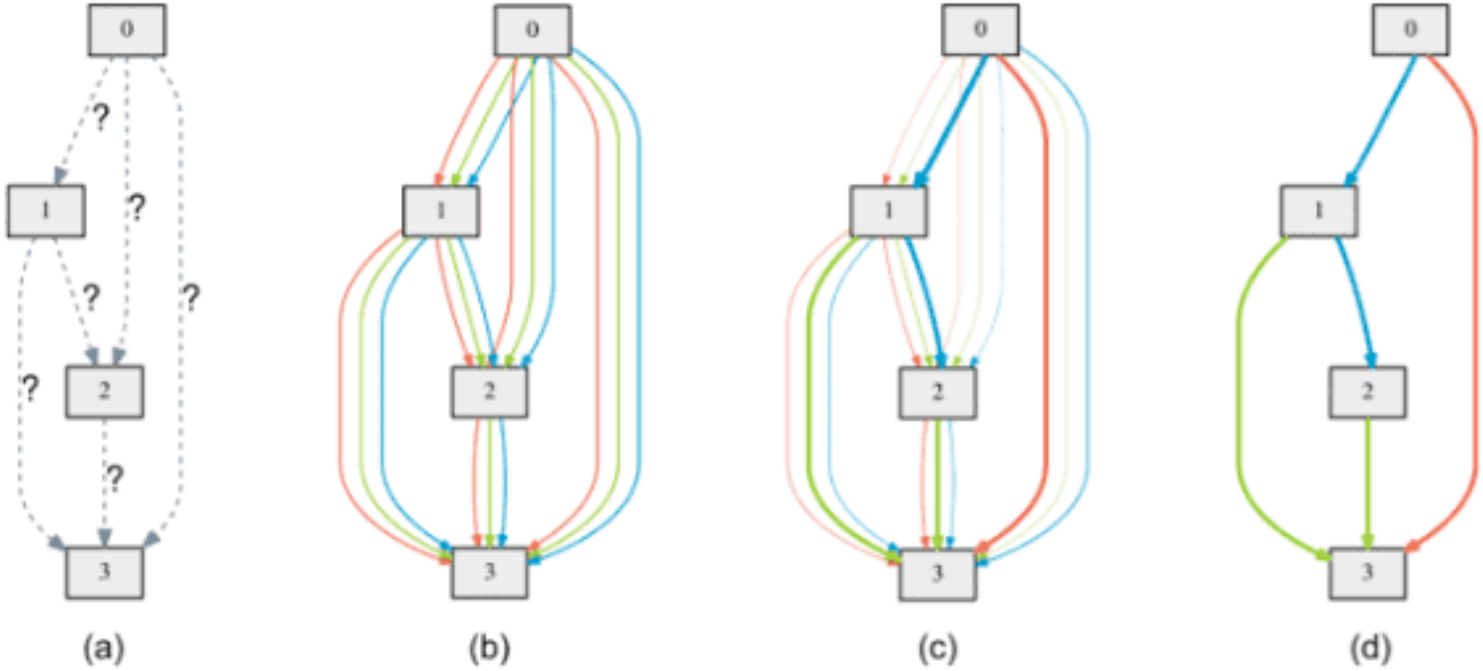

`hyperparameter search → pipeline search → architecture search`

3. Autoresearch

제안

- karpathy/autoresearch: 작은 training setup 위 `read → edit → run → keep-or-revert` loop 제시
- 연구 workflow 일부를 agent가 직접 수행하며, 설정 탐색을 넘어 `code`, `module`, `experiment` 자체 수정
- AutoML의 `fixed search space` 바깥으로 확장

이후 확장

- RD-Agent, AI-Scientist, GPT Researcher 등으로 빠르게 확장

4. Autoresearch Workflow

`Read → Hypothesis → Edit → Run → Analyze → Next experiment`

`Read`

- baseline, failure mode, 제약을 파악한다

`Hypothesis`

- 다음 실험에서 검증할 질문 하나를 명시한다

`Edit`

- 작은 가설 하나를 코드나 설정에 반영한다

`Run`

- 짧은 실험으로 metric과 artifact를 확인한다

`Analyze`

- keep, revert, 다음 실험 제안으로 이어진다

5. AutoML vs. Autoresearch

항목	AutoML	Autoresearch
탐색 대상	config, pipeline, architecture	hypothesis, code, module, experiment
핵심 질문	어떤 설정이 가장 좋은가	다음에 어떤 실험을 해야 하는가
edit 단위	parameter / architecture	code / module / pipeline / experiment
평가 방식	objective 중심	objective + reasoning + iteration
위험	비효율적 탐색	incoherent search, metric hacking
필요한 인프라	experiment infra	experiment + memory + harness

6. Autoresearch Applications

사용례

- 문헌 조사 / deep research: GPT Researcher
- 코드 수정 + 실험 반복: karpathy/autoresearch, RD-Agent
- end-to-end 연구 자동화: AI-Scientist

확장

- benchmark / evaluation: MLE-bench, MLAgentBench, MLR-Bench
- plugin / skill 생태계: awesome-autoresearch, Awesome Auto Research Tools

7. 실험 운영의 어려움

공통 어려움

- `많은 run` 비교와 누적
- 어떤 edit가 차이를 만들었는지 추적하기 어렵다

agent 특유 문제

- `artifact`, `promotion`, `monitoring`, `cost control`까지 함께 관리해야 한다

8. MLOps

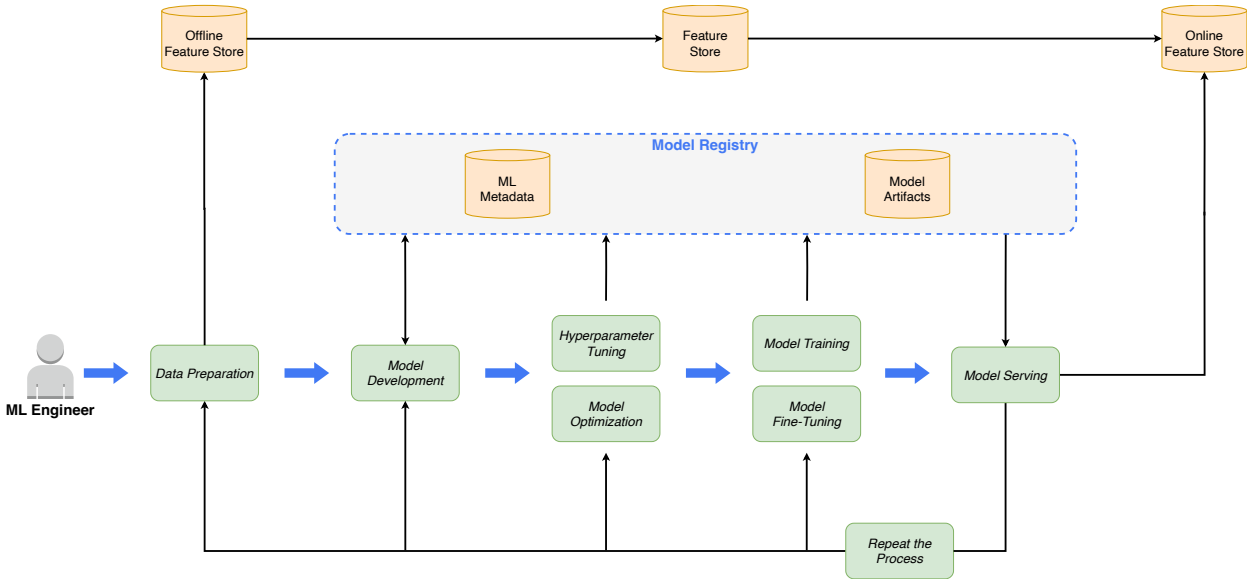

정의

- 모델 개발, 관리, 배포 파이프라인을 유지 관리하는 작업

필요성

- Autoresearch loop는 이 큰 ML lifecycle 안의 일부

핵심 역할

- 지속 운영 , 추적 , 승격 , 유지관리

9. MLOps 요소

요소	AutoML에서의 역할	Autoresearch에서의 역할
tracking	sweep 비교	hypothesis / code edit history 비교
orchestration	search job 실행	agent + eval job 실행
registry / lineage	best model 승격	experiment / prompt / code provenance 보존
monitoring / cost	retrain trigger, SLO	budget, drift, unsafe promotion guardrail

10. 두 질문

성능

- `(AutoML의 도메인에서)` `Autoresearch` 는 baseline보다 낫나

운영

- `Autoresearch` 에 어떤 harness가 있으면 좋을까

11. 질문 1 셋업

비교 항목

Arm	구성
baseline only	`Optuna TPE`, `SMAC3`
agent only	plain `Autoresearch`
hybrid	`agent + TPE`, `agent + SMAC3`, `agent + TPE+SMAC`
direct	`TPE direct`, `SMAC direct`

실험 환경

- benchmarks: `fashion`, `twenty`, `spam`, `cifar`
- model: fixed `mlp` search space
- readout: `best val`, `best hidden`

12. 관련 문헌

- Using Large Language Models for Hyperparameter Optimization
  - 실험 이력 기반 순차 튜닝은 가능하지만, 장기적으로 BO 우위는 불명확하다.
- LLAMBO: Large Language Models to Enhance Bayesian Optimization
  - LLM은 BO를 대체하기보다 초기 탐색을 강화하는 보조 수단에 가깝다.
- AgentHPO: Large Language Model Agent for Hyper-Parameter Optimization
  - Agent형 LLM HPO는 가능성을 보였지만, BO 대비 성능 우위 근거는 약하다.
- SLLMBO: Sequential Large Language Model-Based Hyper-parameter Optimization
  - Hybrid LLM-BO 방식은 일부 태스크에서 classical BO보다 강하다.

13. Optuna TPE

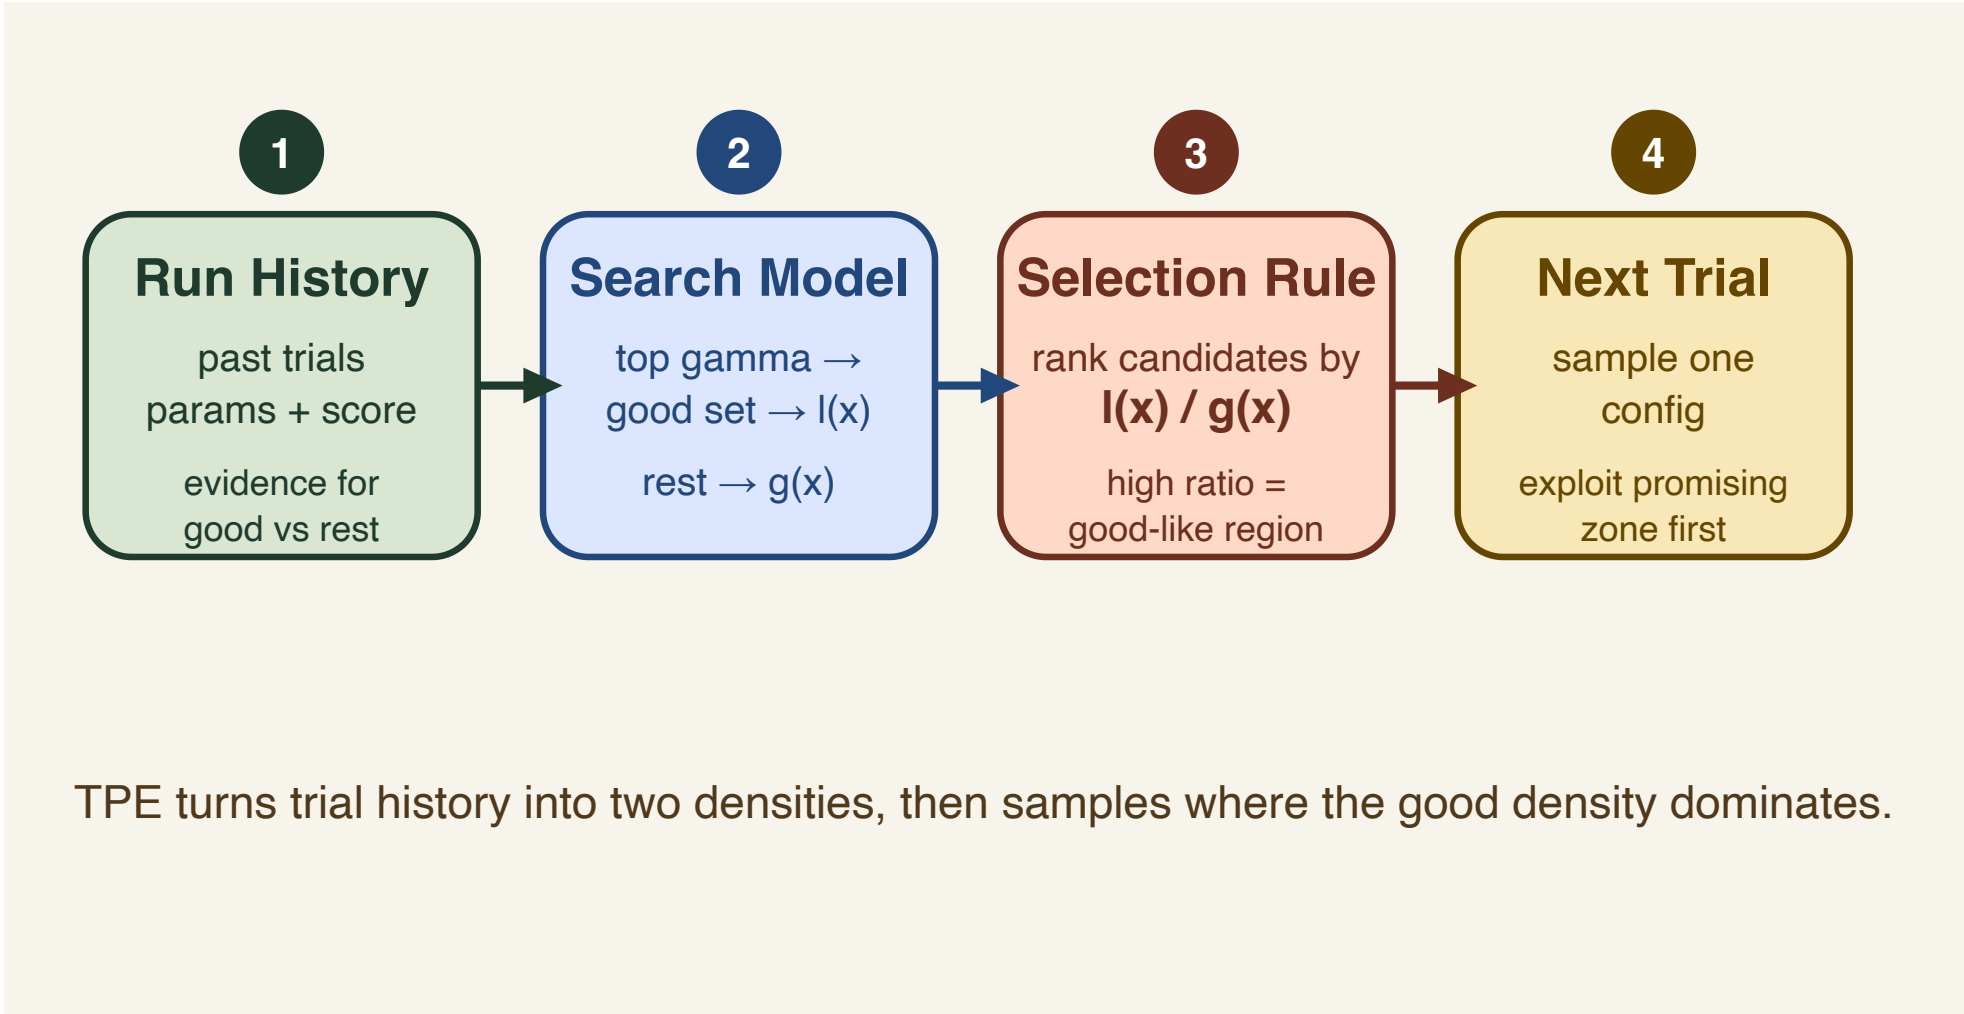

`Run History`

- observed trial을 `good set`과 `rest`로 나눈다

14. SMAC3

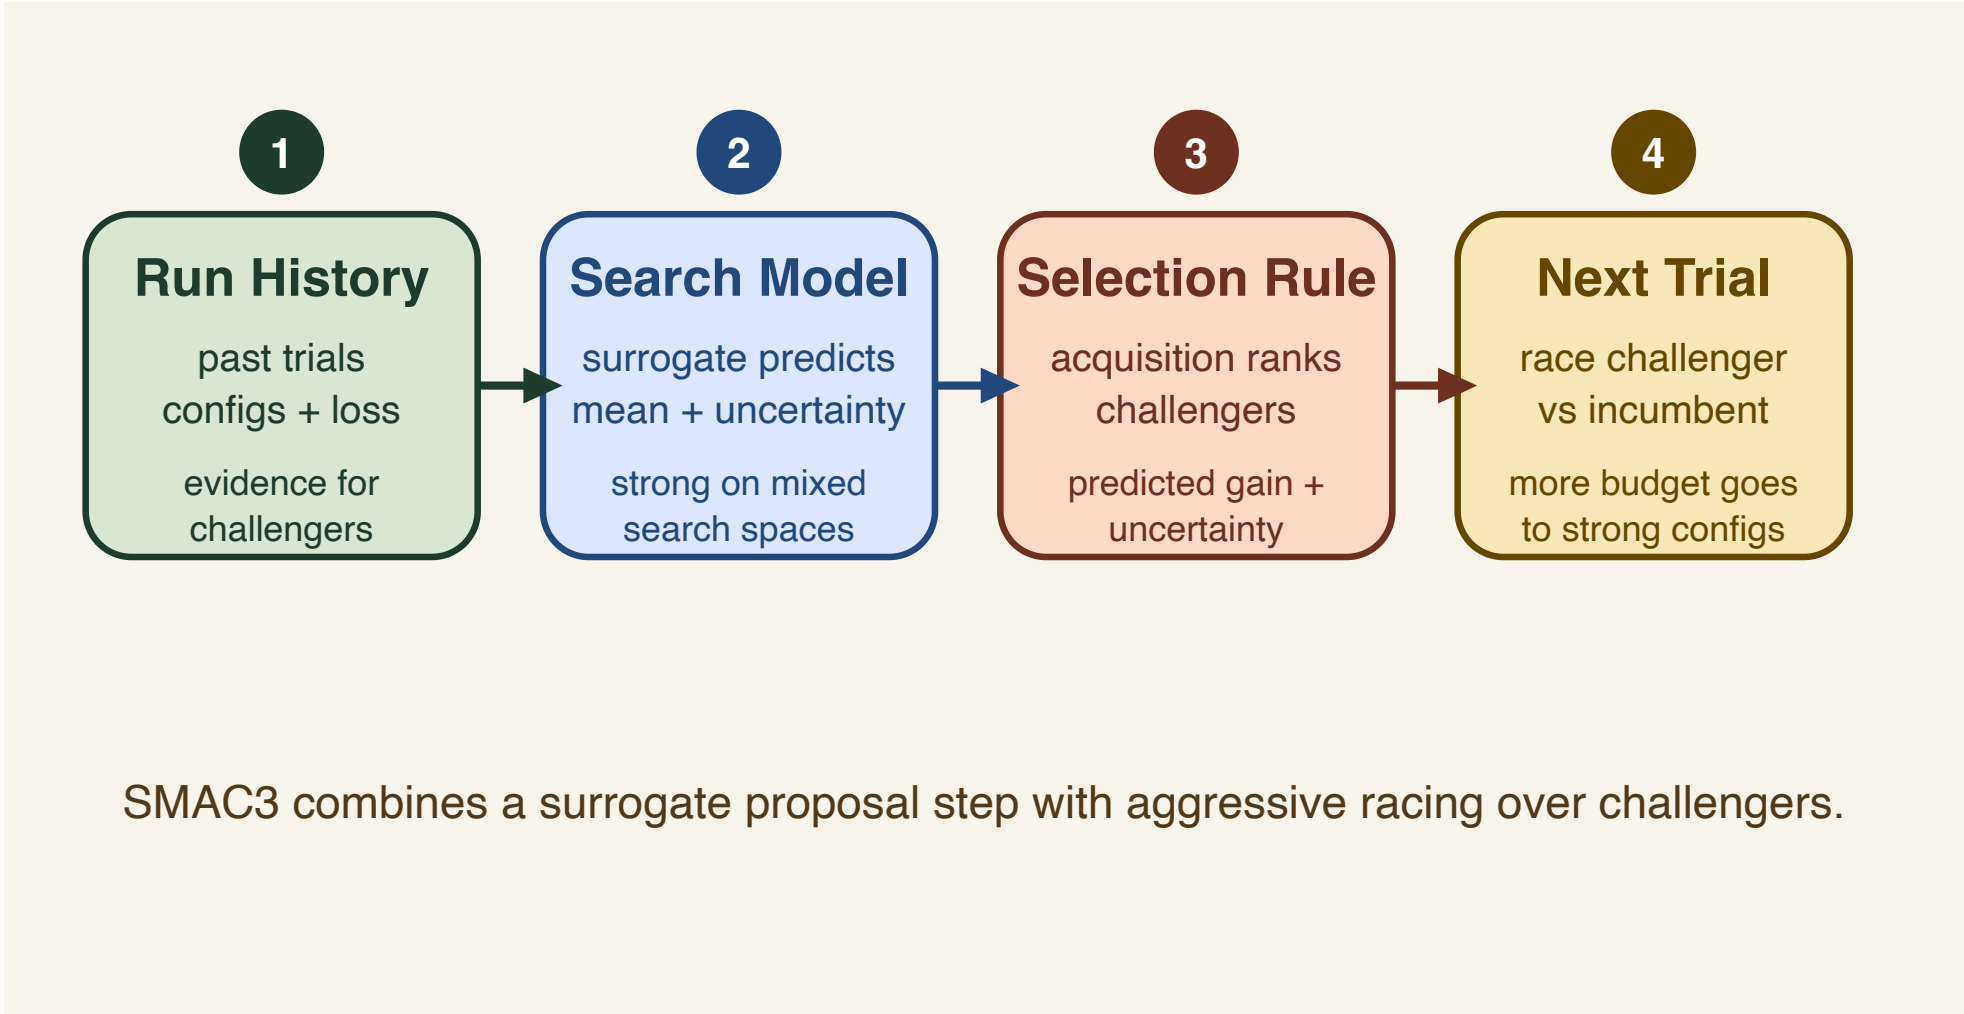

`Run History`

- observed config-loss pair로 surrogate를 학습한다

15. 질문 1 표

Question 1: Comparison Groups x Datasets

Cell value is the best validation reached by that comparison group on the dataset.

Comparison Group	Fashion-MNIST	Twenty Newsgroups	SMS Spam	CIFAR-10
TPE Direct best val in row	**0.854** TPE Dir	**0.551** TPE Dir	**0.990** TPE Dir	**0.428** TPE Dir
SMAC Direct best val in row	**0.863** SMAC Dir	**0.543** SMAC Dir	**0.989** SMAC Dir	**0.413** SMAC Dir
Plain Agent best val in row	**0.861** Scr Plain	**0.566** Rat Plain	**0.992** Scr Plain	**0.417** Adv Plain
Agent + TPE best val in row	**0.854** tie x3	**0.551** tie x3	**0.990** tie x3	**0.428** tie x3
Agent + SMAC best val in row	**0.863** tie x3	**0.543** tie x3	**0.989** tie x3	**0.413** tie x3
Agent + TPE+SMAC best val in row	**0.865** tie x2	**0.542** Adv T+S	**0.990** Scr T+S	**0.440** Rat T+S

16. 질문 1 추적 A

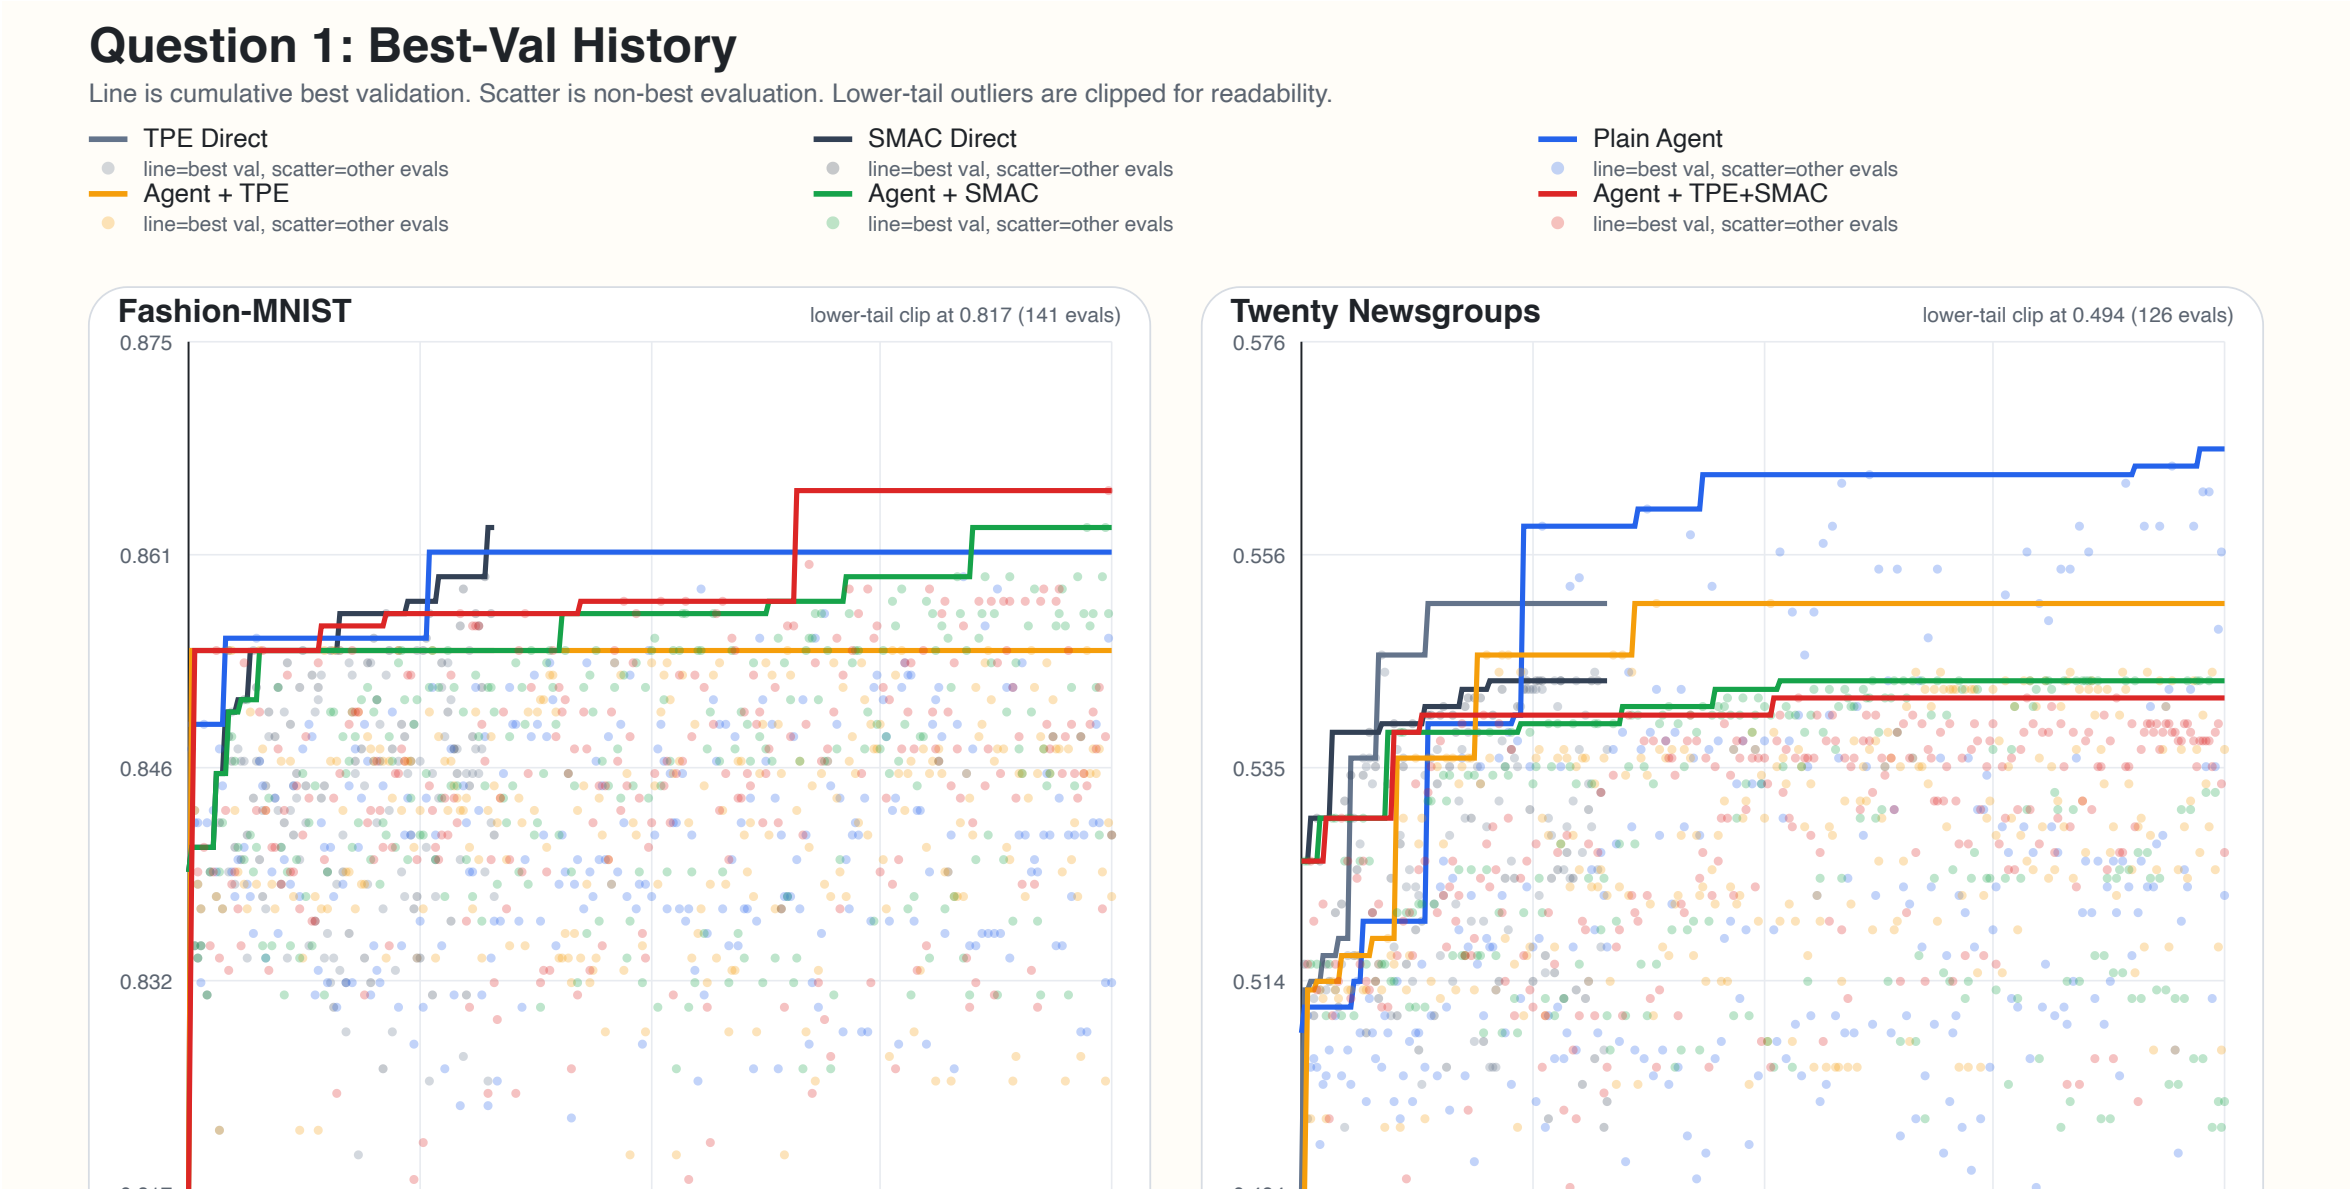
Question 1: Best-Val History
Line is cumulative best validation. Scatter is non-best evaluation. Lower-tail outliers are clipped for readability.
TPE Direct
line=best val, scatter=other evals
SMAC Direct
line=best val, scatter=other evals
Plain Agent
line=best val, scatter=other evals
Agent + TPE
line=best val, scatter=other evals
Agent + SMAC
line=best val, scatter=other evals
Agent + TPE+SMAC
line=best val, scatter=other evals
Fashion-MNIST
lower-tail clip at 0.817 (141 evals)
0.875
0.861
0.846
0.832
Twenty Newsgroups
lower-tail clip at 0.494 (126 evals)
0.576
0.556
0.535
0.514

17. 질문 1 추적 B

Question 1: Best-Val History

Line is cumulative best validation. Scatter is non-best evaluation. Lower-tail outliers are clipped for readability.

- TPE Direct — line=best val, scatter=other evals
- SMAC Direct — line=best val, scatter=other evals
- Plain Agent — line=best val, scatter=other evals
- Agent + TPE — line=best val, scatter=other evals
- Agent + SMAC — line=best val, scatter=other evals
- Agent + TPE+SMAC — line=best val, scatter=other evals

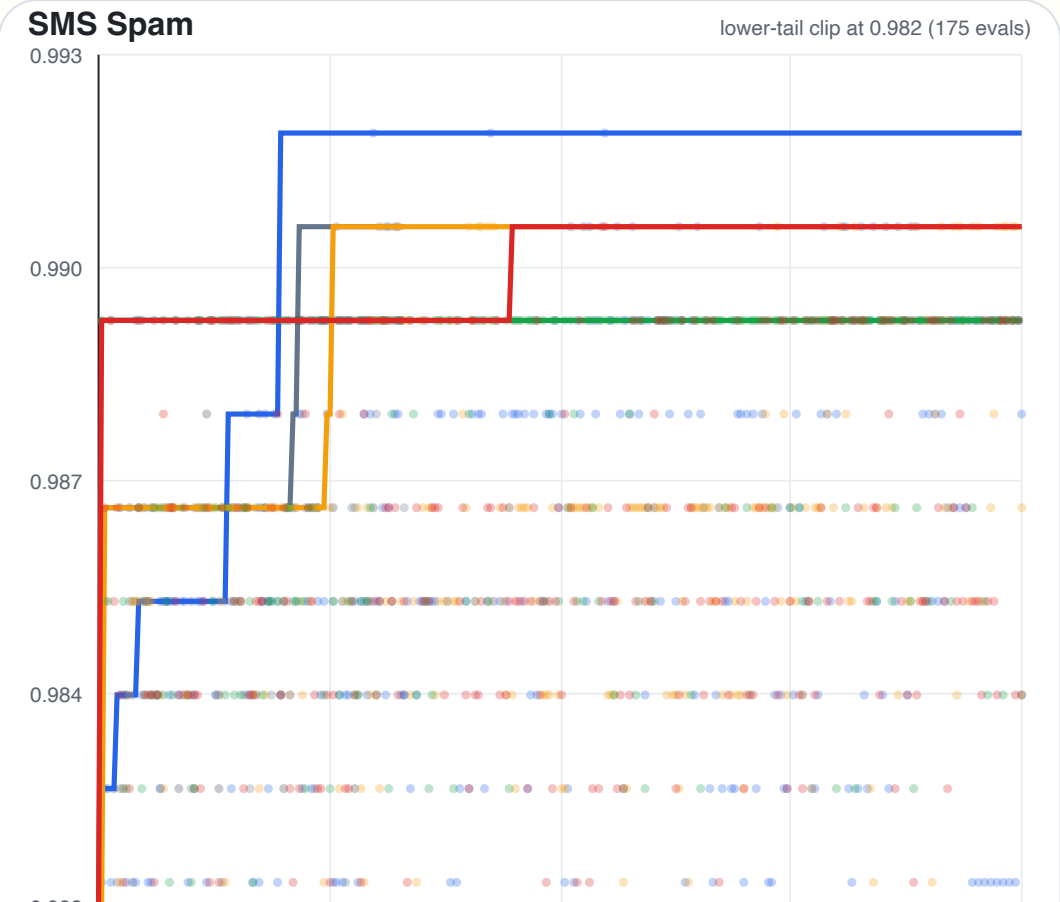

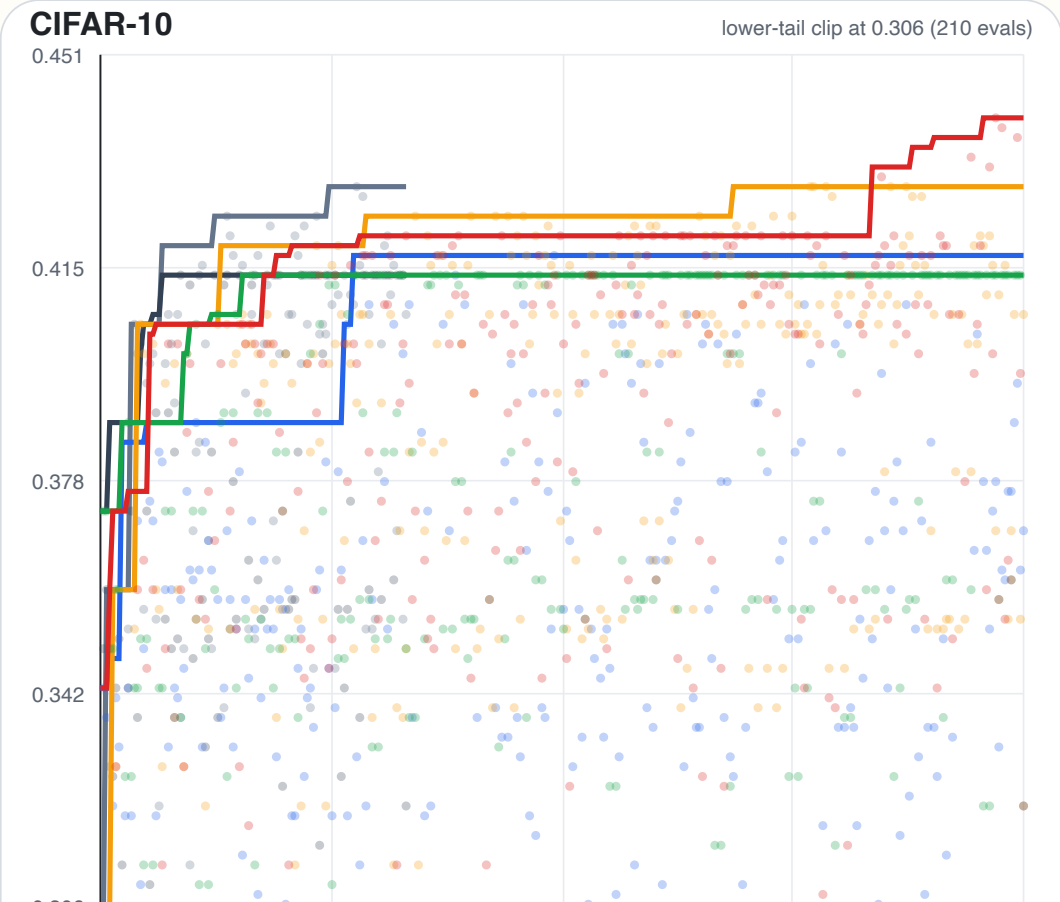

18. 질문 2 표

Question 2: Harness x Datasets

Each cell summarizes the best validation reached by that harness family.

Comparison Group	Fashion-MNIST	Twenty Newsgroups	SMS Spam	CIFAR-10
Ratchet best val in row	**0.863** Rat SMAC	**0.566** Rat Plain	**0.990** tie x2	**0.440** Rat T+S
Screening best val in row	**0.865** Scr T+S	**0.551** Scr TPE	**0.992** Scr Plain	**0.428** Scr TPE
Advanced best val in row	**0.865** Adv T+S	**0.551** Adv TPE	**0.990** tie x2	**0.428** Adv TPE

- harness 비교도 dataset마다 달랐다. 즉 `무슨 advisor를 붙였나` 만으로는 결과를 설명할 수 없고, `어떤 search loop를 돌렸나` 가 별도 요인이다.

19. 질문 2 추적 A

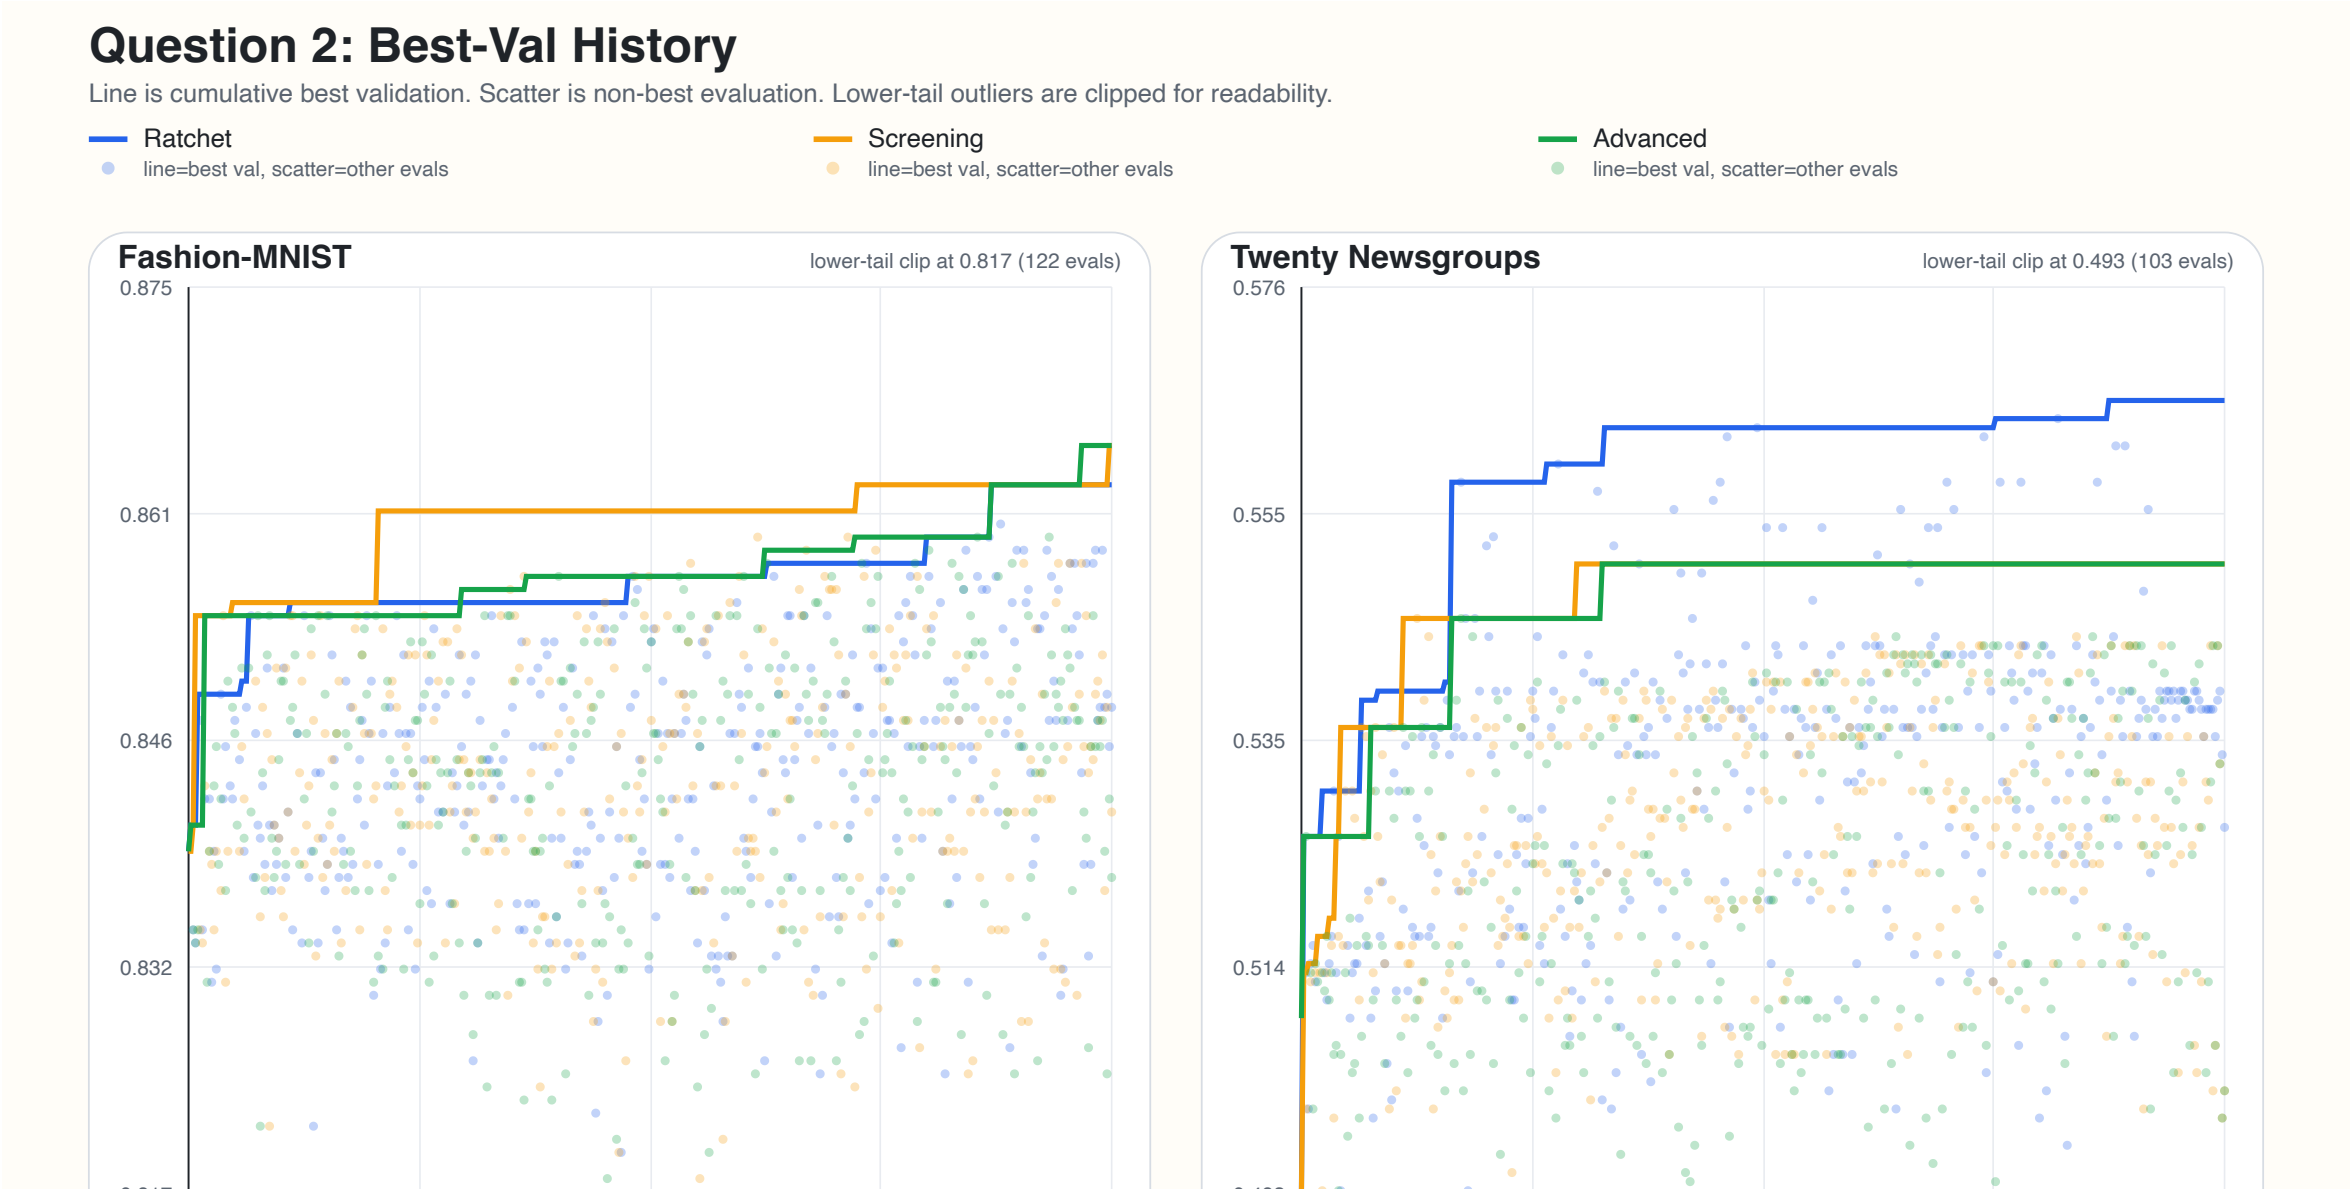
Question 2: Best-Val History
Line is cumulative best validation. Scatter is non-best evaluation. Lower-tail outliers are clipped for readability.
Ratchet
line=best val, scatter=other evals
Screening
line=best val, scatter=other evals
Advanced
line=best val, scatter=other evals
Fashion-MNIST
lower-tail clip at 0.817 (122 evals)
0.875
0.861
0.846
0.832
Twenty Newsgroups
lower-tail clip at 0.493 (103 evals)
0.576
0.555
0.535
0.514

20. 질문 2 추적 B

Question 2: Best-Val History

Line is cumulative best validation. Scatter is non-best evaluation. Lower-tail outliers are clipped for readability.

- Ratchet — line=best val, scatter=other evals
- Screening — line=best val, scatter=other evals
- Advanced — line=best val, scatter=other evals

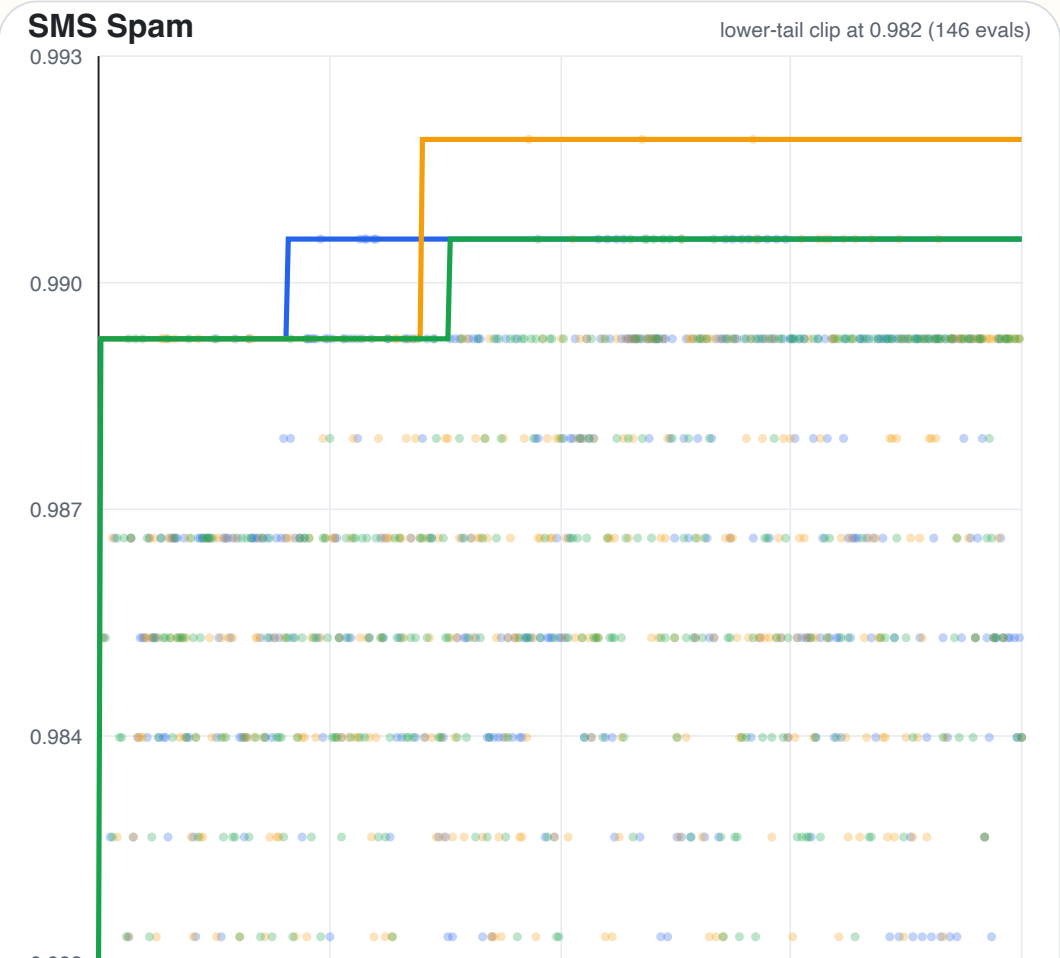

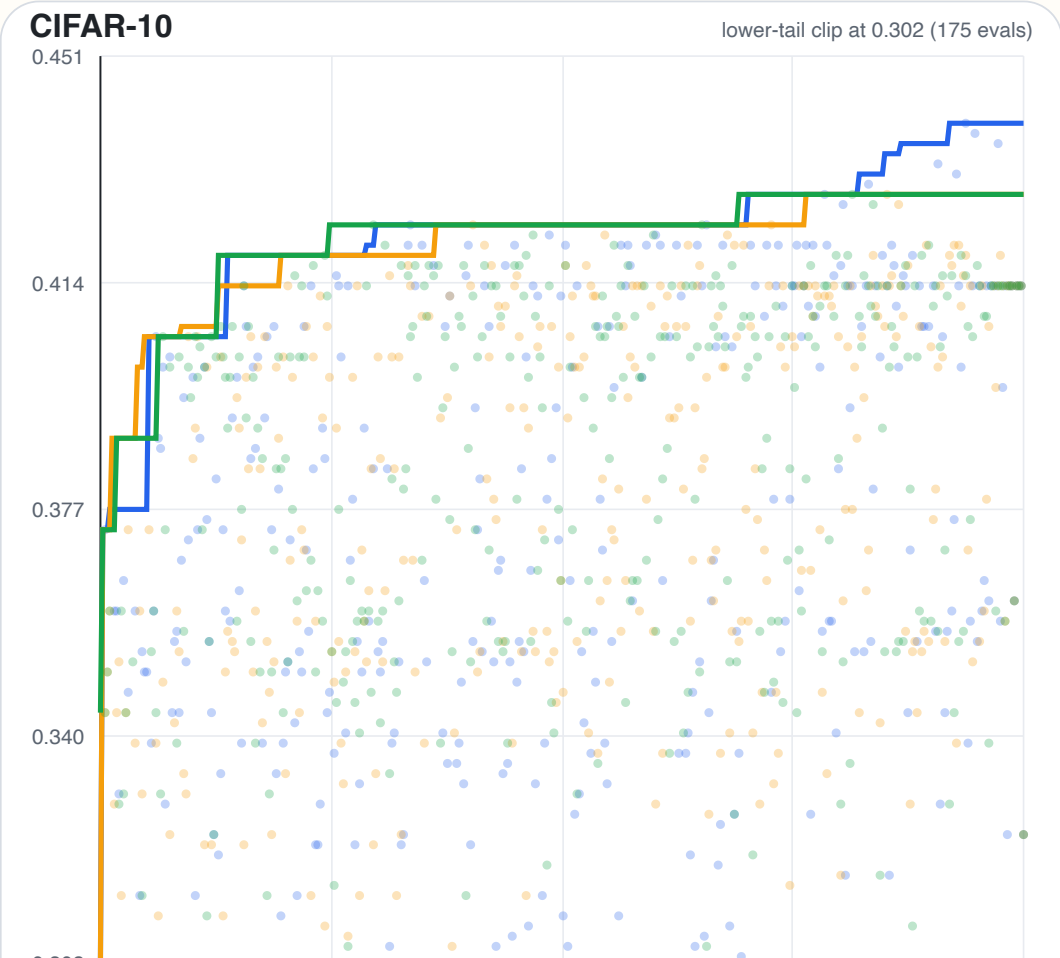

21. 공통 패턴

- winner는 dataset마다 달랐다.
- `best val`과 `best hidden`은 `fashion`, `spam`, `cifar`에서 갈렸다.
- hybrid가 ceiling을 높일 때도 있었지만, plain이 finalize를 더 잘하는 경우가 반복됐다.
- direct baseline도 여러 데이터셋에서 top tier에 남아 있었다.

22. 운영 교훈

- subagent isolation 없이는 dataset 간 context가 섞인다.
- run당 `1` candidate 제한이 없으면 비교 단위가 흐려진다.
- duplicate guard가 없으면 deterministic eval에서 같은 config를 반복하게 된다.
- artifact count로 검산하지 않으면 early finalize나 invalid wave를 놓친다.

23. 핵심 함의

- harness effect는 advisor effect만큼 컸다.
- validation 최적화와 finalize 최적화는 다른 문제였다.
- dual advisor는 일부 데이터셋에서만 이득이 있었다.
- harness 평가는 `best val`, `best hidden`, completeness를 함께 봐야 한다.

24. 추천

추천

- default winner 하나를 고정하지 말고 dataset별 shortlist를 운영한다.
- image tabular-like regime에선 hybrid peak를, text/saturated regime에선 plain finalize를 우선 본다.
- rerun 규칙과 contamination discard 기준을 미리 정해 둔다.

25. 한계

- single split, repeated seed 평균 없음
- model family는 `mlp` 하나만 사용했다
- budget은 condition당 `100 + finalize 1` 로 짧다
- code-edit autoresearch와 open-ended research task는 아직 제외했다

26. References

구분	예시
curated landscape	awesome-autoresearch, Awesome Auto Research Tools
end-to-end systems	karpathy/autoresearch, RD-Agent, AI-Scientist
deep research	GPT Researcher
evaluation	MLE-bench, MLAgentBench, MLR-Bench
optimization baselines	Optuna docs, SMAC3 docs
visuals	AutoML image, NAS image, Kubeflow model registry lifecycle image