AutoML, Autoresearch, MLOps +@

26.4.7

서민교

1. AutoML이란 무엇인가?

- 모델 개발 탐색 일부 자동화
- 대표 대상: `model selection`, `hyperparameter tuning`, `pipeline search`
- 핵심: 비교적 주어진 `search space` 안 최적 설정 탐색

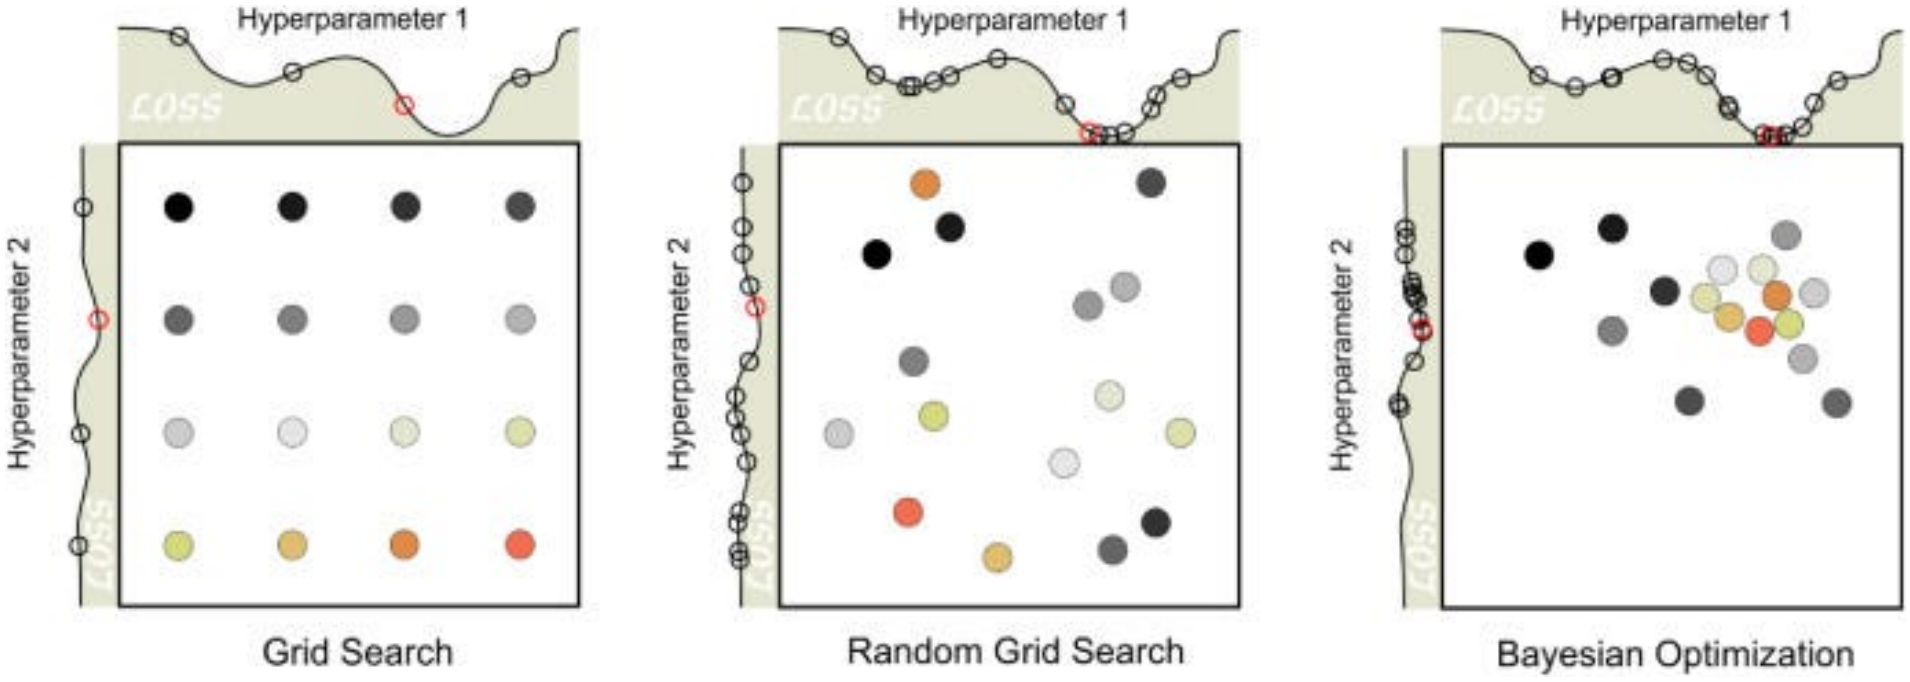

출처 이미지

2. `Neural Architecture Search`는 AutoML의 확장이다

- parameter 대신 architecture 탐색
- AutoML의 `더 넓은 search space` 확장선
- 그래도 중심은 여전히 모델/파이프라인 후보 탐색

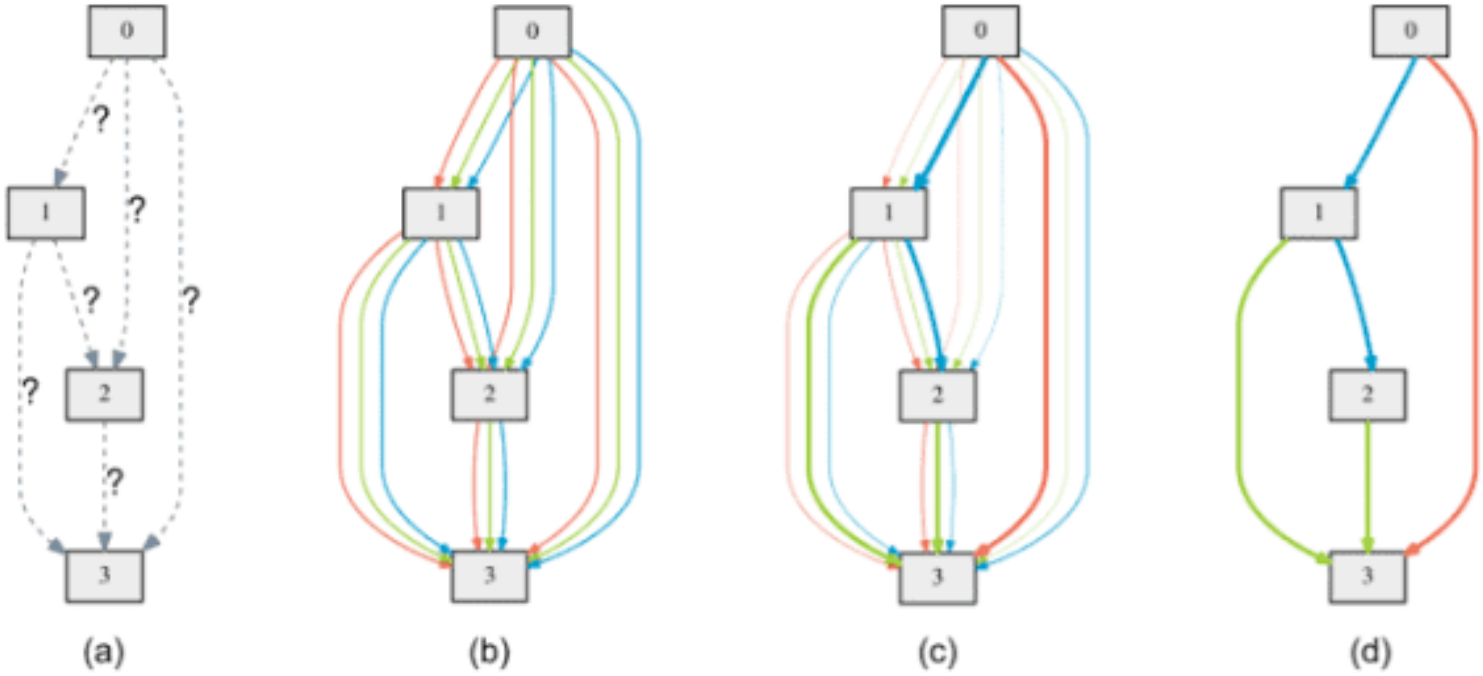

`hyperparameter search → pipeline search → architecture search`

3. `Autoresearch`는 어떻게 등장했고 무엇이 다른가?

- karpathy/autoresearch: 작은 training setup 위 `read → edit → run → keep-or-revert` loop 제시
- 연구 workflow 일부를 agent가 직접 수행하며, 설정 탐색을 넘어 `code`, `module`, `experiment` 자체 수정
- AutoML의 `fixed search space` 바깥으로 확장
- 이후 RD-Agent, AI-Scientist, GPT Researcher 등으로 빠르게 확장

4. Agent 작업 흐름

- 코드 읽기, baseline 파악
- 작은 가설 하나 선택
- 학습 코드나 설정 수정
- 짧은 실험 실행, metric 확인
- 나쁘면 revert, 의미 있으면 keep
- 핵심: `edit 한 번`이 아니라 `짧은 실험 loop의 누적`

```
Question → Read → Edit → Run → Analyze → Next experiment
```

5. AutoML vs. Autoresearch

항목	AutoML	Autoresearch
탐색 대상	config, pipeline, architecture	hypothesis, code, module, experiment
핵심 질문	어떤 설정이 가장 좋은가	다음에 어떤 실험을 해야 하는가
edit 단위	parameter / architecture	code / module / pipeline / experiment
평가 방식	objective 중심	objective + reasoning + iteration
위험	비효율적 탐색	incoherent search, metric hacking
필요한 인프라	experiment infra	experiment + memory + harness

6. 사용례와 확장

사용례

- 문헌 조사 / deep research: GPT Researcher
- 코드 수정 + 실험 반복: karpathy/autoresearch, RD-Agent
- end-to-end 연구 자동화: AI-Scientist

확장

- benchmark / evaluation: MLE-bench, MLAgentBench, MLR-Bench
- plugin / skill 생태계: awesome-autoresearch, Awesome Auto Research Tools
- memory, reusable modules, hardware fork

7. 체계적인 실험 관리의 필요

- 공통 문제: `많은 run` 비교와 누적
- 필수 요소: `tracking`, `lineage`, `orchestration`
- agent edit가 들어오면 `artifact`, `promotion`, `monitoring`, `cost control` 중요도 상승
- 결국 운영 문제

8. AutoML과 Autoresearch가 공통으로 요구하는 MLOps 요소

요소	AutoML에서의 역할	Autoresearch에서의 역할
tracking	sweep 비교	hypothesis / code edit history 비교
orchestration	search job 실행	agent + eval job 실행
registry / lineage	best model 승격	experiment / prompt / code provenance 보존
monitoring / cost	retrain trigger, SLO	budget, drift, unsafe promotion guardrail

9. MLOps는 모델 개발, 관리, 배포 파이프라인을 유지 관리하는 작업이다

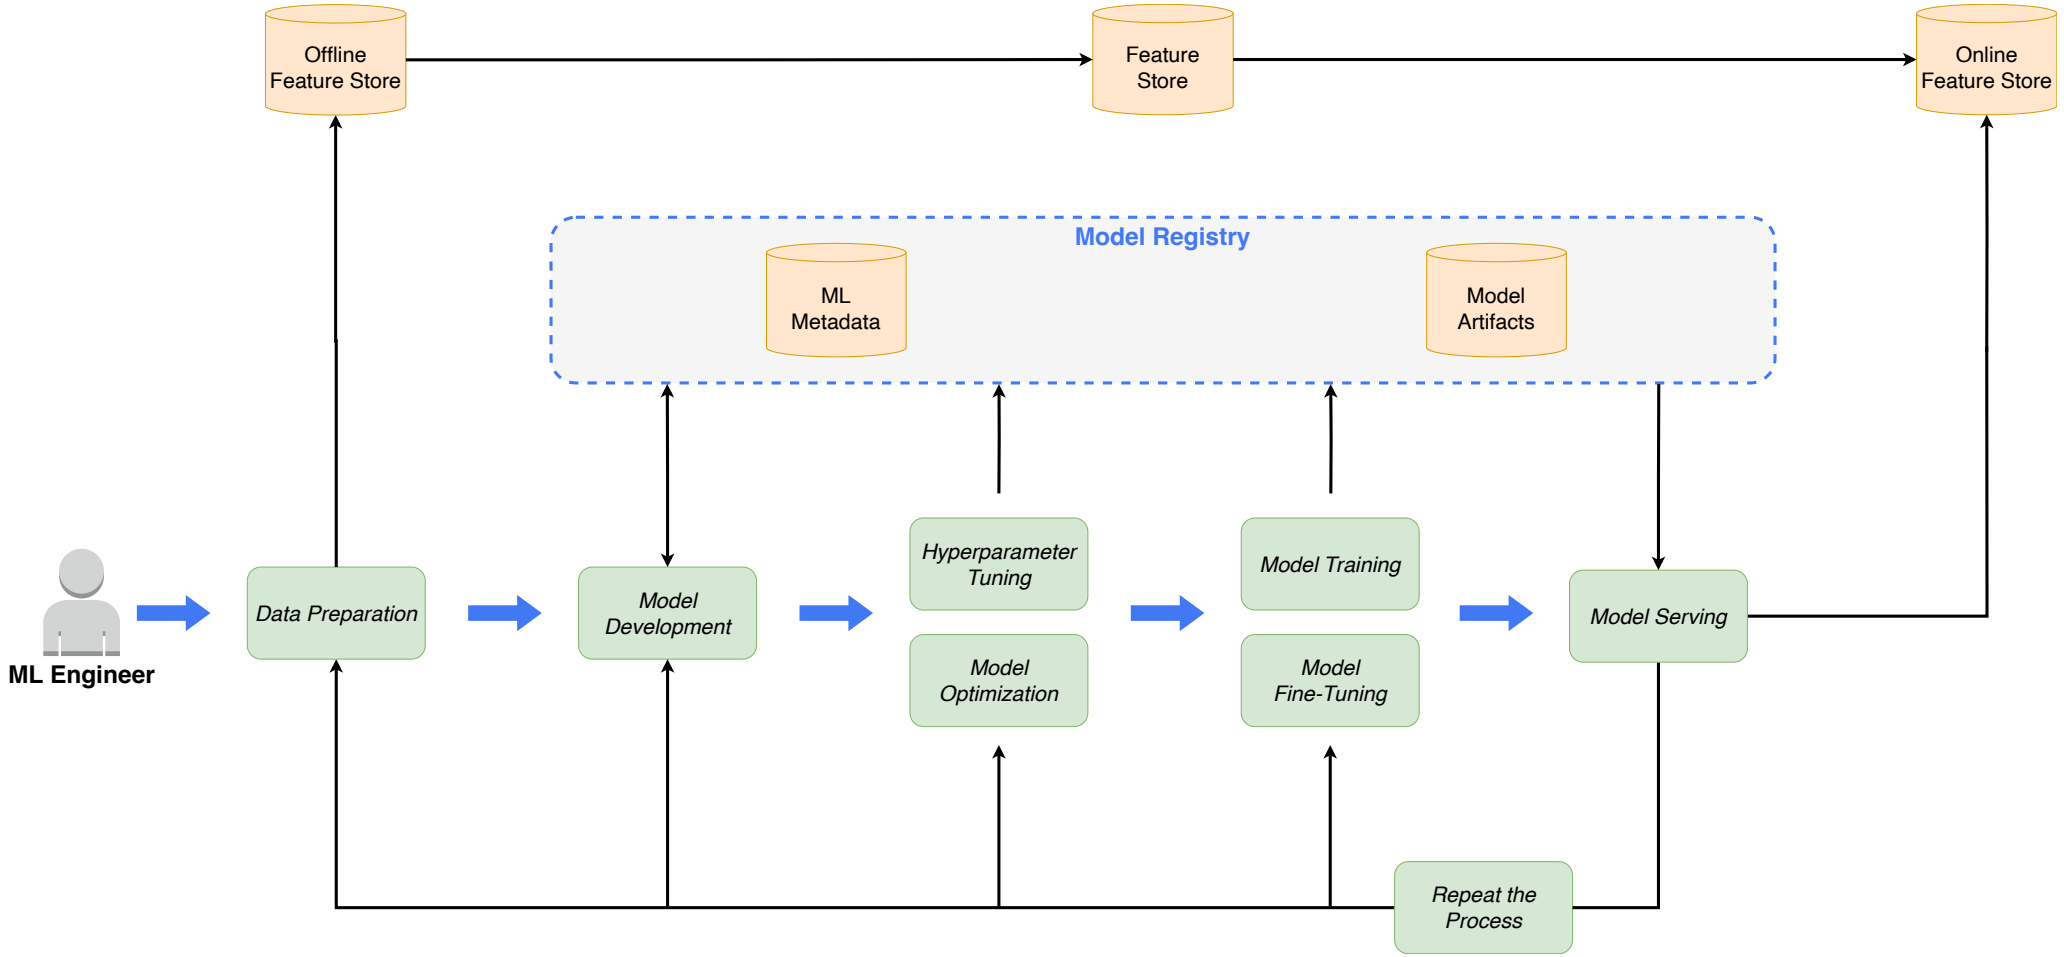

- Autoresearch loop는 이 큰 ML lifecycle 안의 일부
- 실제 시스템: `data`, `experiment`, `model registry`, `deployment`, `monitoring`

10. Autoresearch는 어디서 흔들리나

- 실험이 즉흥적으로 이어지기 쉬움
- 왜 이 실험을 했는지 attribution이 약함
- 큰 수정, 작은 튜닝, 검증 실험이 섞이기 쉬움
- robustness, replication, interaction 확인이 뒤로 밀림
- 잘 정리된 random search로 퇴화할 위험

11. 어떤 Harness가 필요한가

- 무엇을 먼저 볼지 정하는 우선순위
- 어떤 조합을 함께 볼지 정하는 규율
- 탐색 단계와 검증 단계 분리
- 작은 수정과 큰 수정을 다르게 다루는 운영 규칙
- 실패도 정보로 남기는 구조
- 다음 라운드를 설계하는 순차 실험 체계

12. DoE란 무엇인가

- 여러 요인을 한 번에 바꿔 보며 effect를 읽는 실험 설계
- 한 번의 최고점보다 `요인`, `상호작용`, `안정성` 파악에 강점
- 핵심 질문: 무엇을 바꿨고, 무엇이 실제로 영향을 줬는가

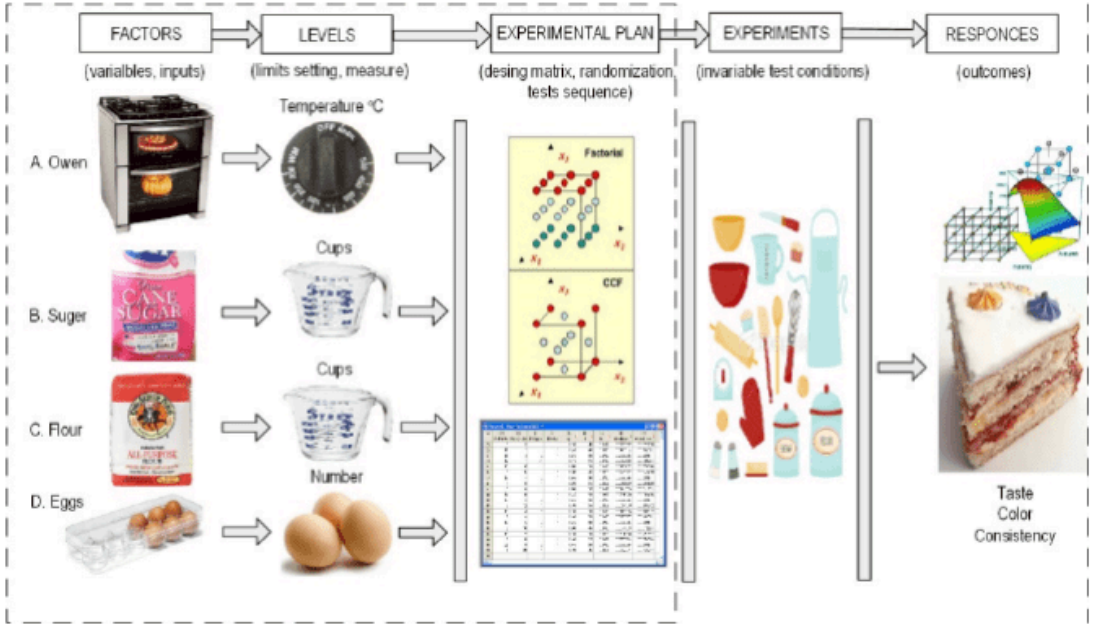

출처 이미지

13. DoE에서 빌려오는 개념

- `screening` : 중요한 요인부터 좁히기
- `factorial thinking` : interaction 보기
- `sequential design` : 라운드별 정교화
- `robust design` : 평균이 아니라 안정성까지 확인
- `mixture / allocation` : 예산과 비율 배분

14. Vanilla Agent와 DoE-Guided Agent

Vanilla autoresearch	DoE-guided autoresearch
edit → run → score 반복	factor 정의 → screening → interaction → refinement → robustness
실험 성격 혼재	실험 타입 분리
best score 중심	effect / interaction / stability 축적
장기 구조 약함	라운드 기반 운영

15. 비교한 Agents

Agent	설명
`01 Sequential`	최신 기록에 맞춰 작은 변경을 순차 적용
`02 Simple DoE`	factor와 level을 두고 screening 중심 비교
`03 Advanced DoE Tic-Tac-To`	staged DoE + 실험 타입 예산 분배

- 비교 포인트: 성능만이 아니라 탐색의 질과 실험 구조
- `Tic` : 둘 이상 모듈 동시 변경
- `Tac` : 한 모듈 교체
- `To` : 같은 구조 안 수치 조정
- 운영 규칙: `Tic:Tac:To = 1:2:4`

16. 실험 설정

Benchmark	데이터 / 제약	실제 사용 model	현재 시작점
`cifar10_real`	`max_samples=4000`	`mlp`	세 agent 모두 `mlp_anchor` control에서 시작
`twenty_newsgroups_real`	`max_samples=8000`, `max_features=2000`, `ngram_max=2`, `min_df=2`	`mlp`	같은 loop로 benchmark만 전환

- 실행 방식: agent별 isolated root를 따로 만들어 context leakage 없이 독립 실행
- 이번 결과: 각 agent가 같은 start control에서 출발해 validation-only `200` runs를 누적

17. 결과: 성능, 효율, 안정성

실험 조건

- benchmark: `cifar10_real`
- model family: `mlp`
- search surface: curated `10` knobs only
- 공개 지표: validation only, hidden test는 열지 않음

Agent	Best Val	Run of Best	Gain vs Run 1	Mean Best-so-Far	Incumbent Updates
`01 Sequential`	`0.4333`	`37`	`+0.0750`	`0.4282`	`10`
`02 Simple DoE`	`0.3850`	`8`	`+0.0133`	`0.3846`	`3`
`03 Advanced DoE + Tic-Tac-To`	`0.4033`	`51`	`+0.0450`	`0.4012`	`5`

Best configs

- `01 Sequential`: `maxabs + svd(32) + [64,32] + relu + adam + batchnorm + wd=0.001 + lr=0.0005 + bs=32`

18. 결과: 탐색 궤적

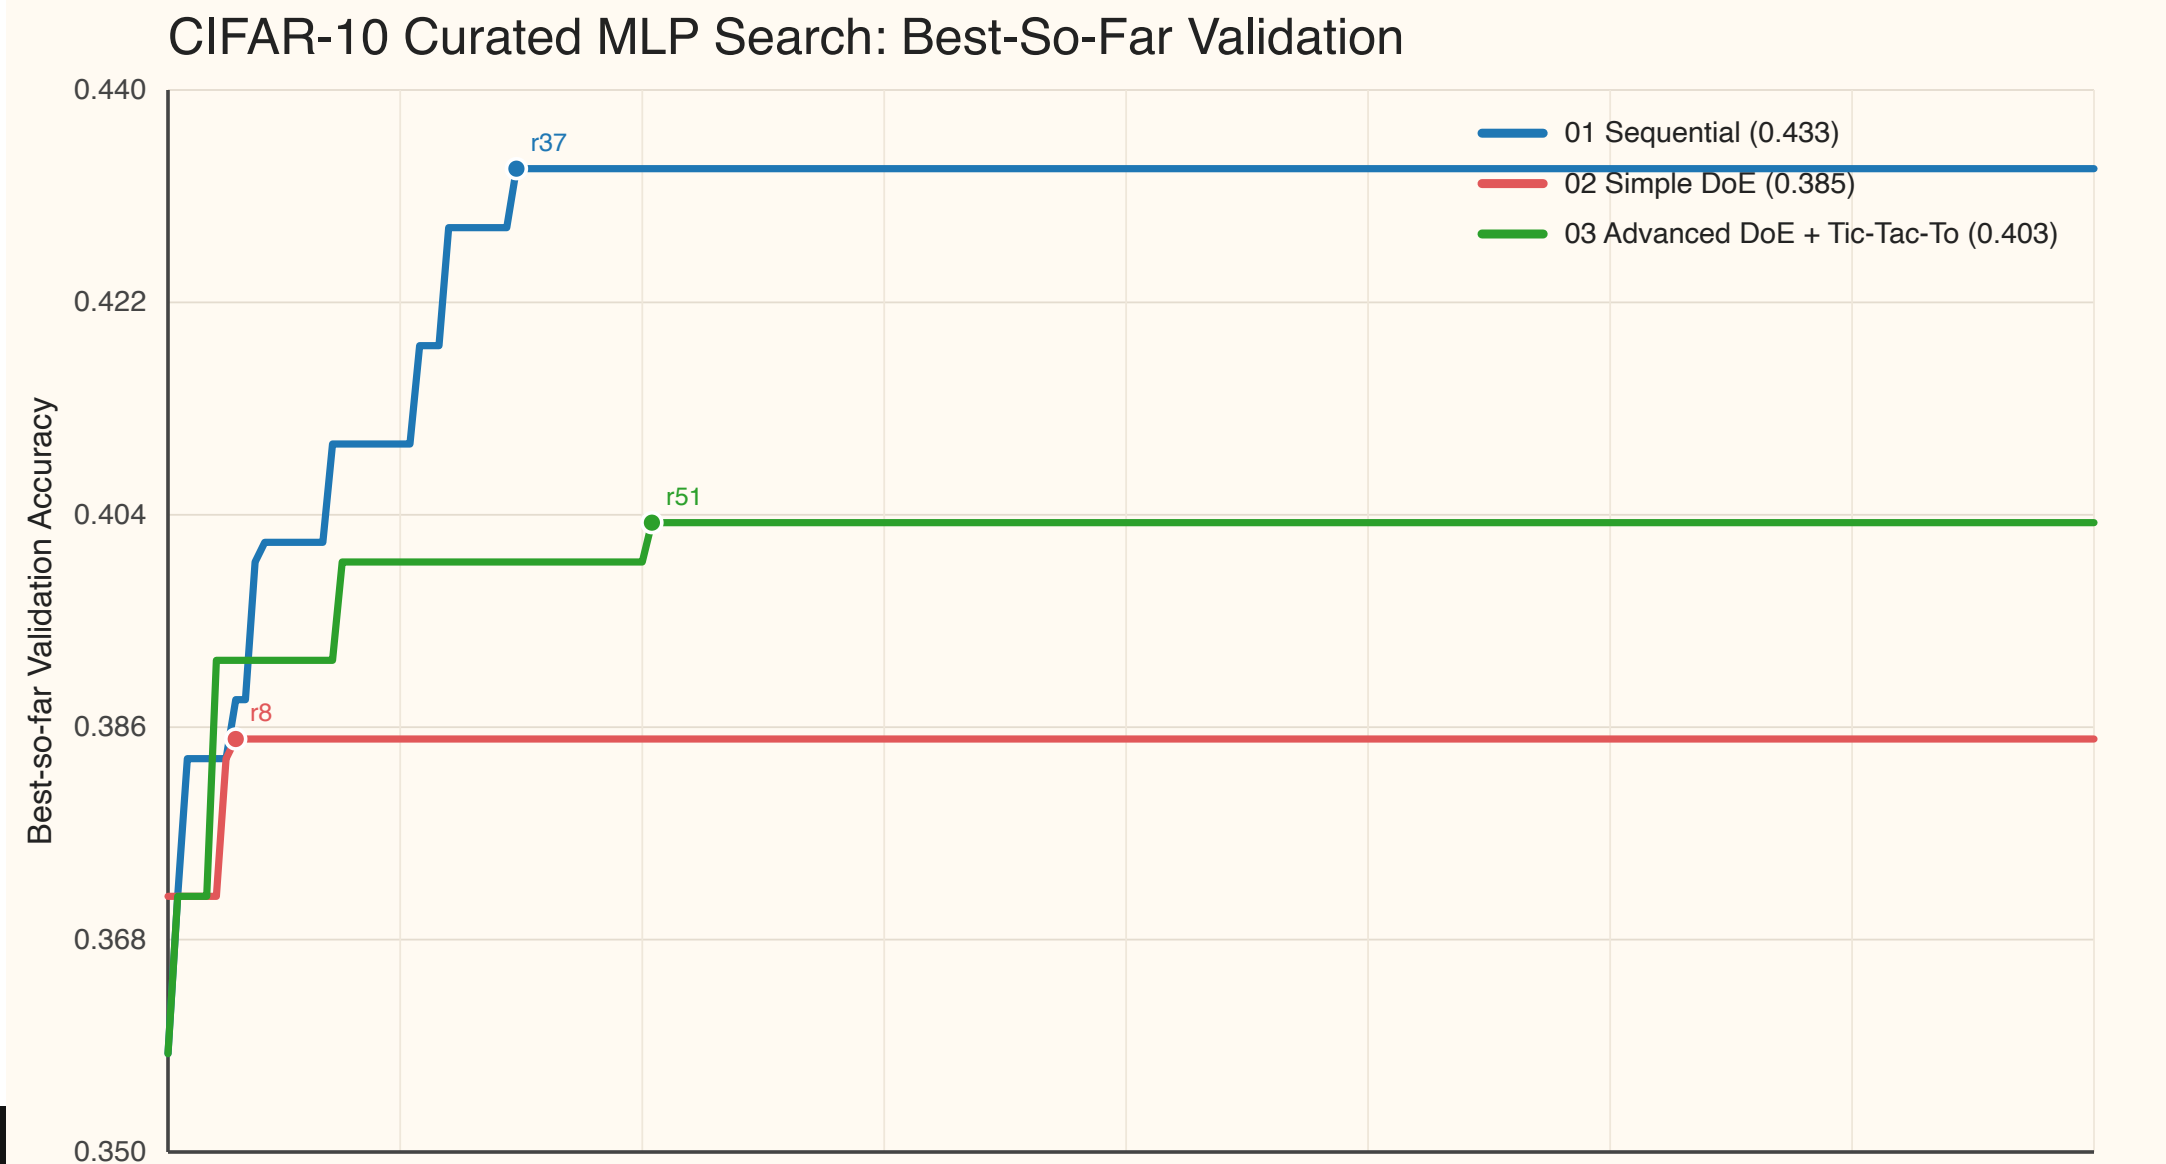
CIFAR-10 Curated MLP Search: Best-So-Far Validation
Best-so-far Validation Accuracy
0.440
0.422
0.404
0.386
0.368
0.350
r37
r51
r8
01 Sequential (0.433)
02 Simple DoE (0.385)
03 Advanced DoE + Tic-Tac-To (0.403)

19. 히스토리에서 읽히는 결론

- `Sequential` 은 좁은 search space에서 가장 강했다. projection, normalization layer, learning rate, batch size를 한 축씩 밀어 보며 강한 incumbent를 빠르게 만들었고, 이후 그 basin을 오래 지켰다.
- `Simple DoE` 는 screening efficiency는 높았지만, factor re-screening이 길어지면서 search diversification이 약해졌다. 좋은 baseline은 빨리 찾았지만 그 이후 ceiling을 거의 못 올렸다.
- `Advanced DoE + Tic-Tac-To` 는 `Simple DoE` 보다 훨씬 건강한 중후반 탐색을 보였다. `Tac` 과 `To` 를 많이 쓰면서도 `Tic` 을 완전히 버리지 않아, plateau 이후에도 구조적 escape 시도를 유지했다.
- 다만 현재 curated surface에서는 `Sequential` 이 여전히 최고였다. 즉 factor space가 충분히 작고 convention이 안정적이면, 복잡한 design보다 strong local refinement가 더 효율적일 수 있다.
- 반대로 `Advanced DoE + Tic-Tac-To` 가 `Simple DoE` 를 확실히 앞선 것은 중요하다. screening-only 프레임은 early orientation에는 좋지만, long-horizon search에는 staged refinement와 budget allocation이 필요하다는 뜻이다.

20. 히스토리와 피드백에서 추출한 튜닝 지식

`01 Sequential`

- 강한 basin: `maxabs + svd(32) + [64,32] + relu + adam`
- 추가 prior: `batchnorm`, `batch_size=32`, `learning_rate_init=0.0005`, `weight_decay=0.001` 쪽이 ceiling을 높였다.
- 실패 prior: `sgd` 전환은 반복적으로 약했다.
- 프로세스 지식: projection → internal normalization → learning rate → batch size 순으로 한 축씩 줄여 가는 local refinement가 효과적이었다.

`02 Simple DoE`

- 강한 basin: `standard + no projection + [64,32] + relu + adam + batch_size=128`
- 추가 prior: screening 초기엔 `normalization`, `learning_rate_init`, `batch_size`를 먼저 보는 편이 효율적이었다.
- 한계 지식: 빠른 orientation에는 좋았지만, 이후에도 screening 프레임이 길어지면 ceiling이 잘 안 오른다.

21. 한계

- 문헌 조사나 가설 생성 자체를 대체하진 못함
- 완전히 open-ended한 구조 탐색은 factorization이 어려움
- classical DoE는 코드 중심 search space에 바로 맞지 않을 수 있음
- large-scale 학습에서는 replication 비용이 큼
- 평가 함수가 빈약하면 DoE도 잘못된 목표를 최적화할 수 있음

22. References

구분	예시
curated landscape	awesome-autoresearch, Awesome Auto Research Tools
end-to-end systems	karpathy/autoresearch, RD-Agent, AI-Scientist
deep research	GPT Researcher
evaluation	MLE-bench, MLAgentBench, MLR-Bench
visuals	AutoML image, NAS image, Kubeflow model registry lifecycle image