AutoML, Autoresearch, MLOps +@

26.4.8

서민교

1. AutoML

정의

- 주어진 `search space` 안에서 더 좋은 모델 설정을 자동으로 찾는 방법

대표 작업

- `model selection`, `hyperparameter tuning`, `pipeline search`

초점

- 새로운 알고리즘 자체보다 후보 비교와 설정 탐색 자동화

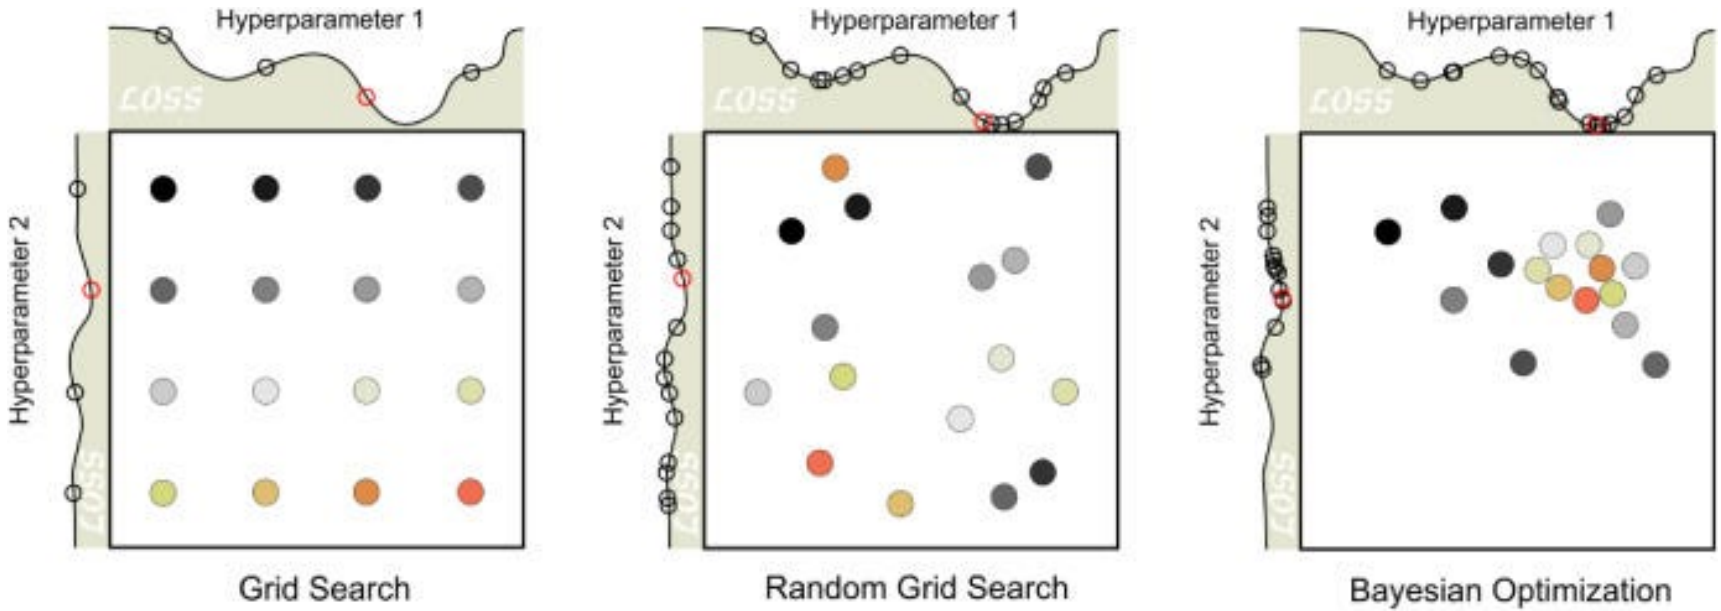

2. Neural Architecture Search

- 설정값이 아니라 architecture 자체를 탐색
- AutoML의 `더 넓은 search space` 확장선
- 그래도 중심은 여전히 모델/파이프라인 후보 탐색

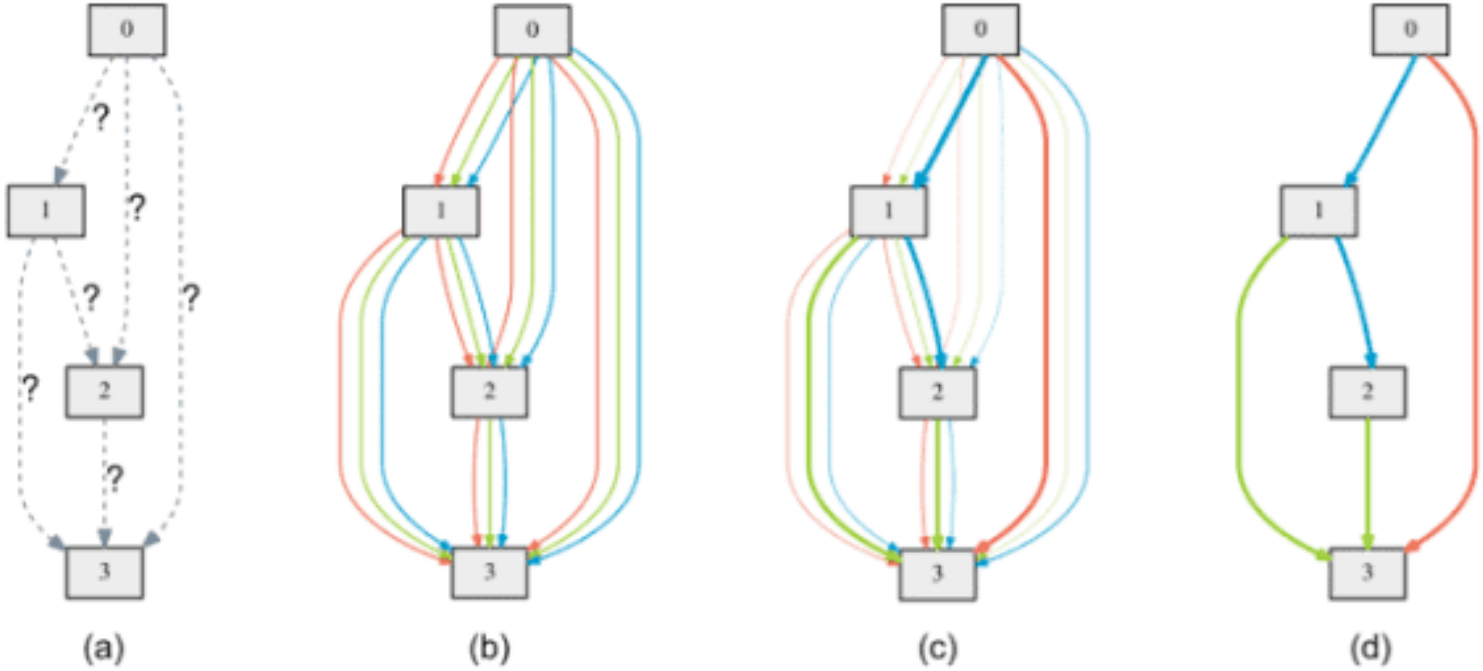

`hyperparameter search → pipeline search → architecture search`

3. Autoresearch

제안

- karpathy/autoresearch: 작은 training setup 위 `read → edit → run → keep-or-revert` loop 제시
- 연구 workflow 일부를 agent가 직접 수행하며, 설정 탐색을 넘어 `code`, `module`, `experiment` 자체 수정
- AutoML의 `fixed search space` 바깥으로 확장

이후 확장

- RD-Agent, AI-Scientist, GPT Researcher 등으로 빠르게 확장

4. Autoresearch Workflow

`Read → Hypothesis → Edit → Run → Analyze → Next experiment`

`Read`

- baseline, failure mode, 제약을 파악한다

`Hypothesis`

- 다음 실험에서 검증할 질문 하나를 명시한다

`Edit`

- 작은 가설 하나를 코드나 설정에 반영한다

`Run`

- 짧은 실험으로 metric과 artifact를 확인한다

`Analyze`

- keep, revert, 다음 실험 제안으로 이어진다

5. AutoML vs. Autoresearch

항목	AutoML	Autoresearch
탐색 대상	config, pipeline, architecture	hypothesis, code, module, experiment
핵심 질문	어떤 설정이 가장 좋은가	다음에 어떤 실험을 해야 하는가
edit 단위	parameter / architecture	code / module / pipeline / experiment
평가 방식	objective 중심	objective + reasoning + iteration
위험	비효율적 탐색	incoherent search, metric hacking
필요한 인프라	experiment infra	experiment + memory + harness

6. Autoresearch Applications

사용례

- 문헌 조사 / deep research: GPT Researcher
- 코드 수정 + 실험 반복: karpathy/autoresearch, RD-Agent
- end-to-end 연구 자동화: AI-Scientist

확장

- benchmark / evaluation: MLE-bench, MLAgentBench, MLR-Bench
- plugin / skill 생태계: awesome-autoresearch, Awesome Auto Research Tools

7. 실험 운영의 어려움

공통 어려움

- `많은 run` 비교와 누적
- 어떤 edit가 차이를 만들었는지 추적하기 어렵다

agent 특유 문제

- `artifact`, `promotion`, `monitoring`, `cost control`까지 함께 관리해야 한다

8. MLOps

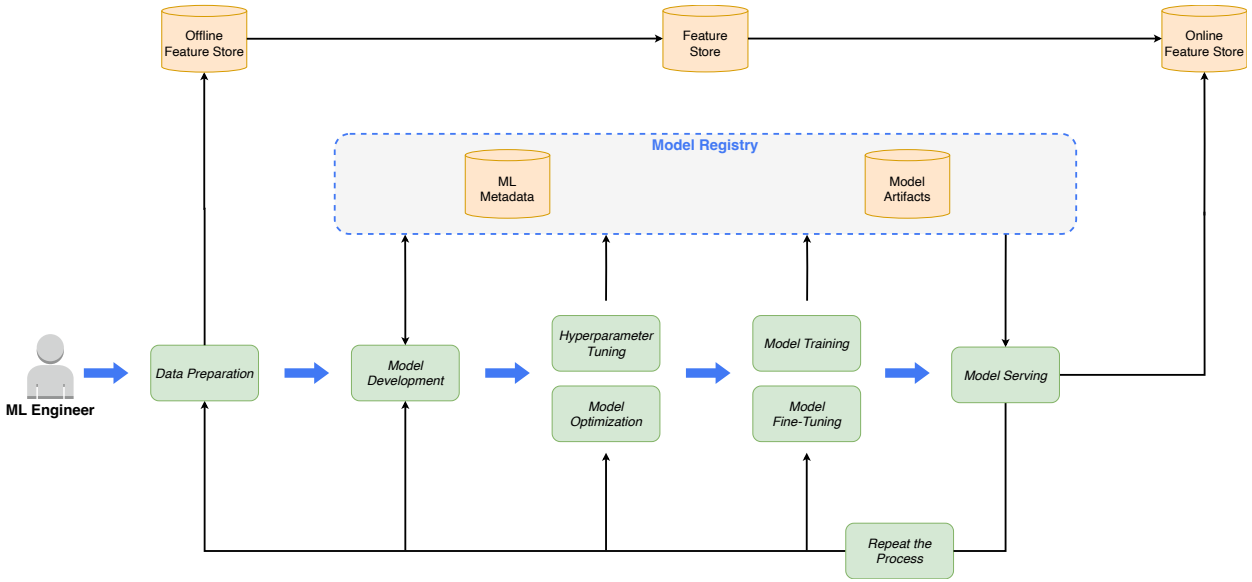

정의

- 모델 개발, 관리, 배포 파이프라인을 유지 관리하는 작업

필요성

- 앞 슬라이드의 실험 운영 문제를 시스템 수준에서 다룰 틀이 필요하다
- Autoresearch loop는 이 큰 ML lifecycle 안의 일부

핵심 역할

- 지속 운영 , 추적 , 승격 , 유지관리

9. MLOps 요소

요소	AutoML에서의 역할	Autoresearch에서의 역할
tracking	sweep 비교	hypothesis / code edit history 비교
orchestration	search job 실행	agent + eval job 실행
registry / lineage	best model 승격	experiment / prompt / code provenance 보존
monitoring / cost	retrain trigger, SLO	budget, drift, unsafe promotion guardrail

10. 두 질문

성능

- `(AutoML의 도메인에서)` `Autoresearch` 는 baseline보다 낫나

운영

- `Autoresearch` 에 어떤 harness가 있으면 좋을까

11. 질문 1 셋업

Arm	의미
baseline only	`Optuna TPE`, `SMAC3`
agent only	plain `Autoresearch`
hybrid	`agent + TPE`, `agent + SMAC3`, `agent + TPE+SMAC`
direct	`TPE direct`, `SMAC direct`

12. 관련 문헌

- Using Large Language Models for Hyperparameter Optimization
  - 실험 이력 기반 순차 튜닝은 가능하지만, 장기적으로 BO 우위는 불명확하다.
- LLAMBO: Large Language Models to Enhance Bayesian Optimization
  - LLM은 BO를 대체하기보다 초기 탐색을 강화하는 보조 수단에 가깝다.
- AgentHPO: Large Language Model Agent for Hyper-Parameter Optimization
  - Agent형 LLM HPO는 가능성을 보였지만, BO 대비 성능 우위 근거는 약하다.
- SLLMBO: Sequential Large Language Model-Based Hyper-parameter Optimization
  - Hybrid LLM-BO 방식은 일부 태스크에서 classical BO보다 강하다.

13. Optuna TPE

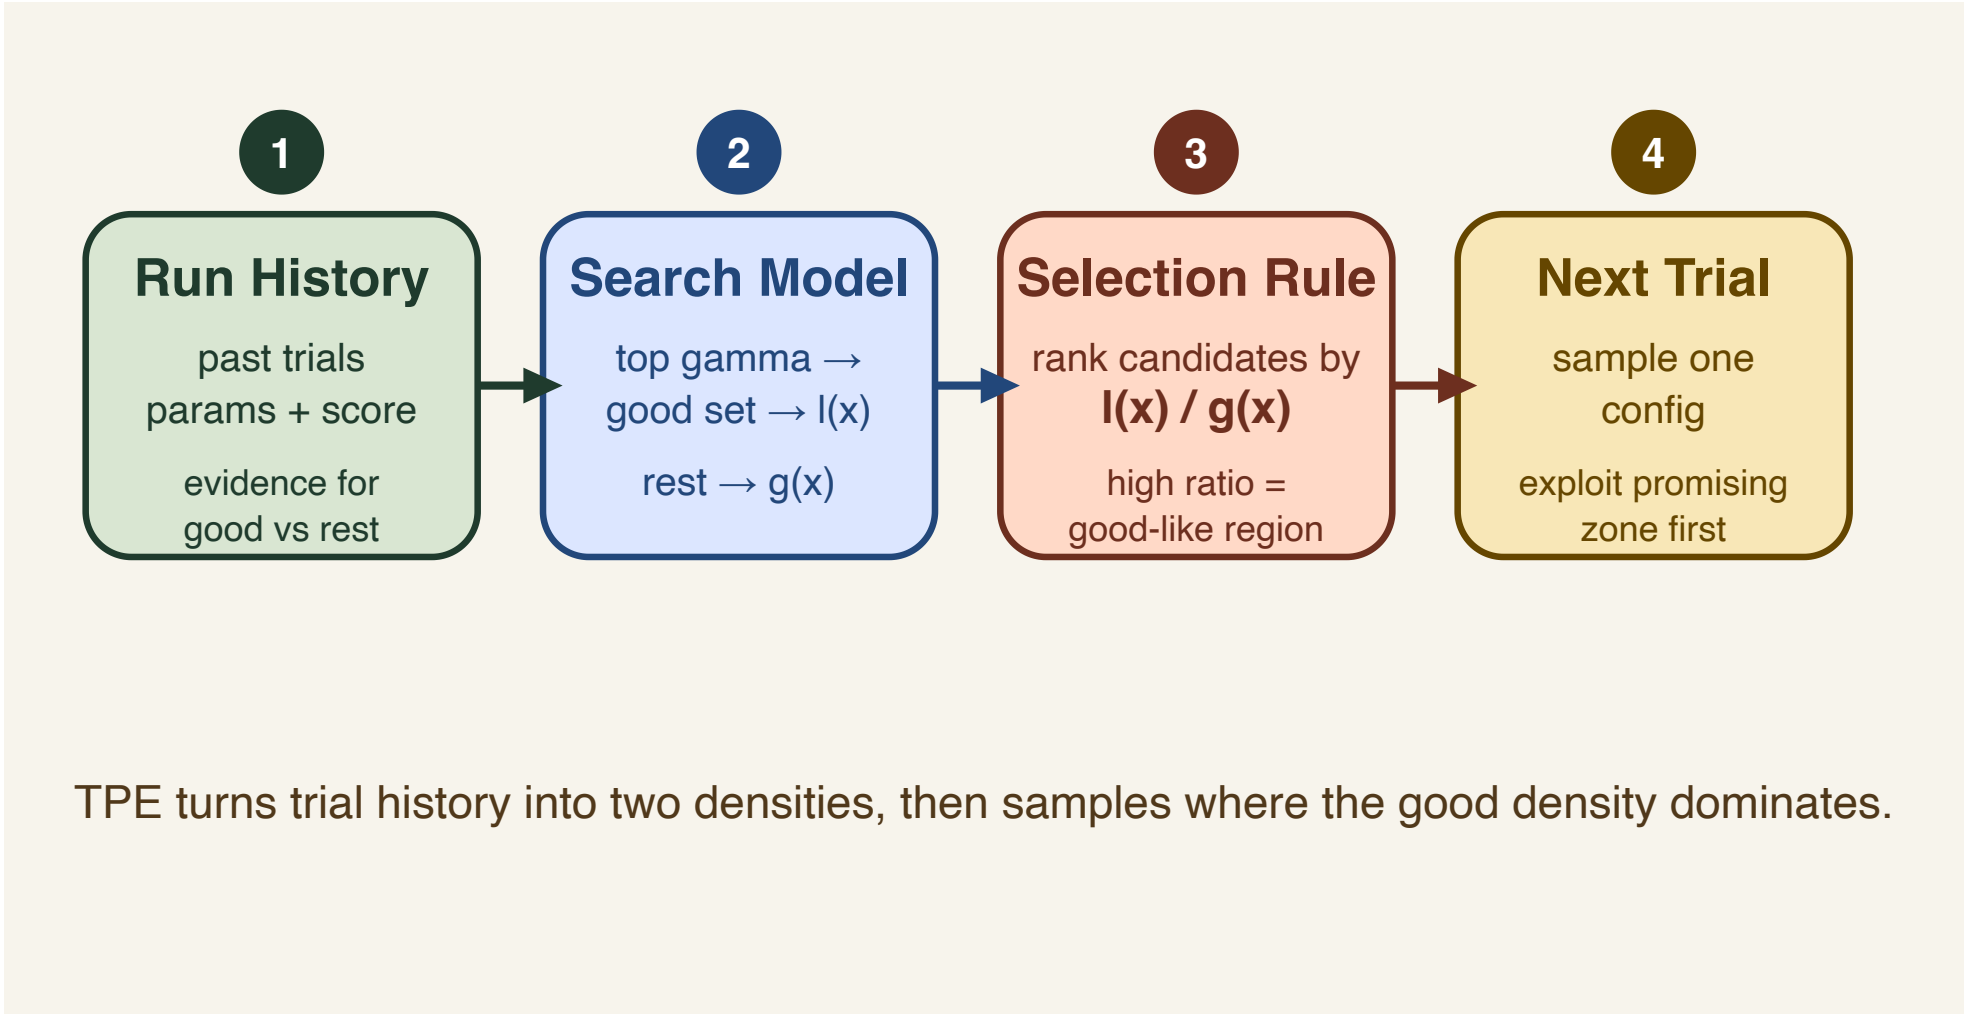

`Run History`

- observed trial을 `good set`과 `rest`로 나눈다

14. SMAC3

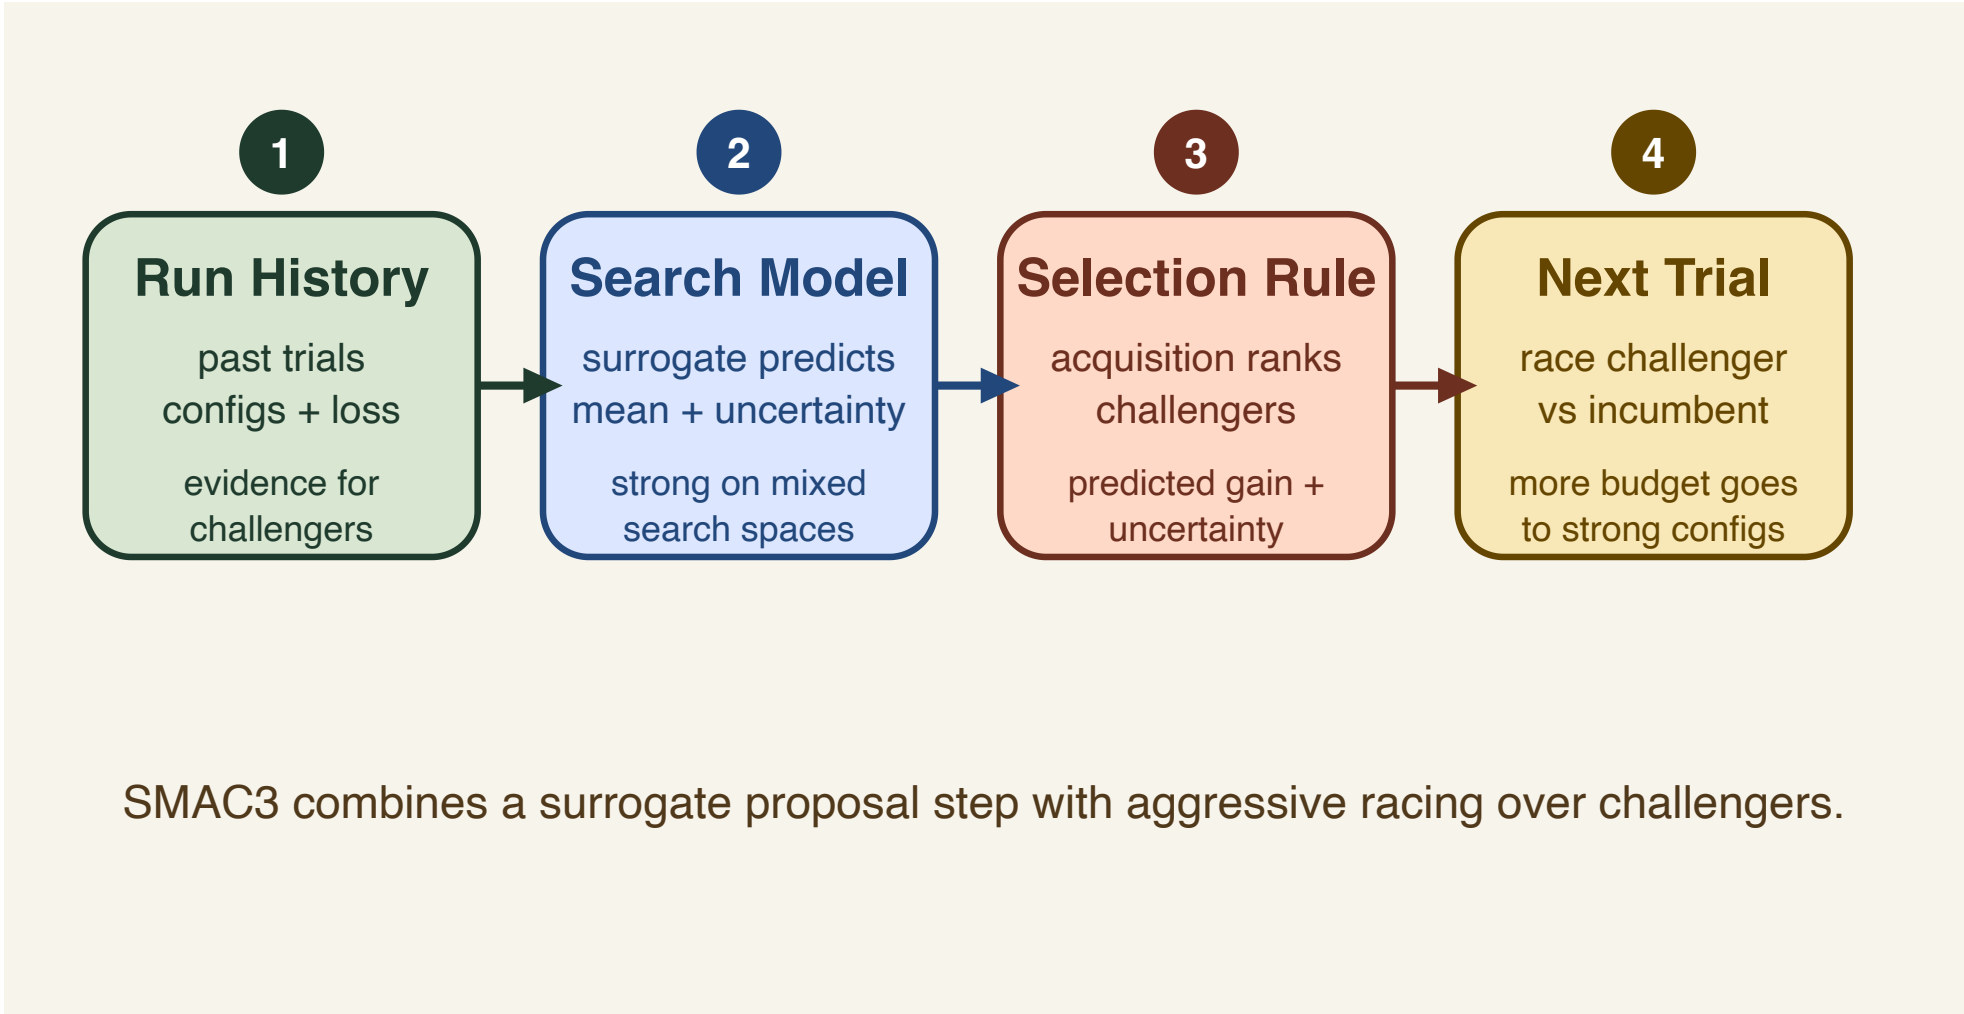

`Run History`

- observed config-loss pair로 surrogate를 학습한다

15. 질문 1 결과

Experiment 1: Dataset Winners
Best validation vs best hidden among 14 isolated conditions per dataset.
1.0
0.8
0.6
0.4
0.2
0.0
0.865
0.853
0.566
0.577
0.992
0.983
0.440
0.392
best val
tie x2
best hidden
tie x4
best val
Rat Plain
best hidden
Rat Plain
best val
Scr Plain
best hidden
Adv T+S
best val
Rat T+S
best hidden
Scr Plain

16. 질문 2 셋업

항목	설정
benchmarks	`fashion`, `twenty`, `spam`, `cifar`
model	`mlp`
conditions	dataset당 `14`
budget	condition당 `100 + finalize 1`

- 각 데이터셋은 fresh isolated root에서 다시 시작했다.
- 각 root 안에서 `14` 개 condition마다 서로 다른 subagent를 띄웠다.
- 이번 질문은 `어떤 harness를 남길 것인가` 다.

17. 실험 설정

항목	설정
subagent isolation	condition별 독립 context
submission width	run당 `1` candidate
duplicate policy	기존과 같은 config 금지
validity gate	`100 runs + finalized 1` 검산

- context mixing과 repeated config를 막기 위해 실행 규칙을 강화했다.
- 첫 `twenty_newsgroups` wave는 contaminated run이라 버리고 clean rerun만 채택했다.

18. 탐색 축

Dataset	best val	best hidden	signal
`fashion`	`advanced_tpe_smac` / `screening_tpe_smac`	`advanced_smac` tier	hybrid peak, `SMAC` finalize
`twenty`	`ratchet_plain`	`ratchet_plain`	plain exploit 승리
`spam`	`screening_plain`	`advanced_tpe_smac`	saturated regime
`cifar`	`ratchet_tpe_smac`	`screening_plain`	peak와 finalize 분리

- 질문 2는 이 차이를 harness 관점에서 읽는 작업이다.

19. 결과 요약

관점	조건	점수
best val	`advanced_tpe_smac`, `screening_tpe_smac`	`0.865`
best hidden	`advanced_smac`, `ratchet_smac`, `screening_smac`, `smac_direct`	`0.853`
reading	peak는 hybrid, finalize는 `SMAC` 계열	

- `fashion_mnist` 에서는 model-based advisor가 late-stage generalization에 유리했다.
- direct `SMAC` 도 top hidden tier에 들어서, agent만의 독점 우위는 아니었다.

20. Twenty 결과

관점	조건	점수
best val	`ratchet_plain`	`0.5658`
best hidden	`ratchet_plain`	`0.5767`
next tier	`advanced_tpe`, `ratchet_tpe`, `screening_tpe`, `tpe_direct`	`0.5458` hidden

- `twenty_newsgroups` 에서는 plain harness가 advisor를 붙인 변형보다 더 좋았다.
- 이 태스크에선 exploit loop 자체가 충분히 강했고, advisor가 추가 이득을 못 만들었다.

21. Spam 결과

관점	조건	점수
best val	`screening_plain`	`0.9916`
best hidden	`advanced_tpe_smac`	`0.9833`
strong hidden tier	`smac_direct`, `advanced_smac`, `ratchet_smac`, `screening_smac`, `ratchet_tpe_smac`	`0.9821`

- `sms_spam` 은 거의 saturate돼서 validation 차이가 매우 작다.
- 이런 regime에선 `best val` 보다 `finalize hidden` 이 harness 판정에 더 중요하다.

22. CIFAR 결과

관점	조건	점수
best val	`ratchet_tpe_smac`	`0.4400`
best hidden	`screening_plain`	`0.3917`
next hidden tier	`advanced_tpe`, `ratchet_tpe`, `screening_tpe`, `tpe_direct`	`0.3900`

- `cifar10` 에선 hybrid가 peak를 끌어올렸지만 finalize winner는 plain이었다.
- 따라서 search trace의 ceiling만 보면 harness를 잘못 고를 수 있다.

23. 공통 패턴

- winner는 dataset마다 달랐다.
- `best val`과 `best hidden`은 `fashion`, `spam`, `cifar`에서 갈렸다.
- hybrid가 ceiling을 높일 때도 있었지만, plain이 finalize를 더 잘하는 경우가 반복됐다.
- direct baseline도 여러 데이터셋에서 top tier에 남아 있었다.

24. Harness 해석

Experiment 2: Hidden-Test Gap By Harness Profile

Cell fill is the gap to the row-best hidden score. Text is the best hidden score reached by that profile.

	Ratchet	Screening	Advanced	Direct
Fashion-MNIST	0.853 Rat SMAC +0.000 vs row best	0.853 Scr SMAC +0.000 vs row best	0.853 Adv SMAC +0.000 vs row best	0.853 SMAC Dir +0.000 vs row best
wenty Newsgroups	0.577 Rat Plain +0.000 vs row best	0.550 Scr Plain -0.027 vs row best	0.551 Adv T+S -0.026 vs row best	0.547 SMAC Dir -0.029 vs row best
SMS Spam	0.982 Rat T+S -0.001 vs row best	0.982 Scr SMAC -0.001 vs row best	0.983 Adv T+S +0.000 vs row best	0.982 SMAC Dir -0.001 vs row best
CIFAR-10	0.390 Rat TPE -0.002 vs row best	0.392 Scr Plain +0.000 vs row best	0.390 Adv TPE -0.002 vs row best	0.390 TPE Dir -0.002 vs row best

lighter = farther from the dataset-best hidden score

25. 운영 교훈

- subagent isolation 없이는 dataset 간 context가 섞인다.
- run당 `1` candidate 제한이 없으면 비교 단위가 흐려진다.
- duplicate guard가 없으면 deterministic eval에서 같은 config를 반복하게 된다.
- artifact count로 검산하지 않으면 early finalize나 invalid wave를 놓친다.

26. 핵심 함의

- harness effect는 advisor effect만큼 컸다.
- validation 최적화와 finalize 최적화는 다른 문제였다.
- dual advisor는 일부 데이터셋에서만 이득이 있었다.
- harness 평가는 `best val`, `best hidden`, completeness를 함께 봐야 한다.

27. 운영 교훈

추천

- default winner 하나를 고정하지 말고 dataset별 shortlist를 운영한다.
- image tabular-like regime에선 hybrid peak를, text/saturated regime에선 plain finalize를 우선 본다.
- rerun 규칙과 contamination discard 기준을 미리 정해 둔다.

28. 한계

- single split, repeated seed 평균 없음
- model family는 `mlp` 하나만 사용했다
- budget은 condition당 `100 + finalize 1` 로 짧다
- code-edit autoresearch와 open-ended research task는 아직 제외했다

29. References

구분	예시
curated landscape	awesome-autoresearch, Awesome Auto Research Tools
end-to-end systems	karpathy/autoresearch, RD-Agent, AI-Scientist
deep research	GPT Researcher
evaluation	MLE-bench, MLAgentBench, MLR-Bench
optimization baselines	Optuna docs, SMAC3 docs
visuals	AutoML image, NAS image, Kubeflow model registry lifecycle image