# AutoML, Autoresearch, MLOps +@

DOE는 Research Agent의 Harness가 될 수 있는가?

배경 정리 + harness 제안

# 1. AutoML이란 무엇인가?

- AutoML은 모델 개발의 탐색 일부를 자동화한다.
- 대표 대상은 `model selection`, `hyperparameter tuning`, `pipeline search` 다.
- 핵심은 비교적 주어진 `search space` 안에서 좋은 설정을 찾는 것이다.

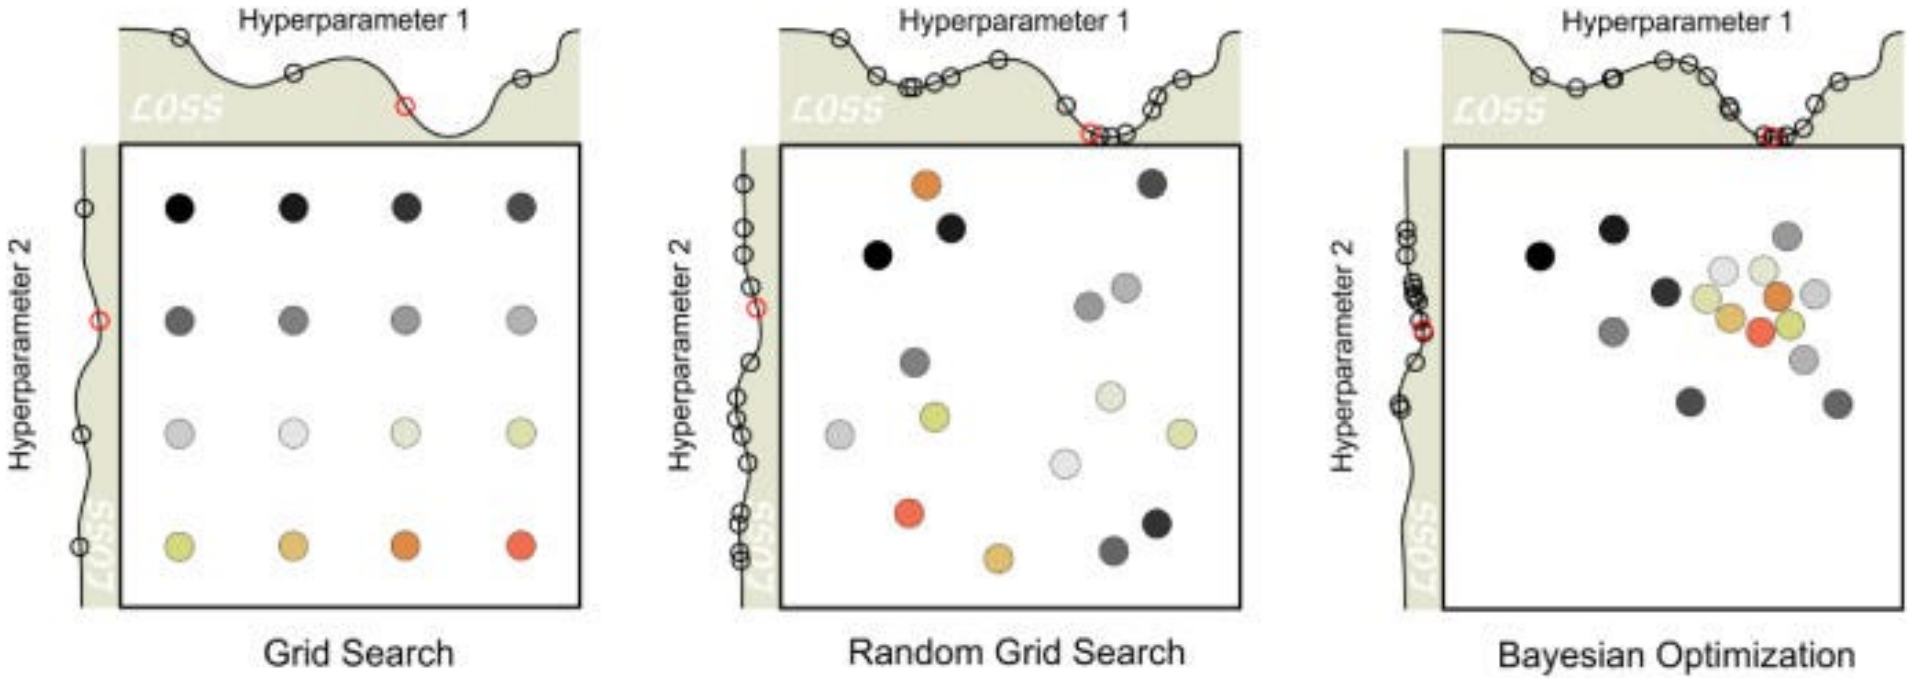


Source image

## 2. `Neural Architecture Search`는 AutoML의 확장이다

- `NAS`는 parameter가 아니라 architecture 자체를 탐색 대상으로 올린다.
- 즉 AutoML은 점점 `더 넓은 search space`를 다루는 방향으로 확장돼 왔다.
- 하지만 여전히 중심은 대체로 `모델/파이프라인 후보 탐색`이었다.

`hyperparameter search → pipeline search → architecture search`

# 3. `Autoresearch`는 어떻게 등장했고 무엇이 다른가?

- karpathy/autoresearch는 작은 training setup 위에서 `read → edit → run → keep-or-revert` loop를 보여줬다.
- Autoresearch는 agent가 연구 workflow 일부를 직접 수행하는 연구 자동화 계열이다.
- 여기서 agent는 설정만 고르는 것이 아니라 `code`, `module`, `experiment` 자체를 건드린다.
- 즉 AutoML이 `주어진 search space`를 최적화했다면, Autoresearch는 `research loop` 쪽으로 탐색 대상을 넓힌다.
- 이후 RD-Agent, AI-Scientist, GPT Researcher처럼 더 넓은 연구 자동화 계열이 빠르게 늘었다.

# 4. 그래서 질문이 바뀐다

| AutoML에서의 질문 | Autoresearch에서의 질문 |
|---|---|
| 어떤 설정이 가장 좋은가? | 다음에 어떤 실험을 해야 하는가? |
| 정해진 공간 안에서 어떻게 최적화할까? | search space 자체를 바꿔도 되는가? |
| 최고 점수는 무엇인가? | 어떤 결과를 믿고 승격할 것인가? |

```
Question → Read → Edit → Run → Analyze → Next experiment
```

# 5. Autoresearch agent의 기본 loop

| 단계 | agent가 하는 일 |
|---|---|
| read | 논문, 코드, 이전 결과를 읽는다 |
| edit | 가설에 맞춰 코드나 설정을 바꾼다 |
| run | 실험을 실행하고 metric을 수집한다 |
| analyze | 결과를 해석하고 다음 실험으로 넘긴다 |

# 6. 사용례와 확장은 함께 커지고 있다

| 현재 보이는 사용례 | 지금 커지는 확장 |
|---|---|
| 문헌 조사 / deep research: GPT Researcher | end-to-end 연구 자동화: AI-Scientist |
| 코드 수정 + 실험 반복: karpathy/autoresearch, RD-Agent | benchmark / evaluation: MLE-bench, MLAgentBench, MLR-Bench |
| 보고서 / 초안 생성 | plugin / skill 생태계: awesome-autoresearch, Awesome Auto Research Tools |
| domain-specific workflow | memory, reusable modules, hardware fork |

# 7. 왜 MLOps가 공통 기반이 되는가?

- AutoML도 Autoresearch도 결국 `많은 run`을 비교하고 누적하는 문제다.
- run 수가 커지면 `tracking`, `lineage`, `orchestration` 없이는 자동화가 지식으로 남지 않는다.
- agent가 코드를 바꾸기 시작하면 `artifact`, `promotion`, `monitoring`, `cost control`이 더 중요해진다.

| MLOps가 없으면 | 생기는 문제 |
|---|---|
| tracking 없음 | 최고 run를 잃는다 |
| lineage 없음 | 왜 좋아졌는지 설명 못 한다 |
| orchestration 없음 | 반복 loop가 수작업으로 돌아간다 |
| monitoring 없음 | 배포 후 feedback이 끊긴다 |

# 8. MLOps는 더 큰 파이프라인을 안정적으로 유지하는 작업이다

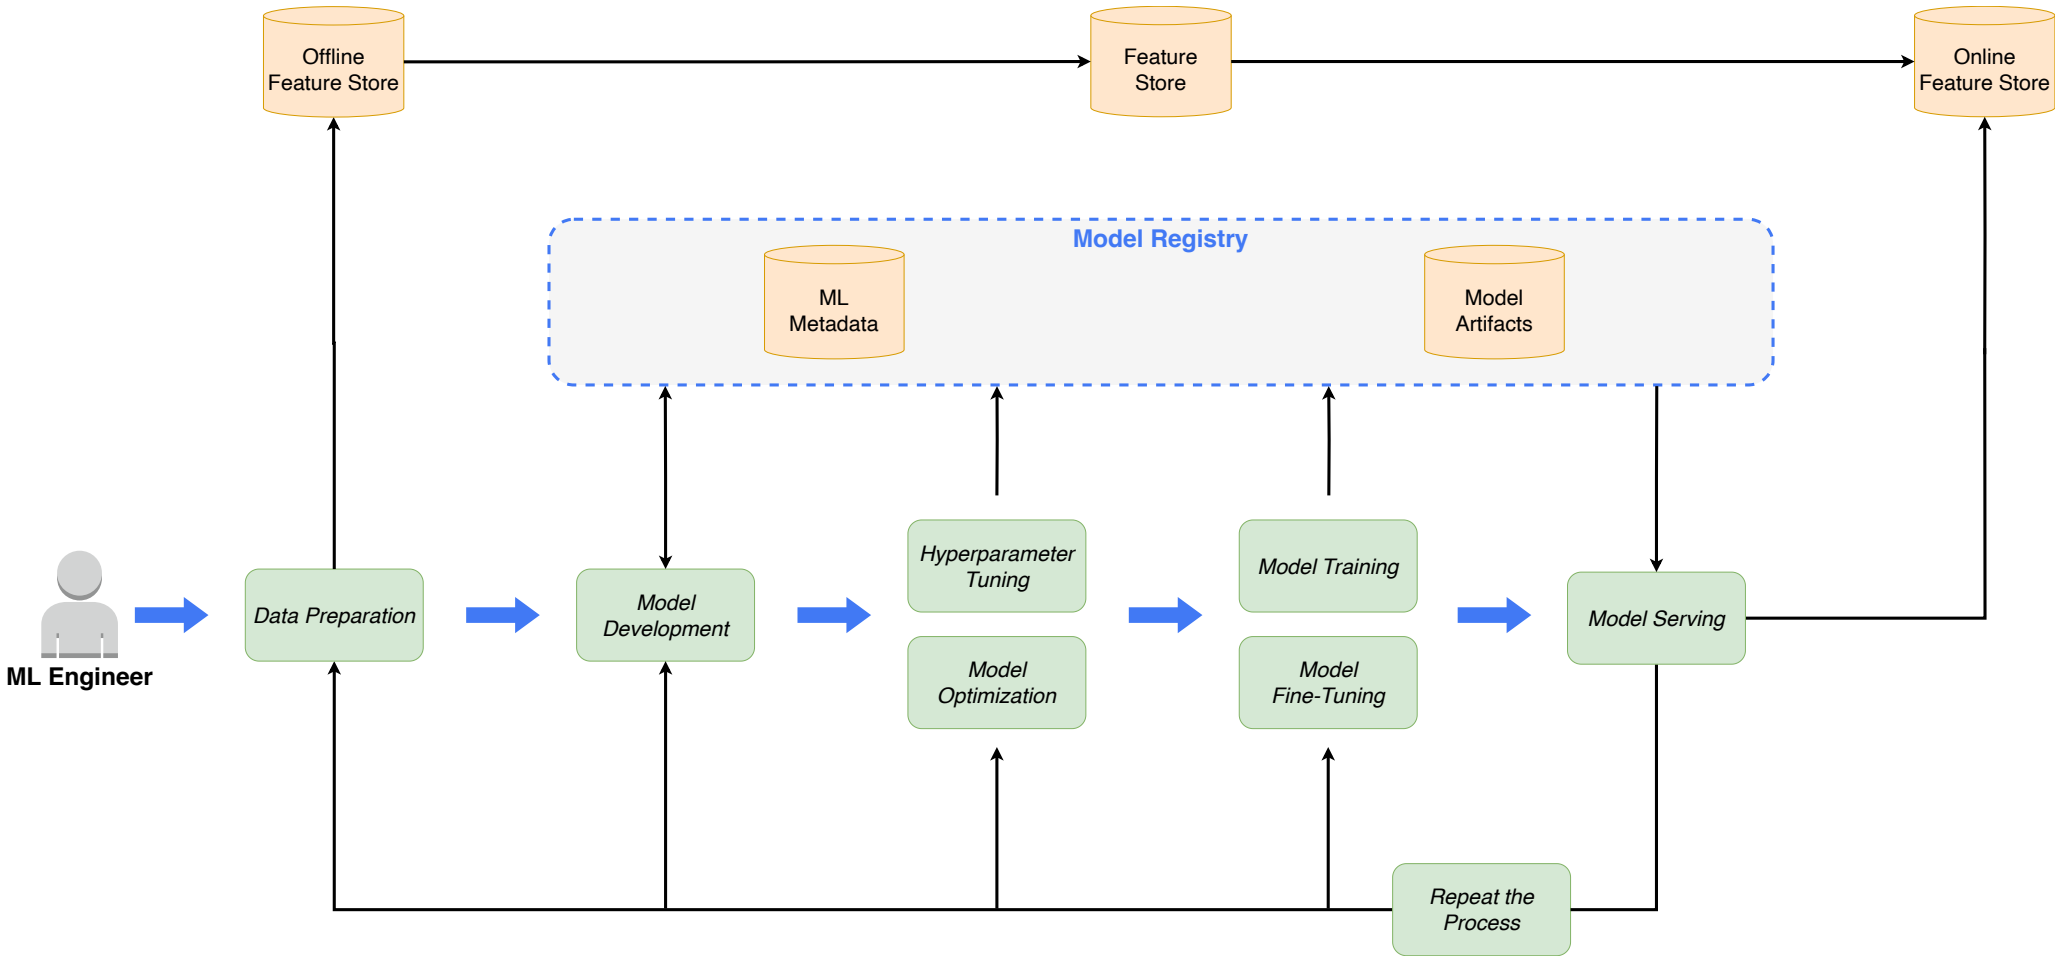


- Autoresearch가 관여하는 loop는 이 큰 ML lifecycle 안의 일부다.

# 9. AutoML과 Autoresearch가 공통으로 요구하는 MLOps 요소

| 요소 | AutoML에서의 역할 | Autoresearch에서의 역할 |
|---|---|---|
| tracking | sweep 비교 | hypothesis / code edit history 비교 |
| orchestration | search job 실행 | agent + eval job 실행 |
| registry / lineage | best model 승격 | experiment / prompt / code provenance 보존 |
| monitoring / cost | retrain trigger, SLO | budget, drift, unsafe promotion guardrail |

# 10. Prelim 정리

배경은 여기까지다.

이제 질문은

`Research Agent에 어떤 harness가 필요한가?`

# 11. Harness gap

| Coding Agent 쪽에서 이미 흔한 것 | Research Agent 쪽에서 아직 약한 것 |
|---|---|
| `TDD` | hypothesis discipline |
| `CI` | factor definition |
| regression test | robustness / replication |
| deploy guardrail | experiment promotion rule |

- 그래서 높은 점수만으로는 좋은 연구 탐색인지 말하기 어렵다.

# 12. DOE를 Harness 후보로 보기

| DOE primitive | Agent loop에서의 역할 |
|---|---|
| screening | 중요한 factor를 초기에 좁힘 |
| factorial thinking | interaction을 구조적으로 확인 |
| sequential refinement | 유망 구간을 단계적으로 세밀화 |
| robustness / confirmation | 우연한 win과 재현 가능한 win을 분리 |

- 즉 DOE는 실험 순서와 비교 규칙을 준다.

# 13. Agent loop에 무엇이 달라지는가?

| 단계 | Vanilla Agent | DOE-guided Agent |
|---|---|---|
| 초기 | idea → edit → run | factor 정의 → screening |
| 중반 | gain 추적 | interaction check |
| 후반 | best-so-far 갱신 | refinement |
| 승격 | high score 채택 | robustness 후 promote |

# 14. 실험 설정

| Variant | 설명 | 비교 목적 |
|---|---|---|
| Vanilla Agent | unconstrained iterative experiments | 기본 baseline |
| DOE Agent | DOE 기반 planning과 staging | harness 효과 측정 |
| DOE + X Agent | DOE + 추가 전략 모듈 | harness와 추가 전략의 결합 효과 |

- 비교 축: `score`, `cost`, `robustness`, `portfolio behavior`

# 15. 결과 요약

실험 후 채움

| Variant | Best score | Avg improvement | Runs | Cost | Robustness pass |
|---|---|---|---|---|---|
| Vanilla | TBD | TBD | TBD | TBD | TBD |
| DOE | TBD | TBD | TBD | TBD | TBD |
| DOE + X | TBD | TBD | TBD | TBD | TBD |

# 16. 성능 향상 추이

- `실험 후 채움`
- `experiment budget` 또는 `run count` 대비 `best-so-far metric`
- 수렴 속도, plateau 형태, sample efficiency 비교

`x-axis = budget / run count`

`y-axis = best-so-far metric`

# 17. 실험 포트폴리오 또는 실패 구조

- `실험 후 채움`
- `Tic / Tac / To` 비율
- 또는 실패 분류
- 또는 `information gain vs. performance gain`

# 18. 왜 DOE-guided Agent는 다를 수 있는가?

- `search space`가 더 구조화된다.
- 중복되거나 정보량이 낮은 실험이 줄어든다.
- 상호작용을 우연히가 아니라 의도적으로 본다.
- robustness 단계가 분리된다.

# 19. 대학원 연구 루프는 더 넓다

- 문헌 조사
- 가설 수립
- 실험 설계
- 구현 및 실행
- 분석과 토론
- 다음 실험 선택

# 20. DOE가 주로 커버하는 구간

| 구간 | DOE의 역할 |
|---|---|
| 강함 | 실험 설계, 비교, refinement, 다음 실험 선택 |
| 부분적 | 구현 및 실행, 결과 분석 |
| 약함 | 문헌 조사, 가설 생성 |

- 즉 DOE는 `research loop` 전체보다 experimentation layer를 강하게 규율한다.

# 21. 한계

- `literature review`나 `hypothesis generation` 자체를 대체하진 못한다.
- open-ended research space는 factorization이 어렵다.
- large-scale training에서는 replication 비용이 크다.
- evaluation harness가 약하면 DOE도 흔들린다.

# 22. 결론

- AutoML에서 Autoresearch로 갈수록 `search space` 는 넓어진다.
- search space가 넓어질수록 더 강한 `harness` 가 필요하다.
- DOE는 Research Agent의 experimentation harness로 매우 유력한 후보다.

> 다음 단계는 더 좋은 agent 자체보다 더 좋은 harness이다.

# 23. References

| 구분 | 예시 |
|---|---|
| curated landscape | awesome-autoresearch, Awesome Auto Research Tools |
| end-to-end systems | karpathy/autoresearch, RD-Agent, AI-Scientist |
| deep research | GPT Researcher |
| evaluation | MLE-bench, MLAgentBench, MLR-Bench |
| visuals | AutoML image, Kubeflow model registry lifecycle image |