AutoML, Autoresearch, MLOps +@

26.4.8

서민교

1. AutoML이란 무엇인가?

- 모델 개발 탐색 일부 자동화
- 대표 대상: `model selection`, `hyperparameter tuning`, `pipeline search`
- 핵심: 비교적 주어진 `search space` 안 최적 설정 탐색

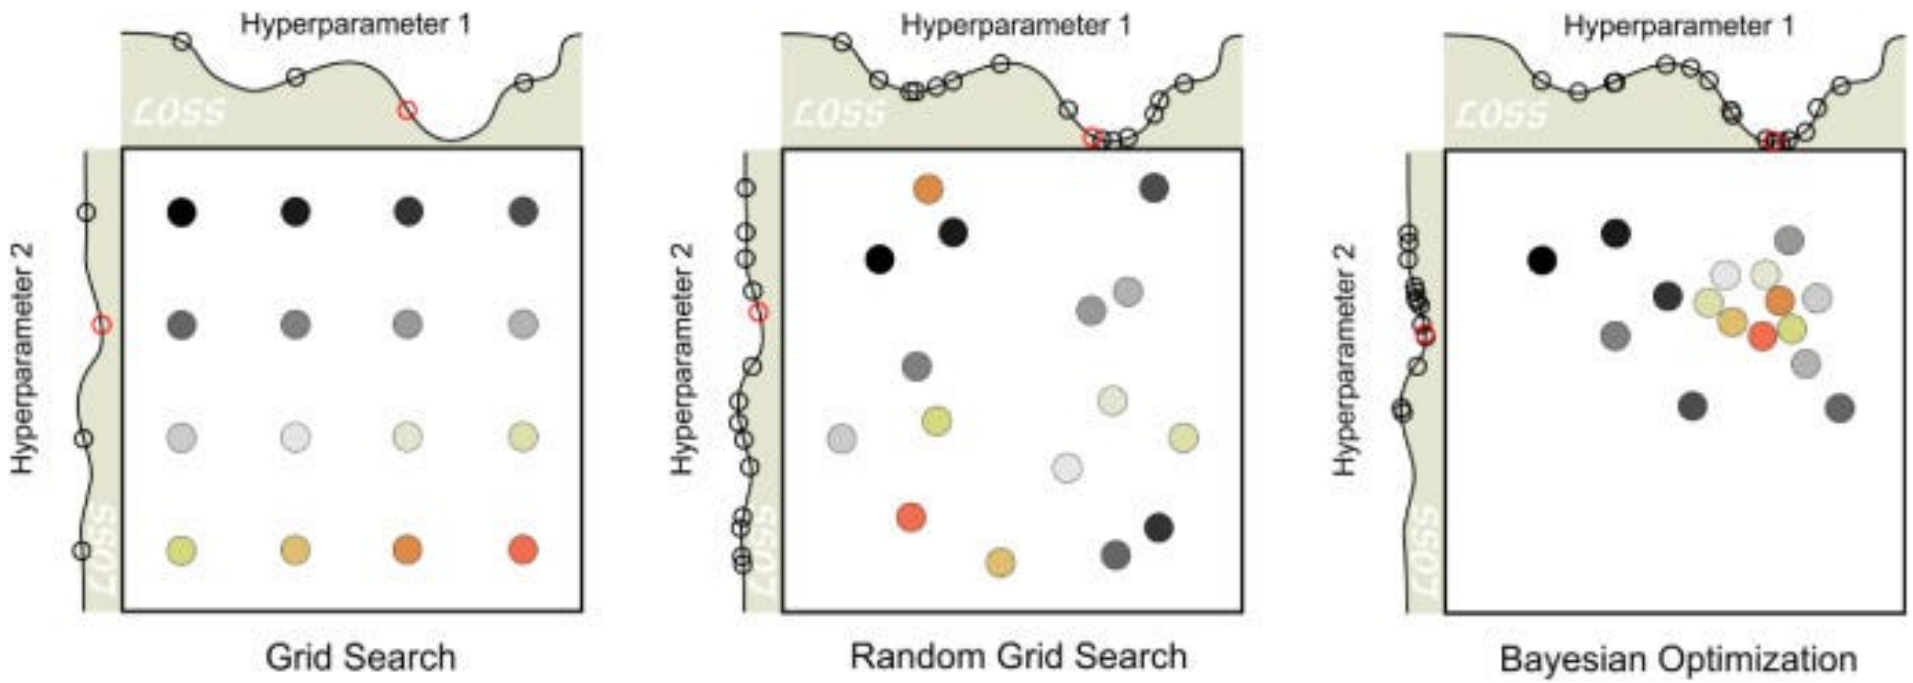

2. `Neural Architecture Search`는 AutoML의 확장이다

- parameter 대신 architecture 탐색
- AutoML의 `더 넓은 search space` 확장선
- 그래도 중심은 여전히 모델/파이프라인 후보 탐색

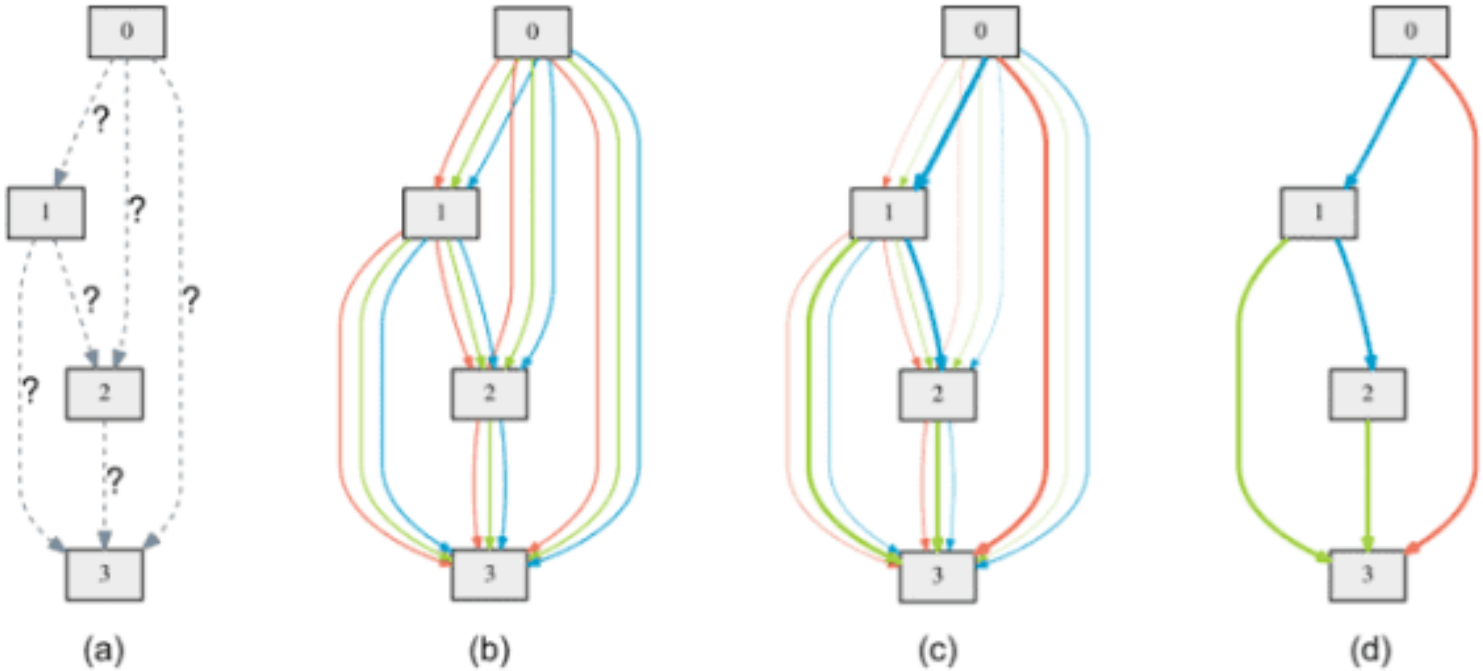

`hyperparameter search → pipeline search → architecture search`

3. `Autoresearch`는 어떻게 등장했고 무엇이 다른가?

- karpathy/autoresearch: 작은 training setup 위 `read → edit → run → keep-or-revert` loop 제시
- 연구 workflow 일부를 agent가 직접 수행하며, 설정 탐색을 넘어 `code`, `module`, `experiment` 자체 수정
- AutoML의 `fixed search space` 바깥으로 확장
- 이후 RD-Agent, AI-Scientist, GPT Researcher 등으로 빠르게 확장

4. Agent 작업 흐름

- 코드 읽기, baseline 파악
- 작은 가설 하나 선택
- 학습 코드나 설정 수정
- 짧은 실험 실행, metric 확인
- 나쁘면 revert, 의미 있으면 keep
- 핵심: `edit 한 번`이 아니라 `짧은 실험 loop의 누적`

```
Question → Read → Edit → Run → Analyze → Next experiment
```

5. AutoML vs. Autoresearch

항목	AutoML	Autoresearch
탐색 대상	config, pipeline, architecture	hypothesis, code, module, experiment
핵심 질문	어떤 설정이 가장 좋은가	다음에 어떤 실험을 해야 하는가
edit 단위	parameter / architecture	code / module / pipeline / experiment
평가 방식	objective 중심	objective + reasoning + iteration
위험	비효율적 탐색	incoherent search, metric hacking
필요한 인프라	experiment infra	experiment + memory + harness

6. 사용례와 확장

사용례

- 문헌 조사 / deep research: GPT Researcher
- 코드 수정 + 실험 반복: karpathy/autoresearch, RD-Agent
- end-to-end 연구 자동화: AI-Scientist

확장

- benchmark / evaluation: MLE-bench, MLAgentBench, MLR-Bench
- plugin / skill 생태계: awesome-autoresearch, Awesome Auto Research Tools
- memory, reusable modules, hardware fork

7. 체계적인 실험 관리의 필요

- 공통 문제: `많은 run` 비교와 누적
- 필수 요소: `tracking`, `lineage`, `orchestration`
- agent edit가 들어오면 `artifact`, `promotion`, `monitoring`, `cost control` 중요도 상승
- 결국 운영 문제

8. AutoML과 Autoresearch가 공통으로 요구하는 MLOps 요소

요소	AutoML에서의 역할	Autoresearch에서의 역할
tracking	sweep 비교	hypothesis / code edit history 비교
orchestration	search job 실행	agent + eval job 실행
registry / lineage	best model 승격	experiment / prompt / code provenance 보존
monitoring / cost	retrain trigger, SLO	budget, drift, unsafe promotion guardrail

9. MLOps는 모델 개발, 관리, 배포 파이프라인을 유지 관리하는 작업이다

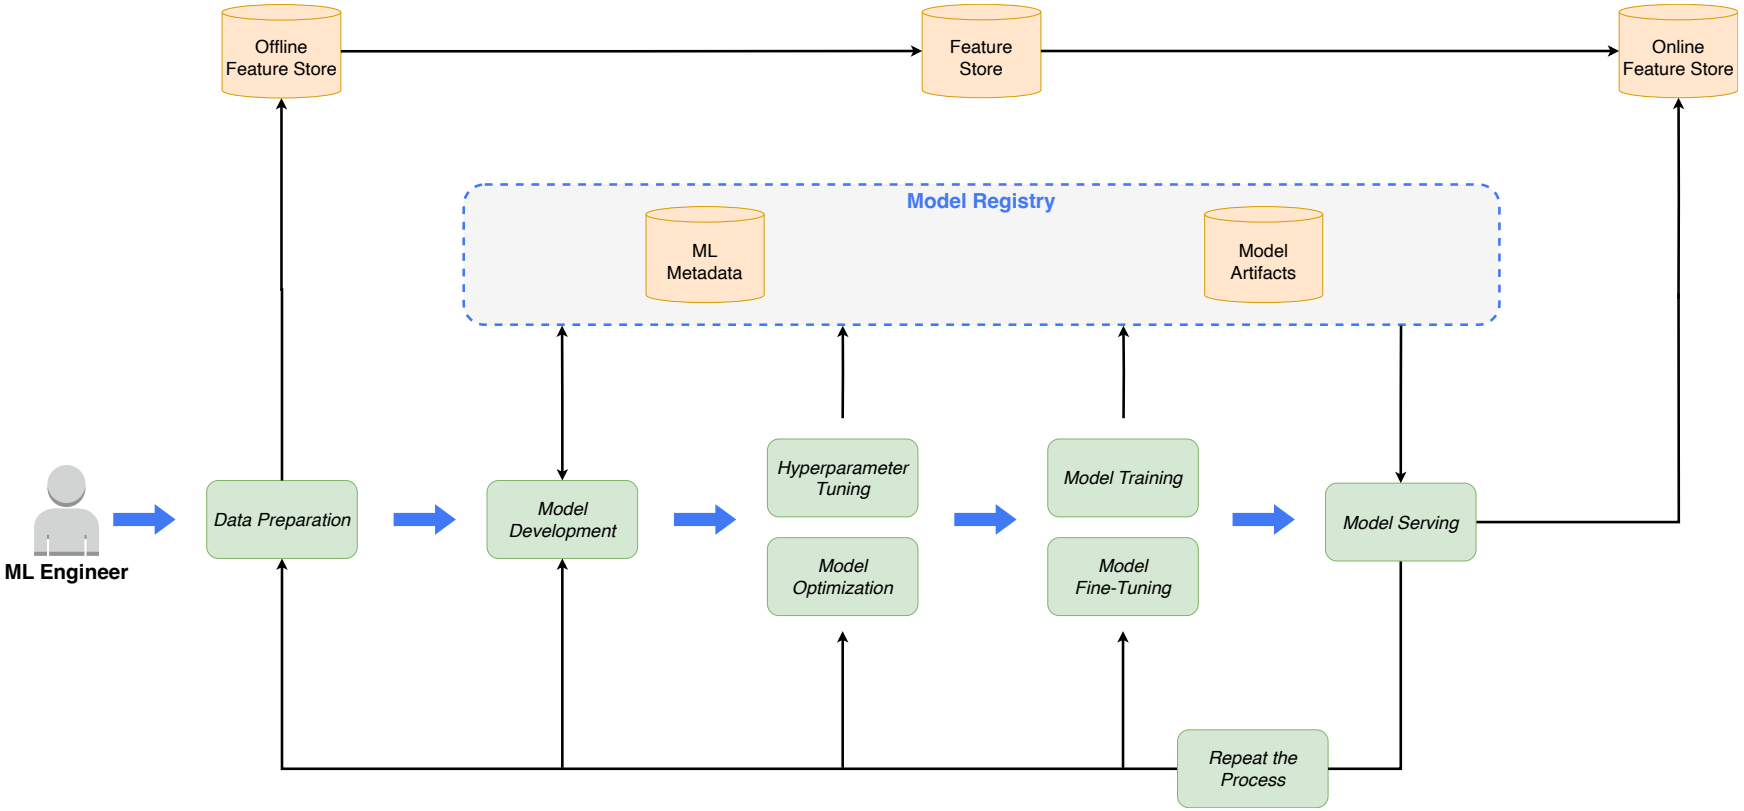

- Autoresearch loop는 이 큰 ML lifecycle 안의 일부
- 실제 시스템: `data`, `experiment`, `model registry`, `deployment`, `monitoring`
- 핵심 역할: `지속 운영`, `추적`, `승격`, `유지관리`

10. Autoresearch의 단점

- 실험이 즉흥적으로 이어지기 쉬움
- 왜 이 실험을 했는지 attribution이 약함
- 큰 수정, 작은 튜닝, 검증 실험이 섞이기 쉬움
- robustness, replication, interaction 확인이 뒤로 밀림
- 잘 정리된 random search로 퇴화할 위험

11. 어떤 Harness가 필요한가

- 무엇을 먼저 볼지 정하는 우선순위
- 어떤 조합을 함께 볼지 정하는 규율
- 탐색 단계와 검증 단계 분리
- 작은 수정과 큰 수정을 다르게 다루는 운영 규칙
- 실패도 정보로 남기는 구조
- 다음 라운드를 설계하는 순차 실험 체계

12. Design of Experiments(DoE)란 무엇인가

- 여러 요인을 한 번에 바꿔 보며 effect를 읽는 실험 설계
- 한 번의 최고점보다 `요인`, `상호작용`, `안정성` 파악에 강점
- 핵심 질문: 무엇을 바꿨고, 무엇이 실제로 영향을 줬는가

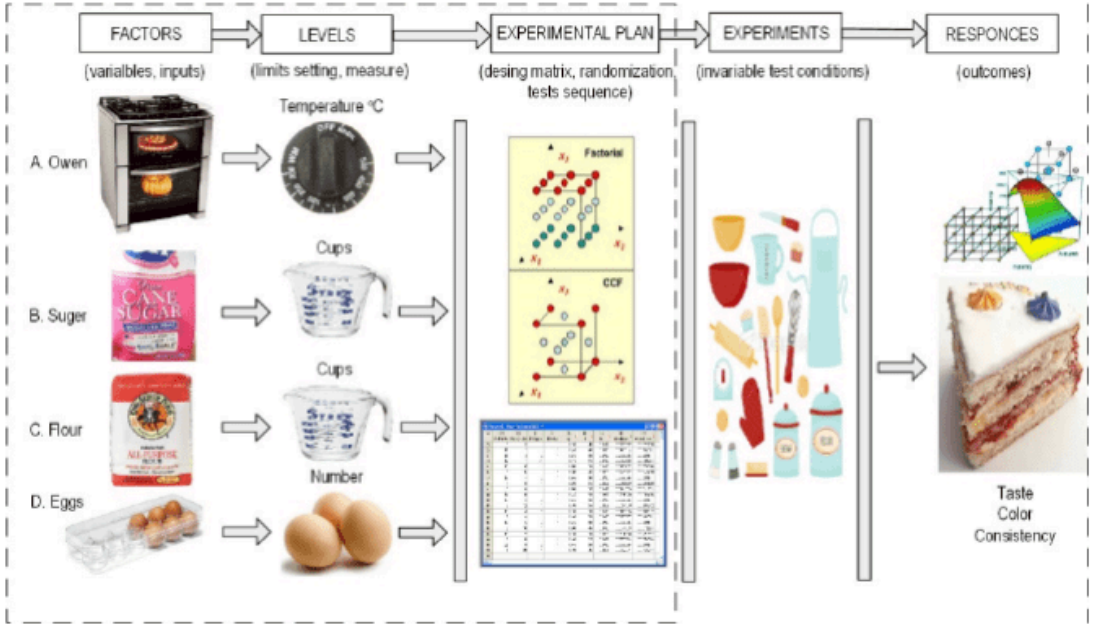

13. DoE에서 빌려오는 개념

- `screening` : 중요한 요인부터 좁히기
- `factorial thinking` : interaction 보기
- `sequential design` : 라운드별 정교화
- `robust design` : 평균이 아니라 안정성까지 확인
- `mixture / allocation` : 예산과 비율 배분

14. DoE-guided 운영과 비교한 Agents

Agent	운영 방식	특징
`01 Ratchet`	local ratchet loop	incumbent를 branch head로 두고 좁게 mutation
`02 Screening DoE`	simple screening	round마다 한 design question만 분리해 main effect를 읽음
`03 Advanced DoE`	staged DoE program	screening → interaction check → local refinement

15. 실험 설정

항목	설정
benchmarks	`cifar10_real`, `twenty_newsgroups_real`
data budget	CIFAR-10 `4k`, 20 Newsgroups `8k`
model	`mlp`
agents	`01 Ratchet`, `02 Screening DoE`, `03 Advanced DoE`
execution	dataset × agent isolated root `6`, validation-only `250` runs

실행 메모

- root별 독립 실행 + subagent 분리, 최신 `program.md` 와 refactored runner 기준
- 이번 비교는 전처리·MLP 구조·최적화 축을 보는 bounded `AutoML` test이며, `AutoAgent` 처럼 코드 전체를 다루는 실험은 아니다

탐색 축

- preprocessing: `normalization`, `outlier`, `projection`, `resampling`
- architecture: `hidden_dims`, `activation`, `normalization_layer`
- optimization: `solver`, `learning_rate`, `batch_size`, `max_iter`
- regularization / stability: `weight_decay`, `dropout`, `noise`, `label_smoothing`,

16. CIFAR-10 결과: validation 탐색

조건: `cifar10_real` / `mlp` / `program.md` batch / validation `250` runs

Agent	Best Val	Run of Best	Gain vs Run1	Incumbent Updates	Plateau Tail
`01 Ratchet`	`0.4350`	`29`	`+0.0867`	`7`	`221`
`02 Screening DoE`	`0.4283`	`52`	`+0.0400`	`6`	`198`
`03 Advanced DoE`	`0.4267`	`94`	`+0.0683`	`12`	`156`

대표 incumbent

- `01 Ratchet`: `standard + clip_iqr + [128,64] + elu + adamw + wd=1e-4 + lr=1e-4 + bs=64`
- `02 Screening DoE`: `standard + clip_percentile + [128,64] + gelu + adam + wd=2.5e-3 + lr=1e-4 + bs=64`
- `03 Advanced DoE`: `standard + clip_iqr + [128,64] + gelu + adam + wd=2.5e-3 + lr=1e-4 + bs=64`

17. CIFAR-10 결과: 탐색 궤적

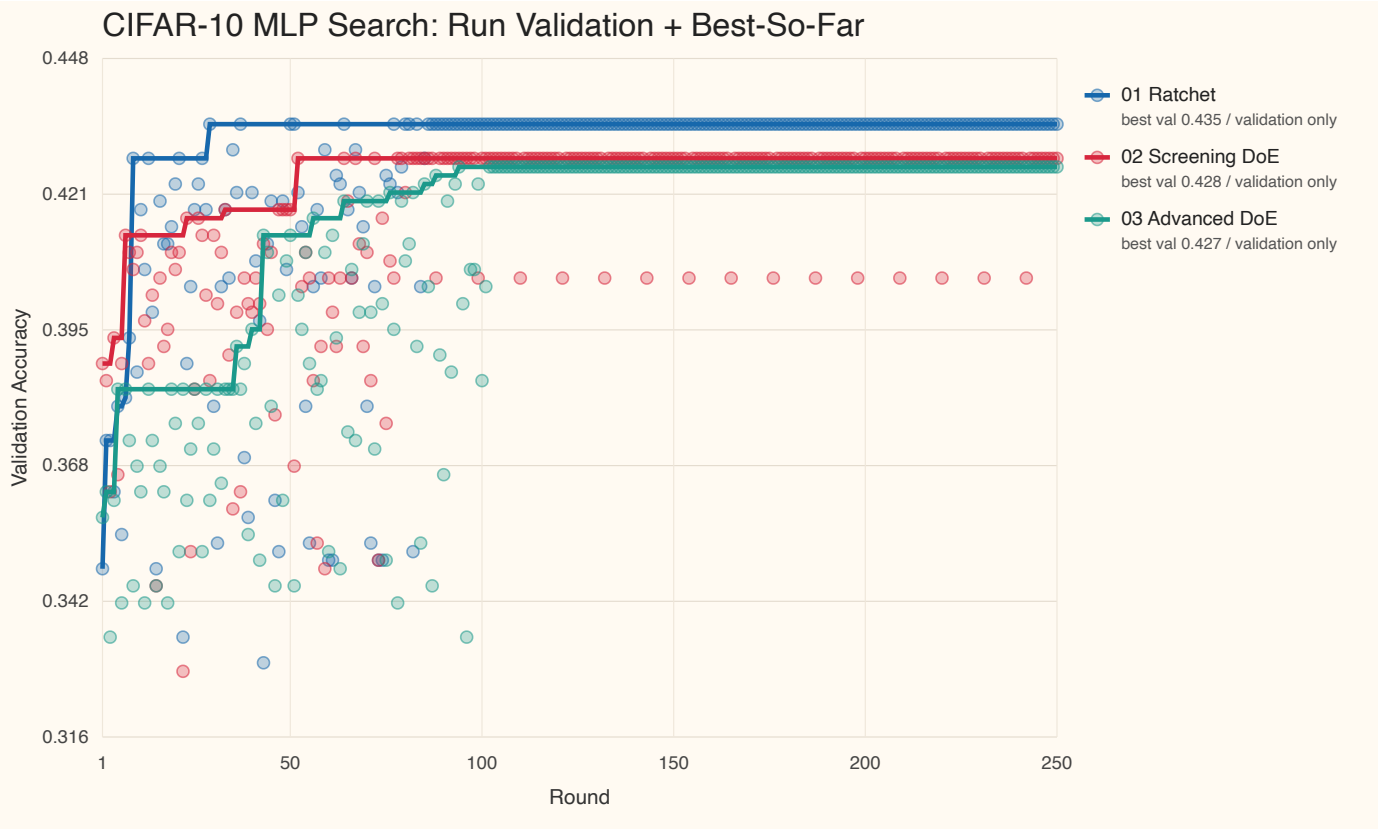

- `Ratchet` 이 가장 높은 ceiling을 만들었다.
- `Screening DoE` 는 중반까지 꾸준히 오르지만 최종 최고점은 낮다.
- `Advanced DoE` 는 가장 늦게 best를 갱신했지만, `run 94` 이후 추가 이득은 없었다.

18. CIFAR-10 해석

- CIFAR에선 `Ratchet`이 가장 높은 최고점을 냈다.
- `Advanced DoE`는 최고점은 약간 낮지만 가장 긴 탐색 수명을 보였다.
- 추가 `150` runs가 새 best를 만들지는 못했다.

19. 20 Newsgroups 결과: validation 탐색

조건: `twenty_newsgroups_real` / `mlp` / `program.md` batch / validation `250` runs

Agent	Best Val	Run of Best	Gain vs Run1	Incumbent Updates	Plateau Tail
`01 Ratchet`	`0.5508`	`43`	`+0.0367`	`10`	`207`
`02 Screening DoE`	`0.5500`	`30`	`+0.0358`	`5`	`220`
`03 Advanced DoE`	`0.5642`	`81`	`+0.0875`	`15`	`169`

대표 incumbent

- `01 Ratchet`: `maxabs + [64,32] + leaky_relu + adamw + wd=5e-4 + lr=1e-4 + bs=32`
- `02 Screening DoE`: `standard + [128,64] + tanh + adamw + wd=1e-3 + lr=1e-3 + bs=64`
- `03 Advanced DoE`: `robust + [128,64] + relu + adamw + wd=0 + lr=1e-4 + bs=64`

20. 20 Newsgroups 결과: 탐색 궤적

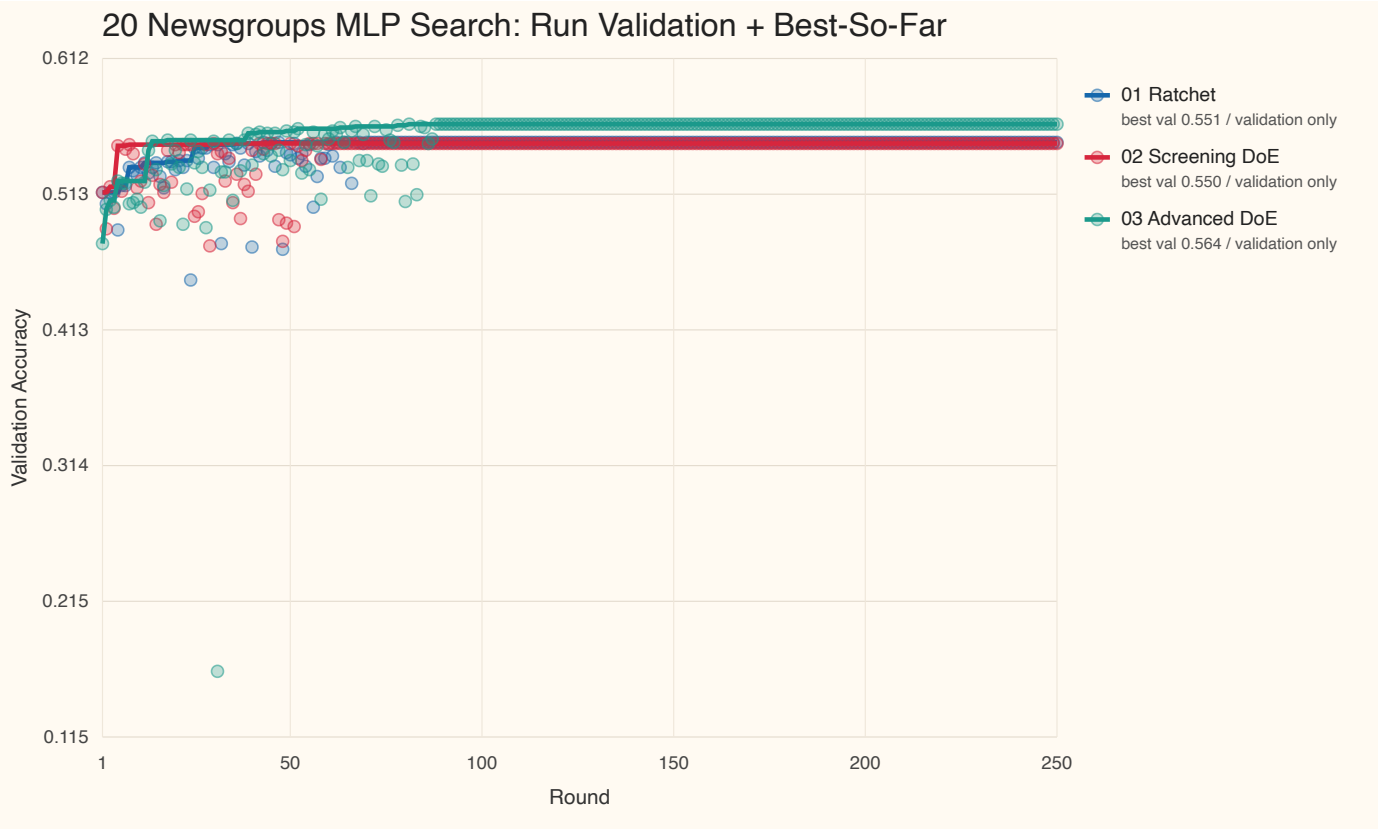

- text에선 `Advanced DoE` 가 후반까지 꾸준히 incumbent를 갱신했다.
- `Ratchet` 도 중반까지는 강했지만 late gain은 작았다.
- `Screening DoE` 는 초반 screen 이후 매우 긴 plateau로 들어갔다.

21. 20 Newsgroups 해석

- text에선 `Advanced DoE`가 가장 높은 최고점과 가장 많은 incumbent update를 만들었다.
- `Ratchet`은 strong local search로는 충분했지만 late exploration은 약했다.
- `Screening DoE`는 초반 우선순위화에는 유용했지만 full-budget owner로는 약했다.
- 여기서도 추가 `150` runs는 기존 best를 뒤집지 못했다.

22. 히스토리에서 남는 지식

`01 Ratchet`

- 강한 incumbent가 보이면 빠르게 붙잡는다.
- local exploit에는 강하지만 late reset 효율은 낮다.

`02 Screening DoE`

- factor 우선순위화에는 유용하다.
- screening 이후 refine로 못 넘어가면 plateau가 길어진다.

`03 Advanced DoE`

- staged search가 실제 candidate diversity로 이어질 수 있었다.
- 특히 text에서 late-stage refinement 효과가 가장 컸다.

23. 히스토리 진단

Agent	CIFAR trace	Text trace	읽을 점
`Ratchet`	best `run 29`, updates `7`	best `run 43`, updates `10`	local ratchet은 유지됐지만 late jump는 약함
`Screening DoE`	best `run 52`, updates `6`	best `run 30`, updates `5`	one-factor screen은 있으나 refine 전환이 약함
`Advanced DoE`	best `run 94`, updates `12`	best `run 81`, updates `15`	staged program이 실제 late improvement로 연결됨

- 이번 batch에선 세 전략 차이가 실제 trace에 남았다.
- 다만 `250`까지 늘려도 모든 최고점은 `100` 이전에 이미 결정됐다.

24. 요약

- CIFAR best: `01 Ratchet`, `val 0.4350`
- Text best: `03 Advanced DoE`, `val 0.5642`
- `Screening DoE`는 front-end screening으로는 유효했지만 full-budget owner로는 약했다.
- 이번 `250-run` batch는 전략 차이를 보여주되, 추가 예산의 한계도 같이 보여준다.

25. 한계

- 이번 정리는 validation-only batch다. hidden finalize는 아직 안 했다.
- single split 기준이라 분산 추정이 약하다.
- fixed subset 위 실험이라 전체 분포 대표성은 제한적이다.
- text는 fixed TF-IDF representation 위 실험이다.
- `program.md` 차이를 더 강하게 보려면 multi-seed confirmation이나 hidden test까지 이어야 한다.

26. References

구분	예시
curated landscape	awesome-autoresearch, Awesome Auto Research Tools
end-to-end systems	karpathy/autoresearch, RD-Agent, AI-Scientist
deep research	GPT Researcher
evaluation	MLE-bench, MLAgentBench, MLR-Bench
visuals	AutoML image, NAS image, Kubeflow model registry lifecycle image