AutoML에서 Autoresearch로

DOE는 Research Agent의 Harness가 될 수 있는가?

AutoML, Autoresearch, MLOps, DOE-guided Agent

실험 결과 영역은 이후 채움

1. 왜 지금 이 주제인가?

- Coding Agent는 실제 개발 workflow 안에서 빠르게 발전하고 있다.
- Research automation도 문헌 정리, 코드 수정, 실험 실행, 보고서 작성까지 넓어지고 있다.
- 하지만 연구 실험은 여전히 ad hoc 반복으로 흐르기 쉽다.
- 이제 질문은 "agent가 실험을 돌릴 수 있는가?"보다 "무슨 harness가 agent를 더 신뢰 가능하게 만드는가?"이다.

지금 보이는 변화	아직 약한 부분
Coding Agent의 실제 배포	research loop의 규율
실험 자동화 도구 증가	실험 설계 표준
end-to-end research demo 확산	robustness / reproducibility

2. AutoML이란 무엇인가?

- AutoML은 모델 개발 과정의 일부 탐색을 자동화한다.
- 대표 대상은 `model selection`, `hyperparameter tuning`, `pipeline search`다.
- 더 넓게는 `feature engineering`과 `NAS`까지 확장된다.
- 핵심은 비교적 주어진 `search space` 안에서 성능을 최적화하는 것이다.

```
Data → Search over models/pipelines → Evaluation → Best configuration
```

3. Autoresearch란 무엇인가?

- Autoresearch는 단순한 `hyperparameter search`를 넘는다.
- `code`, `module`, `pipeline structure`, `experiment program`까지 수정할 수 있다.
- `tool use`, `memory`, `literature`, `iterative reasoning`을 함께 사용할 수 있다.
- 따라서 `search space`는 AutoML보다 넓고, 덜 정돈되어 있으며, 더 open-ended하다.

AutoML	Autoresearch
config / architecture 중심	hypothesis / code / module / pipeline
explicit objective 최적화	objective + reasoning + iteration

4. 자동화를 가능하게 하는 공통 기반: MLOps

- AutoML이든 Autoresearch든 자동화를 반복 가능하게 만들려면 실행 인프라가 필요하다.
- `experiment tracking`, `orchestration`, `reproducibility`가 있어야 탐색이 지식으로 남는다.
- `artifact 관리`, `registry`, `monitoring`, `cost governance`가 있어야 자동화가 운영 가능해진다.
- 즉 `MLOps`는 AutoML의 뒤처리가 아니라, 둘 다를 떠받치는 공통 substrate에 가깝다.

공통 인프라	AutoML에서의 역할	Autoresearch에서의 역할
tracking	후보 비교	실험 history 축적
orchestration	search job 실행	multi-step agent loop 실행
reproducibility	재실행 / 검증	hypothesis와 edit 검증
cost governance	budget control	long-horizon research budget 관리

5. Autoresearch 현황

현재 공개 생태계는 이미 `단일 demo` 보다 `layered ecosystem` 쪽으로 분화되고 있다.

보이는 층	현재 공개 생태계에서 관찰되는 묶음
end-to-end systems	topic → experiment → paper 자동화
deep research	literature search, synthesis, citation report
experiment/code agents	코드 수정, 실행, 평가 자동화
skills / plugins	반복 가능한 research workflow 모듈화
benchmarks	`MLE-bench`, `MLAgentBench`, `MLR-Bench` 등 평가 체계
hardware / infra ports	consumer GPU, WebGPU, swarm, persistent memory

- 즉 현재의 흐름은 "하나의 강한 agent"보다 "생태계 + 실행 인프라 + benchmark + reusable skill" 쪽으로 이동 중이다.

Source: curated autoresearch repos, accessed 2026-04-07

6. 현재 보이는 사용례

연구 작업	이미 자동화되는 형태
문헌 조사	논문 검색, 요약, citation 포함 report 생성
idea exploration	novelty check, idea refinement, proposal structuring
paper-to-code	논문 구현, baseline reproduction, Kaggle/quant task automation
experiment execution	코드 수정, run, metric 비교, keep-or-revert loop
결과 해석	failure analysis, robustness check, 비교 요약
글쓰기 보조	manuscript draft, figure/diagram 제작, reviewer response 초안

- 즉 "연구 자동화"는 이미 단일 단계가 아니라 정보 수집부터 실험, 보고서까지 여러 단계에 걸쳐 나타난다.

사용례는 curated repo들에 등장하는 실제 task 유형을 요약한 것이다.

7. 지금 보이는 발전 방향

방향	의미
end-to-end 통합	topic에서 paper까지 한 loop로 묶으려는 시도
Coding Agent와 결합	experiment 실행층을 coding agent가 담당
reusable skills / plugins	domain별 workflow를 재사용 가능한 모듈로 분리
benchmark 강화	성능뿐 아니라 robustness와 open-endedness 평가
infra diversification	single GPU, consumer desktop, WebGPU, swarm 실행
persistent memory / portfolio	실험 기록을 장기 지식과 탐색 정책으로 재사용

- 다시 말해 Autoresearch는 "한 번의 인상적인 demo"에서 "programmable research stack"으로 이동 중이다.

8. AutoML vs. Autoresearch

항목	AutoML	Autoresearch
탐색 대상	config, architecture	hypothesis, code, module, pipeline, experiment program
평가	explicit objective	objective + reasoning + iteration
인간 역할	search space 설계	research program 설계
주요 위험	비효율적 탐색	metric hacking, incoherent search
필요한 인프라	experiment infra	experiment + memory + harness

9. Harness gap

Coding Agent 쪽에서 이미 흔한 것	Research Agent 쪽에서 아직 약한 것
`TDD`	hypothesis discipline
`CI`	factor definition
regression test	robustness check
lint / build check	reproducible iteration structure
deploy guardrail	experiment promotion rule

- 그래서 Research Agent는 점수가 좋아 보여도 그 탐색이 coherent했는지 설명하기 어렵다.

10. DOE를 Harness 후보로 보기

DOE primitive	Agent loop에서의 역할
screening	중요한 factor를 초기에 좁힘
factorial thinking	interaction을 구조적으로 확인
sequential refinement	유망 구간을 단계적으로 세밀화
robustness / confirmation	우연한 win과 재현 가능한 win을 분리

- 따라서 DOE는 "무엇을, 어떤 순서로, 어떤 조합으로 실험할지"에 대한 규율을 제공한다.

11. Agent loop에 무엇이 달라지는가?

단계	Vanilla Agent	DOE-guided Agent
시작	idea 생성	factor 정의
초반	code change 후 바로 run	screening으로 후보 압축
중반	gain이 나면 계속 추적	interaction check
후반	best-so-far 갱신 중심	refinement + robustness
종료	score가 높으면 채택	promote rule로 승격

12. 실험 설정

Variant	설명	비교 목적
Vanilla Agent	unconstrained iterative experiments	기본 baseline
DOE Agent	DOE 기반 planning과 staging	harness 효과 측정
DOE + X Agent	DOE + 추가 전략 모듈	harness와 추가 전략의 결합 효과

- 평가는 `best score` 만이 아니라 `cost`, `robustness`, `portfolio behavior` 까지 함께 본다.

13. 결과 요약

- Placeholder only: 실험 완료 후 채움

Variant	Best score	Avg improvement	Runs	Cost	Robustness pass
Vanilla	TBD	TBD	TBD	TBD	TBD
DOE	TBD	TBD	TBD	TBD	TBD
DOE + X	TBD	TBD	TBD	TBD	TBD

14. 성능 향상 추이

- Placeholder only: 실험 완료 후 채움
- `experiment budget` 또는 `run count` 대비 `best-so-far metric`
- 수렴 속도, plateau 형태, sample efficiency 비교

`x-axis = budget / run count`

`y-axis = best-so-far metric`

15. 실험 포트폴리오 또는 실패 구조

- Placeholder only: 실험 완료 후 채움
- Option A: `Tic / Tac / To` 비율
- Option B: `invalid / no gain / unstable / robustness fail / promoted`
- Option C: `information gain vs. performance gain`

16. 왜 DOE-guided Agent는 다를 수 있는가?

- `search space`가 더 구조화된다.
- 중복되거나 정보량이 낮은 실험이 줄어든다.
- 상호작용을 우연히가 아니라 의도적으로 본다.
- opportunistic improvement와 robustness 확인을 분리할 수 있다.
- experiment history가 재사용 가능한 지식으로 축적된다.

17. 대학원 연구 루프와 DOE의 범위

연구 루프 단계	DOE가 직접 다루는 정도
문헌 조사	약함
가설 수립	약함
실험 설계	강함
구현 및 실행	중간, 인프라 필요
분석	중간
토론 및 수정	간접적
다음 실험 선택	강함

- 즉 DOE는 `research loop` 전체를 대체하기보다, 그중에서도 `experiment design / comparison / refinement`를 강하게 규율하는 도구에 가깝다.

문헌 조사, 가설 수립 같은 단계는 DOE의 바깥 또는 상위 층에 더 가깝다.

18. 한계

- DOE가 `literature review`나 `hypothesis generation` 자체를 대체하진 못한다.
- open-ended research space는 깔끔한 factorization이 어렵다.
- large-scale training에서는 replication 비용이 크다.
- classical DOE는 discrete structural edit 공간에 그대로 맞지 않을 수 있다.
- evaluation harness가 약하면 DOE도 쉽게 흔들린다.

19. 결론

- AutoML에서 Autoresearch로 갈수록 `search space`는 넓어진다.
- search space가 넓어질수록 더 강한 `harness`가 필요하다.
- DOE는 Research Agent의 experimentation harness로 매우 유력한 후보다.

> 다음 단계는 더 좋은 agent 자체보다 더 좋은 harness이다.

20. References

구분	예시
curated landscape	`alvinreal/awesome-autoresearch`, `handsome-rich/Awesome-Auto-Research-Tools`
end-to-end systems	`karpathy/autoresearch`, `microsoft/RD-Agent`, `SakanaAI/AI-Scientist`
deep research	`assafelovic/gpt-researcher`, `Open Deep Research`, `PaperQA2`
experiment/code agents	`OpenHands`, `Aider`, `SWE-agent`, `AIDE`
evaluation	`openai/mle-bench`, `snap-stanford/MLAgentBench`, `chchenhui/mlrbench`