AutoML, Autoresearch, MLOps +@

26.4.8

서민교

1. AutoML이란 무엇인가?

- 모델 개발 탐색 일부 자동화
- 대표 대상: `model selection`, `hyperparameter tuning`, `pipeline search`
- 핵심: 비교적 주어진 `search space` 안 최적 설정 탐색

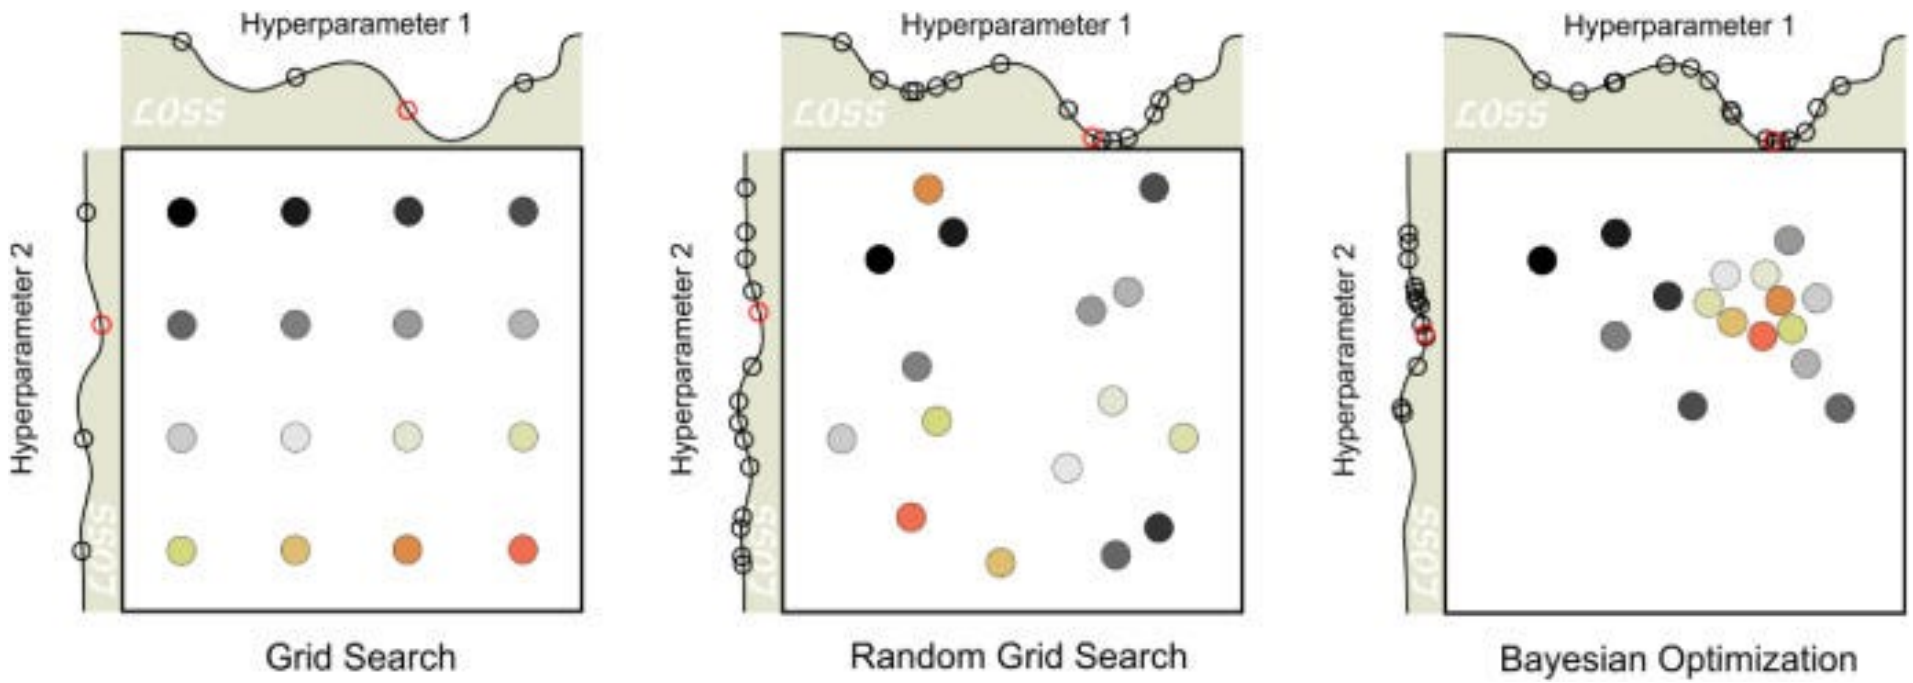

2. `Neural Architecture Search`는 AutoML의 확장이다

- parameter 대신 architecture 탐색
- AutoML의 `더 넓은 search space` 확장선
- 그래도 중심은 여전히 모델/파이프라인 후보 탐색

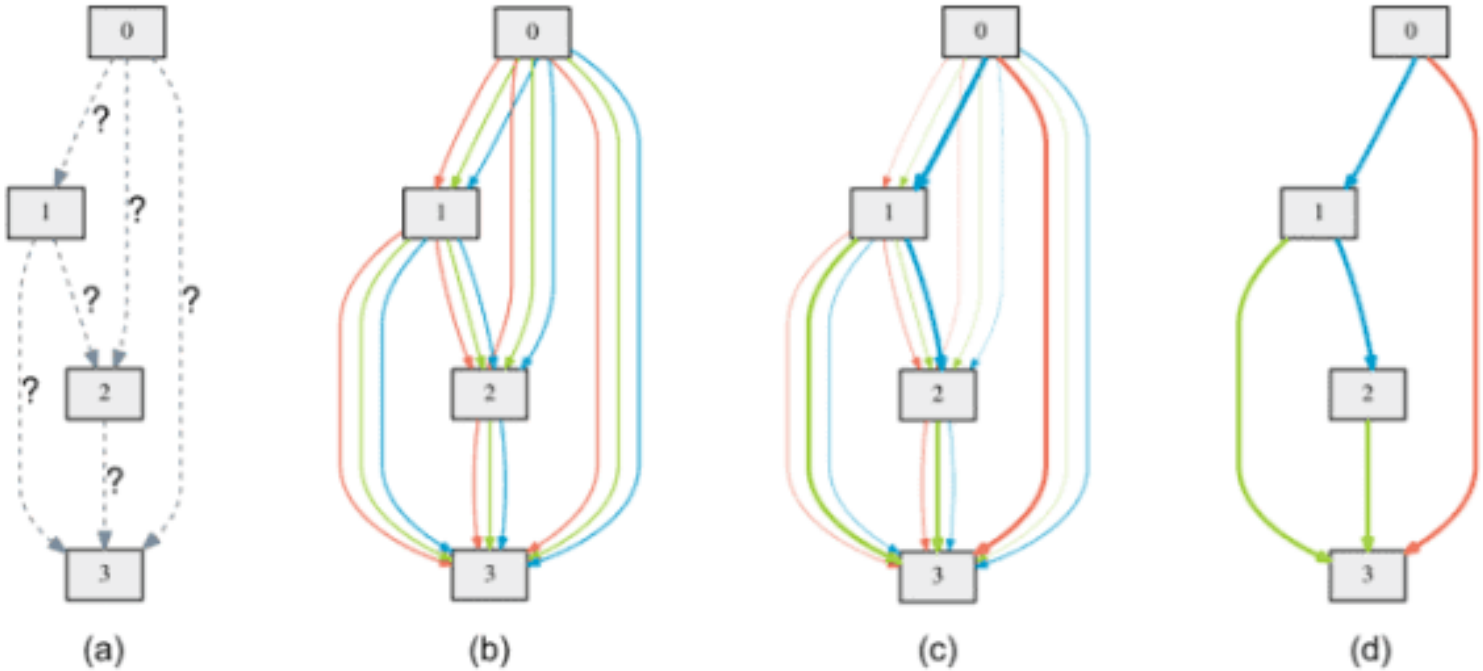

`hyperparameter search → pipeline search → architecture search`

3. `Autoresearch`는 어떻게 등장했고 무엇이 다른가?

- karpathy/autoresearch: 작은 training setup 위 `read → edit → run → keep-or-revert` loop 제시
- 연구 workflow 일부를 agent가 직접 수행하며, 설정 탐색을 넘어 `code`, `module`, `experiment` 자체 수정
- AutoML의 `fixed search space` 바깥으로 확장
- 이후 RD-Agent, AI-Scientist, GPT Researcher 등으로 빠르게 확장

4. Agent 작업 흐름

- 코드 읽기, baseline 파악
- 작은 가설 하나 선택
- 학습 코드나 설정 수정
- 짧은 실험 실행, metric 확인
- 나쁘면 revert, 의미 있으면 keep
- 핵심: `edit 한 번`이 아니라 `짧은 실험 loop의 누적`

```
Question → Read → Edit → Run → Analyze → Next experiment
```

5. AutoML vs. Autoresearch

항목	AutoML	Autoresearch
탐색 대상	config, pipeline, architecture	hypothesis, code, module, experiment
핵심 질문	어떤 설정이 가장 좋은가	다음에 어떤 실험을 해야 하는가
edit 단위	parameter / architecture	code / module / pipeline / experiment
평가 방식	objective 중심	objective + reasoning + iteration
위험	비효율적 탐색	incoherent search, metric hacking
필요한 인프라	experiment infra	experiment + memory + harness

6. 사용례와 확장

사용례

- 문헌 조사 / deep research: GPT Researcher
- 코드 수정 + 실험 반복: karpathy/autoresearch, RD-Agent
- end-to-end 연구 자동화: AI-Scientist

확장

- benchmark / evaluation: MLE-bench, MLAgentBench, MLR-Bench
- plugin / skill 생태계: awesome-autoresearch, Awesome Auto Research Tools
- memory, reusable modules, hardware fork

7. 체계적인 실험 관리의 필요

- 공통 문제: `많은 run` 비교와 누적
- 필수 요소: `tracking`, `lineage`, `orchestration`
- agent edit가 들어오면 `artifact`, `promotion`, `monitoring`, `cost control` 중요도 상승
- 결국 운영 문제

8. AutoML과 Autoresearch가 공통으로 요구하는 MLOps 요소

요소	AutoML에서의 역할	Autoresearch에서의 역할
tracking	sweep 비교	hypothesis / code edit history 비교
orchestration	search job 실행	agent + eval job 실행
registry / lineage	best model 승격	experiment / prompt / code provenance 보존
monitoring / cost	retrain trigger, SLO	budget, drift, unsafe promotion guardrail

9. MLOps는 모델 개발, 관리, 배포 파이프라인을 유지 관리하는 작업이다

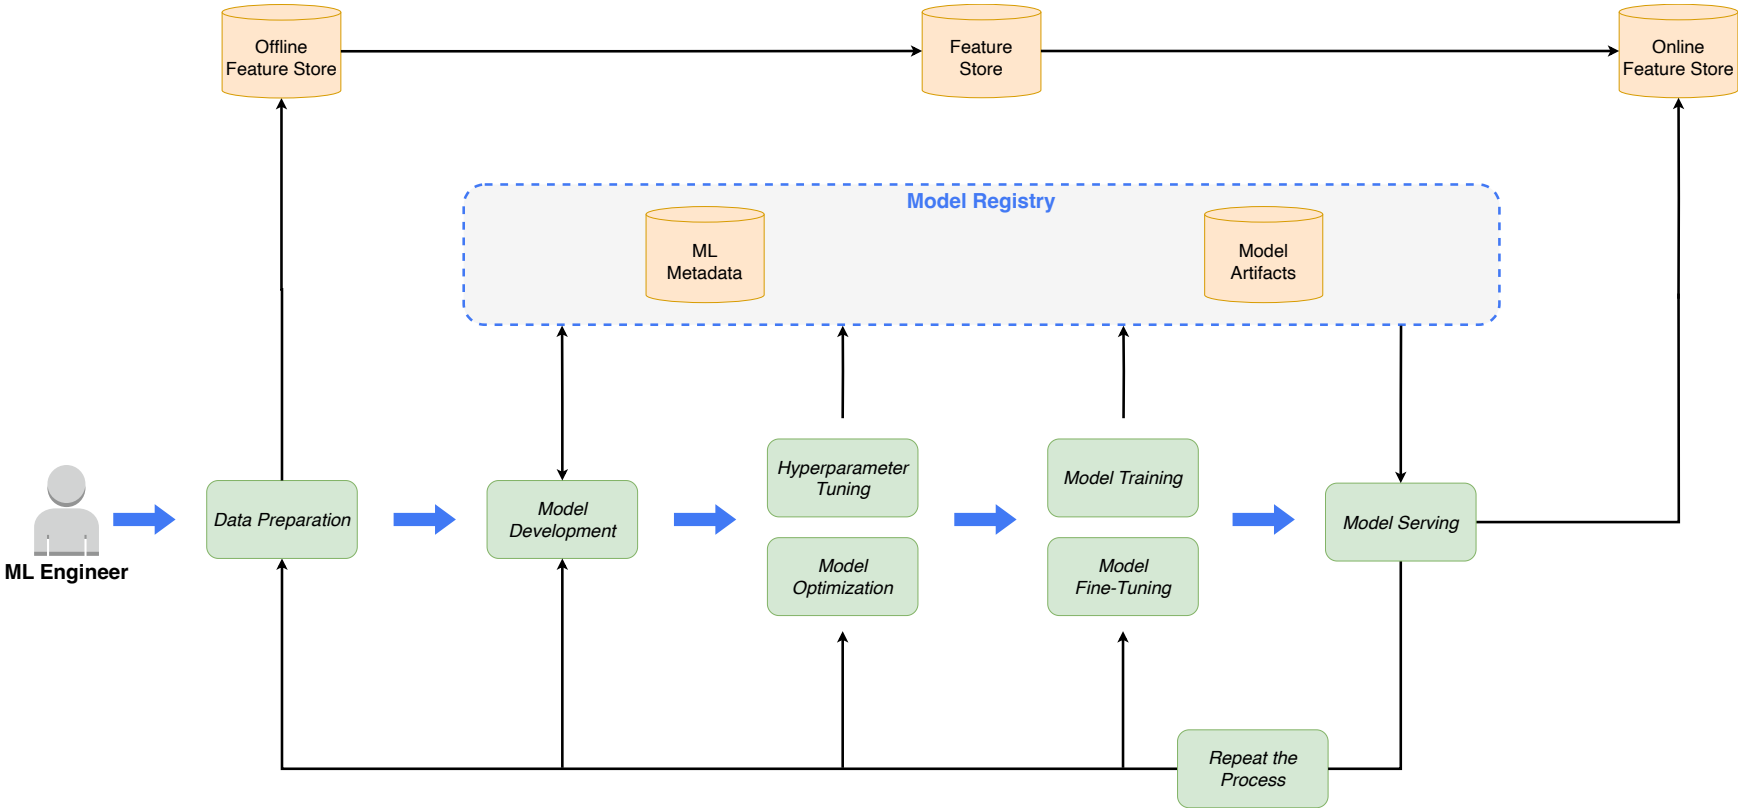

- Autoresearch loop는 이 큰 ML lifecycle 안의 일부
- 실제 시스템: `data`, `experiment`, `model registry`, `deployment`, `monitoring`
- 핵심 역할: `지속 운영`, `추적`, `승격`, `유지관리`

10. Autoresearch의 단점

- 실험이 즉흥적으로 이어지기 쉬움
- 왜 이 실험을 했는지 attribution이 약함
- 큰 수정, 작은 튜닝, 검증 실험이 섞이기 쉬움
- robustness, replication, interaction 확인이 뒤로 밀림
- 잘 정리된 random search로 퇴화할 위험

11. 어떤 Harness가 필요한가

- 무엇을 먼저 볼지 정하는 우선순위
- 어떤 조합을 함께 볼지 정하는 규율
- 탐색 단계와 검증 단계 분리
- 작은 수정과 큰 수정을 다르게 다루는 운영 규칙
- 실패도 정보로 남기는 구조
- 다음 라운드를 설계하는 순차 실험 체계

12. Design of Experiments(DoE)란 무엇인가

- 여러 요인을 한 번에 바꿔 보며 effect를 읽는 실험 설계
- 한 번의 최고점보다 `요인`, `상호작용`, `안정성` 파악에 강점
- 핵심 질문: 무엇을 바꿨고, 무엇이 실제로 영향을 줬는가

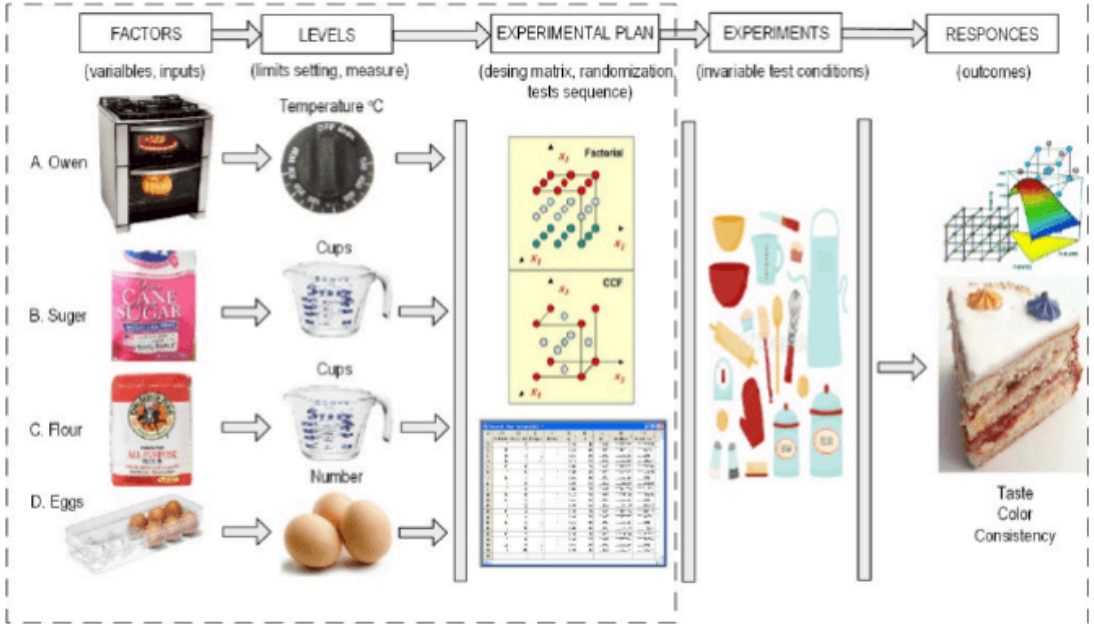

13. DoE에서 빌려오는 개념

- `screening` : 중요한 요인부터 좁히기
- `factorial thinking` : interaction 보기
- `sequential design` : 라운드별 정교화
- `robust design` : 평균이 아니라 안정성까지 확인
- `mixture / allocation` : 예산과 비율 배분

14. DoE-guided 운영과 비교한 Agents

Agent	운영 방식	특징
`01 Ratchet`	local ratchet loop	incumbent를 branch head로 두고 좁게 mutation
`02 Screening DoE`	simple screening	round마다 한 design question만 분리해 main effect를 읽음
`03 Advanced DoE`	staged DoE program	screening → interaction check → local refinement

15. 실험 설정

항목	설정
benchmarks	`cifar10_real`, `twenty_newsgroups_real`
data budget	CIFAR-10 `max_samples=4000`, 20 Newsgroups `max_samples=8000`
model	`mlp`
agents	`01 Ratchet`, `02 Screening DoE`, `03 Advanced DoE`
execution	dataset × agent별 isolated root `6` 개에서 validation `500` runs 후 hidden finalize

실행 조건

- agent별 isolated root를 따로 만들어 context leakage 없이 독립 실행
- `50-run` block마다 새 subagent를 붙여 context를 reset
- validation-only `500` runs를 먼저 누적하고 hidden test는 마지막 `finalize-agent`에서만 공개
- 이번 batch는 넓어진 MLP search surface를 사용

열려 있는 주요 축

- preprocessing: `normalization`, `outlier`, `projection`, `resampling`
- architecture: `hidden_dims`, `activation`, `normalization_layer`
- optimization: `solver`, `learning_rate`, `batch_size`, `max_iter`

16. CIFAR-10 결과: validation 탐색과 hidden test

조건: `cifar10_real` / `mlp` / block-reset execution / validation `500` runs + hidden finalize

Agent	Best Val	Hidden Test	Gap	Run of Best	Incumbent Updates
`01 Ratchet`	`0.4450`	`0.3933`	`0.0517`	`224`	`14`
`02 Screening DoE`	`0.4417`	`0.3900`	`0.0517`	`349`	`13`
`03 Advanced DoE`	`0.4117`	`0.3817`	`0.0300`	`394`	`8`

대표 config

- `01 Ratchet`: `maxabs + [128,128,64] + relu + sgd(adaptive,nesterov) + wd=5e-4 + lr=0.021 + bs=64`
- `02 Screening DoE`: `maxabs + clip_percentile + [64,32] + relu + adam + batchnorm + wd=5e-3 + lr=6.3e-5 + bs=128`
- `03 Advanced DoE`: `maxabs + [128,128,64] + relu + adam + wd=2e-4 + lr=0.0018 + bs=128`

17. CIFAR-10 결과: 탐색 궤적

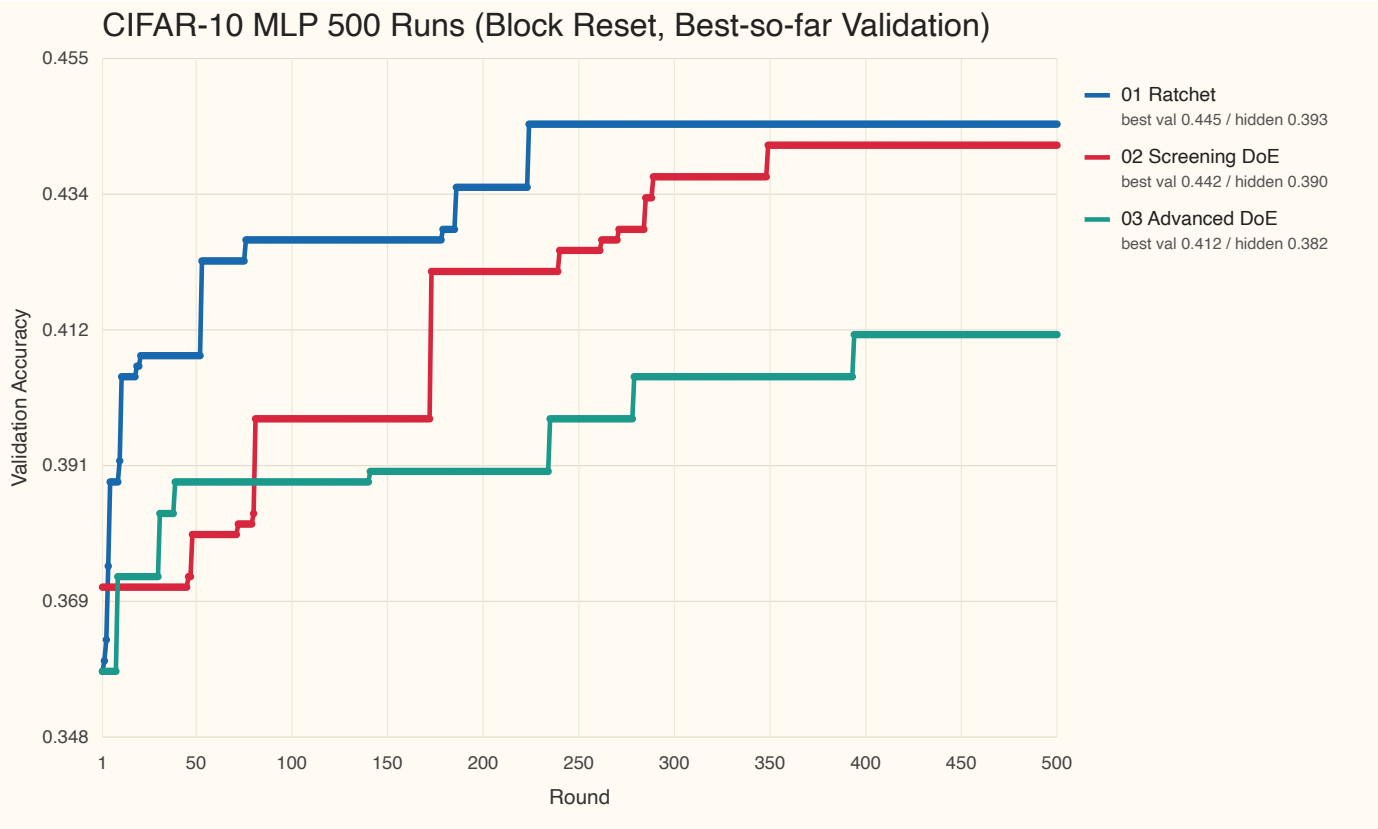

- `Ratchet` 은 중반까지 개선을 이어가며 가장 높은 CIFAR validation과 hidden을 남겼다.
- `Screening DoE` 는 늦게까지 개선했지만 Ratchet을 넘지는 못했다.
- `Advanced DoE` 는 이전 batch보다 일찍 plateau에 들어가 이번 설정에선 우세를 만들지 못했다.

18. CIFAR-10 해석

- block reset과 stricter loop hygiene를 넣자 CIFAR winner는 `Ratchet`으로 바뀌었다.
- 이번 search space에선 staged DOE보다 강한 local exploitation이 더 유리했다.
- `Screening DoE`는 좋은 basin까지는 갔지만 후반 ceiling이 낮았다.
- `Advanced DoE`는 gap은 가장 작았지만 absolute performance는 가장 낮았다.

19. 20 Newsgroups 결과: validation 탐색과 hidden test

조건: `twenty_newsgroups_real` / `mlp` / block-reset execution / validation `500` runs + hidden finalize

Agent	Best Val	Hidden Test	Gap	Run of Best	Incumbent Updates
`01 Ratchet`	`0.5375`	`0.4967`	`0.0408`	`235`	`15`
`02 Screening DoE`	`0.5717`	`0.5508`	`0.0208`	`299`	`19`
`03 Advanced DoE`	`0.5442`	`0.5275`	`0.0167`	`240`	`16`

대표 config

- `01 Ratchet`: `maxabs + [64,64] + tanh + adamw + layernorm + xavier_uniform + wd=5.86e-4 + lr=0.00119 + bs=64`
- `02 Screening DoE`: `robust + oversample_minority + [128,64] + leaky_relu + adam + xavier_normal + dropout + residual + warmup=16`
- `03 Advanced DoE`: `robust + [32] + relu + adam + wd=5e-5 + lr=7.85e-4 + bs=145`

20. 20 Newsgroups 결과: 탐색 궤적

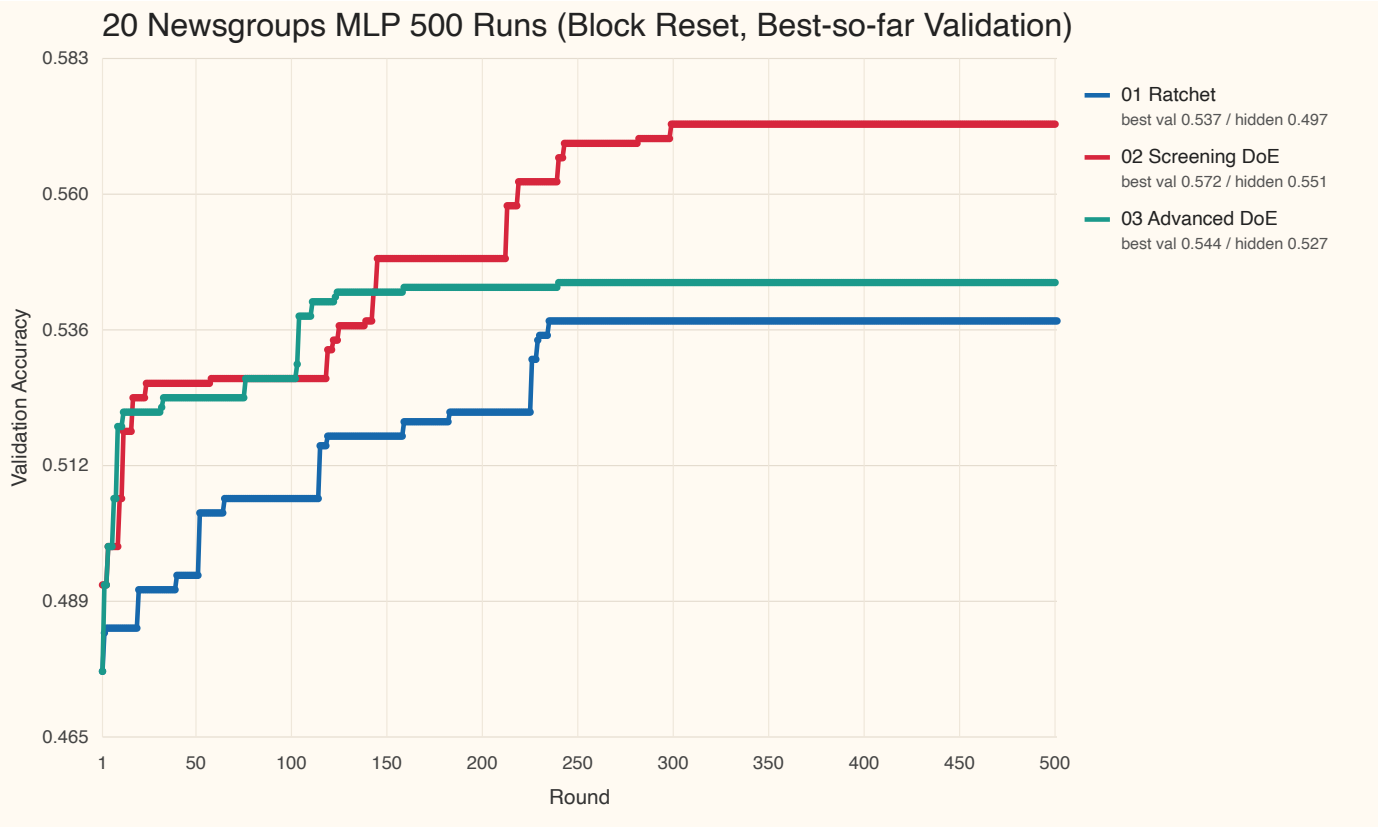

- `Screening DoE` 는 중반에 winner를 확정하고 끝까지 hidden에서도 유지했다.
- `Advanced DoE` 는 꾸준히 개선했지만 screening을 넘지 못했다.
- `Ratchet` 은 val은 올렸지만 hidden gap이 가장 컸다.

21. 20 Newsgroups 해석

- text에서는 이번에도 `Screening DoE`가 가장 강했다.
- robust scaling, oversampling, 중간 폭 MLP, 작은 warmup이 강한 prior로 남았다.
- `Advanced DoE`는 안정적이었지만 screening의 early win을 뒤집지는 못했다.
- `Ratchet`은 hidden gap이 가장 커서 generalization 측면에서 불리했다.

22. 히스토리에서 남는 지식

`01 Ratchet`

- CIFAR에서는 강한 incumbent basin을 붙잡고 끝까지 미는 전략이 실제로 가장 강했다.
- text에서는 좋은 basin은 찾았지만 hidden gap이 커서 confirmation quality가 약했다.
- reset을 넣어도 local exploitation 편향은 여전히 강하다.

`02 Screening DoE`

- text prior: `robust + oversampling + leaky_relu/adam + small warmup` 계열이 강하다.
- CIFAR에서는 `clip_percentile`와 작은 MLP branch가 끝까지 살아남았다.
- 두 dataset 모두 hidden에서도 비교적 안정적이었다.

`03 Advanced DoE`

- CIFAR에서는 이번 batch에서 payoff가 크지 않았다.
- text에서는 꾸준한 개선은 만들었지만 screening의 top basin은 못 넘었다.
- staged refinement가 항상 최고점으로 이어지지는 않는다는 반례로 읽힌다.

23. 히스토리 진단

Agent	CIFAR trace	Text trace	읽을 점
`Ratchet`	best `run 224`, updates `14`	best `run 235`, updates `15`	block reset 뒤에는 긴 예산도 실제 개선으로 연결됐다
`Screening DoE`	best `run 349`, updates `13`	best `run 299`, updates `19`	screening이 생각보다 오래 유효했고 hidden도 가장 안정적이었다
`Advanced DoE`	best `run 394`, updates `8`	best `run 240`, updates `16`	이번 batch에선 staged design이 winner를 만들지는 못했다

- 이번 batch에서는 초기 trap보다 `후반 예산을 누가 더 잘 쓰는가`가 더 중요했다.
- block reset을 넣자 세 agent 모두 장기 탐색 품질은 개선됐다.
- 하지만 dataset별 winner는 달랐다. CIFAR는 ratchet, text는 screening이었다.

24. 요약

- CIFAR winner: `01 Ratchet`, val `0.4450`, test `0.3933`
- Text winner: `02 Screening DoE`, val `0.5717`, test `0.5508`
- block reset을 넣은 이번 batch에서는 이전 결론이 일부 뒤집혔다.
- 같은 `mlp`라도 dataset이 바뀌면 좋은 harness가 달라졌다.

25. 한계

- 이번 결과는 single split 기준이라 분산 추정이 약하다.
- hidden test도 agent당 한 번만 열었으므로 replication이나 confidence interval은 없다.
- fixed subset 위 실험이라 dataset 전체 분포를 대표한다고 보기는 어렵다.
- text는 여전히 fixed TF-IDF representation 위 실험이라 representation search까지 포함한 결론은 아니다.
- `twenty_newsgroups_01_ratchet`은 최종 count가 `501`로 `+1` overshoot했다.

26. References

구분	예시
curated landscape	awesome-autoresearch, Awesome Auto Research Tools
end-to-end systems	karpathy/autoresearch, RD-Agent, AI-Scientist
deep research	GPT Researcher
evaluation	MLE-bench, MLAgentBench, MLR-Bench
visuals	AutoML image, NAS image, Kubeflow model registry lifecycle image